

金融數據分析期中報告

共同三家標的 + 個別第四家標的之效率前緣比較與整合分析

課程名稱：金融數據分析

報告名稱：共同三家標的 + 個別第四家標的之效率前緣比較與整合分析

組員：孔亭諭(611436002)、李宜璇(611436004)、

蕭靖誼(611436003)、葉竹芸(611436006)

共同三家標的：AAPL、JPM、XOM

各自第四家標的：GLD（孔亭諭）、TLT（李宜璇）、VNQ（蕭靖誼）、DJP（葉竹芸）

一、研究主題與動機

本次期中報告以 Markowitz 效率前緣理論為核心，探討在固定三家共同標的前提下，加入不同第四家標的後，投資組合效率前緣的改善效果。共同三家標的選擇 Apple Inc. (AAPL)、JPMorgan Chase (JPM) 與 ExxonMobil (XOM)，三者分屬科技、金融與能源產業，彼此相關係數介於 0.19 至 0.55 之間，具備適當的分散化基礎，非完全同向波動，適合作為比較分析的共同基準。

四位組員各自加入一家具差異性的第四家標的：黃金 ETF (GLD)、美國公債 ETF (TLT)、房地產 ETF (VNQ) 與原物料 ETF (DJP)，分別代表避險資產、固定收益、房地產信託與大宗商品等不同資產類別，藉此比較哪一個第四家標的對共同三家所形成的投資組合改善效果最佳。

研究核心問題為：在固定三家基準組合下，加入哪一類資產能最有效地使效率前緣向左上方移動，即在相同風險下提升預期報酬，或在相同預期報酬下降低風險？

二、研究設計與分工

本組研究設計分為四個階段：

- 第一階段：**全組共同選定三家投資標的 (AAPL、JPM、XOM)，統一資料期間 (2020/01–2024/12)、資料頻率 (月資料) 與報酬率定義 (簡單報酬率)。
- 第二階段：**每位組員各自選定一家具差異性的第四家標的，四人不重複，並說明選取理由。
- 第三階段：**各自完成三家與四家投資組合效率前緣分析，比較加入第四家前後的效率前緣變化，並計算最小變異投資組合 (MVP) 之報酬率與標準差。
- 第四階段：**整合四位組員之四家結果，以 MVP 風險下降幅度與效率前緣整體外移程度為指標，比較四種第四家標的何者改善效果最佳。

各組員工作分配如下：

組員	第四家標的	主要分工
孔亭諭	GLD 黃金 ETF	資料抓取與前處理、效率前緣主程式撰寫、整合比較圖製作、期中報告彙整
李宜璇	TLT 美國公債 ETF	個人分析 (TLT)、相關係數矩陣分析、共同三家選取說明撰寫

蕭靖誼	VNQ 房地產 ETF	個人分析 (VNQ)、Excel 整合比較表製作、資料設定與樣本說明撰寫
葉竹芸	DJP 原物料 ETF	個人分析 (DJP)、小組整合比較與結論撰寫、AI Prompt 紀錄整理

三、資料來源與樣本說明

本報告所有資料均透過 Python yfinance 套件自 Yahoo Finance 平台抓取 (auto_adjust=True 以還原股息調整後價格)，資料期間為 2020 年 1 月 1 日至 2024 年 12 月 31 日，採月資料 (interval='1mo')，共 60 個月價格觀測，計算簡單報酬率後得 59 筆有效資料。七支標的在此期間資料完整，無缺值或異常中斷。

資料設定摘要：

資料來源：Yahoo Finance (yfinance 套件, auto_adjust=True)

資料期間：2020 年 1 月 1 日至 2024 年 12 月 31 日

資料頻率：月資料 (interval='1mo')

樣本數：60 個月價格，59 筆有效報酬率

缺值處理：七支標的資料完整，無缺值，不需處理

各標的月平均報酬率與月標準差如下：

標的	月平均報酬率	月標準差	資產類別
AAPL	2.40%	8.41%	科技股
JPM	1.58%	8.12%	金融股
XOM	1.81%	9.73%	能源股
GLD	0.91%	4.16%	黃金 ETF
TLT	-0.56%	4.49%	美國公債 ETF
VNQ	0.43%	6.52%	房地產 ETF
DJP	0.87%	5.23%	原物料 ETF

四、報酬與風險衡量方法

本報告採用簡單報酬率計算月報酬，公式為： $R_t = (P_t - P_{t-1}) / P_{t-1}$ ，其中 P_t 為當月調整後收盤價， P_{t-1} 為上月調整後收盤價。各資產月平均報酬率取 59 筆報酬率之算術平均數。

投資組合預期報酬率為各資產報酬率之加權平均： $E[R_p] = \sum w_i \times E[R_i]$ 。投資組合風險（標準差）由共變異數矩陣計算： $\sigma_p = \sqrt{w^T \Sigma w}$ ，其中 Σ 為資產報酬率之樣本共變異數矩陣。

效率前緣透過在給定目標報酬率下最小化投資組合變異數求得，使用 `scipy.optimize.minimize`（SLSQP 法）進行數值最佳化。本報告允許放空（即權重無上下限限制，`bounds=(None, None)`），僅限制所有權重總和為 1，以完整呈現理論效率前緣形狀。最小變異投資組合（MVP）定義為效率前緣上標準差最小之點。

五、個人分析結果

（一）孔亭諭：GLD 黃金 ETF

指標	三家基準 MVP	四家 MVP (含 GLD)	變化
月平均報酬率	0.0200	0.0114	-43.16%
月標準差	0.0646	0.0360	↓ 44.32%

加入 GLD 後效率前緣明顯向左移動，MVP 風險由 0.0646 下降至 0.0360，降幅高達 44.32%，為四人中最大。GLD 與三家基準的相關係數極低（GLD-AAPL：0.23，GLD-JPM：0.02，GLD-XOM：-0.08），其中與 XOM 呈負相關，分散效果最為顯著。從效率前緣整體形狀來看，含 GLD 的前緣在中低風險區間（標準差 0.036 至 0.08）明顯位於三家基準前緣的左上方，意味著在相同風險下可達成更高預期報酬。

MVP 報酬雖由 0.0200 下降至 0.0114（降幅 43.16%），主因在於 MVP 最佳化權重中 GLD 配置高達 74.28%，而 GLD 本身月均報酬率（0.91%）低於三家基準，使組合 MVP 報酬下移。然而此為 MVP 單點的比較；若觀察整條效率前緣，在相同風險水準下含 GLD 的組合所能達到的最高報酬仍優於三家基準，顯示 GLD 帶來的是風險分散效益而非報酬提升效益。

結論：GLD 具有顯著投資效率，其與股票資產的低相關性使其成為四種第四家標的中最有效的分散化工具。

（二）李宜璇：TLT 美國公債 ETF

指標	三家基準 MVP	四家 MVP (含 TLT)	變化
月平均報酬率	0.0200	0.0002	-99.23%
月標準差	0.0646	0.0374	↓ 42.09%

加入 TLT 後 MVP 風險下降 42.09%，降幅與 GLD 相近，顯示長期公債在數學上同樣具有強力的降風險效果。TLT 與三家中 DJP 呈負相關（-0.17）、與 XOM 亦呈負相關（-0.18），與 AAPL 相關係數為 0.34，整體低相關性帶來明顯的分散效益。

然而，MVP 月報酬率幾乎歸零（0.0002，降幅 99.23%）。此因 2020 至 2024 年美聯準會由無限量化寬鬆轉向史上最激進升息周期，TLT 月均報酬率為 -0.56%，在 MVP 最佳化中大量配置 TLT（74.73%）嚴重拖累組合整體報酬。在效率前緣形狀上，含 TLT 的前緣低風險端雖確實位於基準前緣左側，但其可達到的最高報酬天花板遠低於其他配置。

結論：TLT 雖能有效降低 MVP 風險，但在 2020–2024 年升息環境下報酬表現極差，風險與報酬的整體權衡並不理想，屬於「降低風險但同時大幅犧牲報酬」的配置。此結論具有強烈的樣本期間依賴性。

（三）蕭靖誼：VNQ 房地產 ETF

指標	三家基準 MVP	四家 MVP (含 VNQ)	變化
月平均報酬率	0.0200	0.0149	-25.48%
月標準差	0.0646	0.0614	↓ 5.04%

加入 VNQ 後 MVP 風險僅下降 5.04%，為四人中改善效果最小。從效率前緣圖形可見，含 VNQ 的前緣與三家基準前緣幾乎重疊，在中低風險區間幾乎無向左外移跡象。

原因在於 VNQ 與三家基準的相關係數偏高（VNQ-AAPL：0.61，VNQ-JPM：0.65，VNQ-XOM：0.42），VNQ 與三家的報酬高度同向波動，邊際分散效果極為有限。VNQ 本身月均報酬率（0.43%）亦低於三家均值，加入後 MVP 報酬下移 25.48%。值得注意的是，在高風險端（標準差大於 0.12），含 VNQ 的前緣可延伸至更高報酬，但此段需承受超出一般投資人風險承受度的波動。

結論：VNQ 因與三家基準高度相關，邊際分散效果最小，加入後效率前緣改善幅度不顯著，不具備有效的分散化貢獻。

(四) 葉竹芸：DJP 原物料 ETF

指標	三家基準 MVP	四家 MVP (含 DJP)	變化
月平均報酬率	0.0200	0.0122	-38.94%
月標準差	0.0646	0.0482	↓ 25.41%

加入 DJP 後 MVP 風險下降 25.41%，改善效果中等，介於 VNQ（5.04%）與 GLD（44.32%）之間。DJP 與三家基準的相關係數適中（DJP-AAPL：0.28，DJP-JPM：0.37，DJP-XOM：0.56），其中與 XOM 相關係數最高（0.56），反映原物料與能源股之間存在較強的景氣連動性，部分抵銷了分散效果。

在效率前緣形狀上，含 DJP 的前緣在低風險端（標準差 0.048 至 0.07）有一定程度的左移，但幅度不及 GLD 或 TLT 明顯。DJP 月均報酬率（0.87%）低於三家均值，MVP 最佳化配置中 DJP 佔 70.08%，導致 MVP 報酬下移 38.94%。

結論：DJP 具備一定分散效果，但因與 XOM 相關性較高，邊際貢獻受限，效率前緣改善效果中等。

六、小組整合比較

以下整合四位組員之分析結果，以 MVP 風險下降幅度為主要量化指標，並輔以效率前緣整體外移程度進行綜合評估：

第四家標的	風險下降幅度	MVP 報酬變化	效率前緣整體外移	綜合評估
GLD 黃金 ETF	44.32% ★	-43.16%	低風險端明顯左移，整體前緣飽滿左擴	最佳
TLT 美國公債 ETF	42.09%	-99.23%	低風險端左移，但高報酬端受壓縮	風險降低但報酬犧牲過大
VNQ 房地產 ETF	5.04%	-25.48%	前緣與基準幾乎重疊，改善幅度不顯著	改善效果最小
DJP 原物料 ETF	25.41%	-38.94%	低風險端有一定左移，幅度中等	中等

在整合比較時，本組確認以下一致性事項：四位組員使用相同三家基準（AAPL、JPM、XOM）、相同資料期間（2020/01–2024/12）、相同月資料頻率、相同簡單

報酬率定義，以及相同效率前緣建構方法（`scipy minimize`，允許放空），確保比較基礎一致。

綜合比較，GLD 黃金 ETF 對共同三家投資組合的改善效果最佳。雖然 TLT 的風險下降幅度與 GLD 相近（42.09% vs 44.32%），但 TLT 使 MVP 報酬率幾乎歸零，在風險報酬整體權衡下不具投資效率。更重要的是，從效率前緣整體形狀來看，含 GLD 的前緣在低風險至中等風險的廣泛區間均位於三家基準前緣的左上方，代表在各種風險承受度下均能獲得改善；TLT 則僅在極低風險端有改善效果，高報酬可能性受到嚴重壓縮。VNQ 因高相關性使邊際分散貢獻最小；DJP 表現中等。因此本組結論為：GLD 為四種第四家標的中，對共同三家投資組合改善效果最佳的選擇，主因在於其與股票資產的低相關性結構（最高 0.23，最低 -0.08）提供了最有效的分散化效益。

七、結論與反思

本次期中報告透過 Python 程式化分析，系統性地比較加入不同第四家標的後效率前緣的變化。研究結果顯示，資產間的相關性結構是決定第四家標的改善效果的關鍵因素：GLD 與三家基準的低相關性（最高 0.23，最低 -0.08）使其成為最有效的分散化工具，而 VNQ 與三家基準的高相關性（最高 0.65）使其邊際貢獻幾乎消失。

方法限制

- 1. 歷史資料假設：**本報告採用 2020–2024 年歷史資料估計預期報酬與共變異數，此期間涵蓋新冠疫情衝擊（2020）與聯準會史上最激進升息周期（2022–2023），TLT 在此期間錄得歷史性跌幅，未來報酬不保證與歷史一致。
- 2. 放空假設：**本報告允許放空（`bounds` 無上下限），效率前緣為理論最優解。實務上放空需支付借券費用並承擔融資風險，實際可達成的報酬略低於理論曲線。
- 3. 未納入夏普比率最佳化：**本報告以 MVP 風險下降幅度為主要指標，未納入無風險利率計算夏普比率（Sharpe Ratio）或找出切點投資組合（Tangency Portfolio），未來可進一步延伸分析。
- 4. 交易成本與流動性：**模型未納入交易成本、滑價與流動性限制，實務投資組合調整時需考量此類摩擦成本。

AI 協作效益

本次報告過程中使用 Claude 協助 Python 程式撰寫、圖表製作與文件格式整理，詳細 AI Prompt 迭代歷程記錄於附錄。AI 工具有效提升了分析效率，特別是在效率前緣數值最佳化、matplotlib 圖表製作（含中文字體相容性問題處理）與 Word 文件自動化生成方面。然而，對於金融邏輯的判斷（如 TLT 在升息環境下的報酬特性解讀、相關係數結構的分析）與結果合理性的驗證，仍須由研究者自行負責，AI 僅作為計算與格式化的輔助工具。

八、AI Prompt 協作紀錄

以下為本次期中報告之 AI 協作迭代歷程，呈現 Prompt 設計、修正與反思過程。

任務目標

本次任務目標為「完善期中專題報告的效率前緣分析與專案目錄重構」。需求包含：找出用於比較四種資產效率前緣的 Python 程式碼、對散落的專案檔案進行系統性分類、在不破壞 Word 報告排版的前提下將圖表插入報告，以及解決 matplotlib 繪圖時出現的中文字體相容性問題。

Prompt 迭代歷程

第一次 Prompt（初始指令）

指令內容：「請幫我找出專案中用於繪製『四家資產效率前緣比較圖』的 Python 檔案。另外，目前專案資料夾結構過於混亂，請協助建立分類邏輯並重新整理所有檔案。」

AI 回應：AI 成功在資料夾中檢索出 `comparative_analysis.py`，並提出目錄重構計畫，將檔案分類成 `src`（原始碼）、`reports`（報告文件）、`data`（數據）、`images`（圖表）與 `tools`（除錯腳本）五大類，解決了專案環境混亂的問題。

反思：初始指令包含兩個不同性質的任務（找檔案＋重構目錄），AI 均順利處理，但若分開下達指令可獲得更精準的回應。

第二次 Prompt（優化過程）

指令內容：「請撰寫 Python 腳本，將四位組員個別的效率前緣圖與整合圖自動插入期中報告的 Word 檔中，且不得更動原有文字排版。另外，請修改 Python 繪圖程式，將圖表上的預設標籤修改為客觀的『組員 A、B、C、D』形式以符合報告規範。」

AI 回應：AI 撰寫了基於 python-docx 的自動化腳本，將圖表以附錄形式 append 到 Word 報告尾端，避免人工貼圖可能導致的跑版問題。同時順利修改程式碼，將代名詞替換為學術報告適用的客觀標籤。

反思：「不得更動原有文字排版」是關鍵約束條件，明確指定約束後 AI 選擇 append 而非 insert 的策略，避免了潛在的排版問題。

第三次 Prompt（最佳指令）

指令內容：「目前產出的新圖表中，文字因系統不支援中文字型而顯示為亂碼方塊。請修改程式碼，將圖表中的所有標籤與標題轉換為專業的英文金融術語來解決此問題。」


AI 回應：針對 macOS 環境下 matplotlib 中文字型缺失（Glyph missing）問題，AI 建議將標籤全面翻譯為專業英文金融術語（如 Monthly Std Dev、Monthly Avg Return、MVP），不僅立即解決字體相容性問題，全英文視覺化圖表也提升了報告的專業度。

反思：直接翻譯為英文是高效且優雅的解法，相較於安裝中文字型套件的繁瑣方式，此方案在不同作業系統環境下均可重現，具有更好的跨平台相容性。

附錄：各標的相關係數矩陣與效率前緣比較圖


1. 各標的相關係數矩陣

資料期間：2020 年 1 月至 2024 年 12 月，月資料，樣本數 59 筆。



2. 四位組員各自之效率前緣對比（統一座標軸）

以下四圖使用統一座標軸（X 軸：月標準差 0.03–0.19；Y 軸：月均報酬率 -0.005–0.035），確保跨圖比較基礎一致。



3. 四家資產效率前緣整合全景比較圖

以下整合圖將四種第四家標的之效率前緣繪製於同一座標系，並標示三家基準前緣（黑色虛線）作為對照，可直觀比較各第四家標的之改善效果與差異。

小組總結：四大類資產避險效益與效率前緣全景比較

