

判決文本會說話嗎？

臺灣智慧財產權裁判結果之文字探勘與分類研究

Do Court Judgments Speak? Text Mining and Classification of Intellectual Property Judgment Outcomes in Taiwan

摘要

隨著司法資料公開與法律科技發展，判決文本分析已成為實證法律研究的重要議題。本研究以臺灣智慧財產權相關裁判書為資料來源，將裁判結果整理為敗訴、部分勝訴與勝訴三類，並依行政、民事、刑事與刑事附帶民事案件分別建模。研究流程包含文本清理、停用詞移除、中文斷詞、BoW、TF 與 TF-IDF 特徵表示、Chi-square 特徵選擇，以及 Chi-square + MNIR + SVM 與 Chi-square + SVM 兩種流程比較。結果顯示，Chi-square + SVM 在四類案件資料集之 Macro F1 皆優於加入 MNIR 轉換之流程；不同案件類型適合的文字特徵表示亦不相同。本文指出，智慧財產權判決分類應重視案件異質性、少數類別辨識與可解釋基準模型。

關鍵字：智慧財產權、判決文本、文字探勘、MNIR、SVM

Abstract

This study analyzes Taiwanese intellectual property judgments using text mining and machine learning. Judgment outcomes are classified into Lose, Mixed, and Win, and four case types are modeled separately: administrative, civil, criminal, and criminal cases with attached civil claims. The study compares BoW, TF, and TF-IDF representations, Chi-square feature selection, and two pipelines: Chi-square + MNIR + SVM and Chi-square + SVM. The results show that Chi-square + SVM outperforms the MNIR pipeline in Macro F1 across all case types. Feature representations also vary by case type, suggesting that legal text classification should account for case heterogeneity, class imbalance, and interpretable baseline models.

壹、前言

近年來，大數據與人工智慧的發展，使法律研究逐漸從傳統法釋義學與個案分析，延伸至以資料為基礎的實證研究。臺灣司法體系在資料透明與開放方面具備制度性優勢，公開裁判書查詢系統累積大量完整判決全文，為法律實證研究與法律科技應用提供重要資料基礎。然而，判決全文主要以自然語言呈現，包含主文、事實、當事人主張、法院理由與法律適用，並非可直接投入統計模型的結構化資料。因此，如何將裁判文本轉換為可計算且可解釋的文字特徵，是法律文本分析的重要問題。

智慧財產權案件尤其適合作為研究對象。此類案件常涉及專利範圍解釋、商標混淆、著作利用、營業秘密與損害賠償等專業議題，文本中同時包含法律規範、技術事實、權利範圍、行為主體與因果關係等多層次資訊。另一方面，智慧財產權案件之裁判結果在不同案件類型間高度不均衡，有些類型以 Lose 為主，有些類型以 Win 或 Mixed 為主。若模型僅追求整體準確率，可能因大量預測多數類別而取得表面上較高分數，卻無法辨識真正重要的少數類別。

基於上述背景，本研究以臺灣智慧財產權相關裁判書為研究對象，建立裁判結果分類流程。本文將裁判結果整理為敗訴、部分勝訴與勝訴三類，並依案件類型區分為行政、民事、刑事與刑事附帶民事案件。在方法上，本文比較 BoW、TF 與 TF-IDF 三種文字特徵表示，並以 Chi-square 特徵選擇後之 SVM 為基準流程，進一步檢驗 MNIR 監督式特徵轉換是否能帶來額外分類增益。

一、研究目的與問題

本研究目的有五項：第一，建立臺灣智慧財產權判決文本分類流程；第二，比較 BoW、TF 與 TF-IDF 在不同案件類型下的分類效果；第三，檢驗 MNIR 監督式特徵轉換於中文智慧財產權判決分類中的適用性；第四，分析模型對敗訴、部分勝訴與勝訴三類結果的辨識能力；第五，建立不僅依賴 Accuracy，而能同時檢視 Macro F1、分類報告與混淆矩陣的評估方式。

據此，本文提出四個研究問題：（一）不同文字特徵表示方式在智慧財產權判決結果分類中的表現是否存在差異？（二）在卡方特徵選擇後，MNIR 監督式特徵轉換是否能相較於 Chi-square + SVM 提升分類表現？（三）不同案件類型下，較適合的文字特徵表示與模型流程是否不同？（四）在裁判結果類別不平衡的情況下，模型是否能有效辨識敗訴、部分勝訴與勝訴三類結果？

貳、文獻回顧

一、實證法律研究與司法資料分析

實證法律研究強調以資料觀察法律制度的實際運作，並透過統計分析、計量方法或文字探勘檢視法院裁判、司法行為與訴訟結果。國外研究已運用大量法院資料分析司法決策，例如外部事件、氣溫、案件特徵或訴訟資源與裁判結果的關係。在臺灣，司法資料公開亦使研究者能從判決全文、案件類型與裁判結果等面向進行量化研究。此一研究傳統說明，判決書不僅是法理文本，也可轉化為可觀察、可檢驗的實證資料。

相較於傳統法學研究主要透過法規、判決與學說探討法律應如何解釋，實證法律研究更關注法律制度在大量案件中的實際呈現。法院判決可提供案件事實、訴訟類型、當事人主張、法院理由與結果等資訊，使研究者得以觀察特定法律領域是否存在穩定模式。對管理、風險與決策研究而言，裁判結果亦可視為制度環境中的重要資料來源，因其反映交易、創新、權利保護與爭端解決的實際成本。

臺灣公開裁判書資料具備兩項研究優勢。第一，資料量大且可跨年度累積，適合觀察長期趨勢與不同案件類型之差異。第二，裁判書全文包含法院對事實與法律爭點的敘述，使研究者不必僅依賴少數結構化欄位。然而，這些優勢也帶來方法挑戰：裁判書內容冗長、段落結構不一、法律術語密集，且同一概念可能以不同語句表達。若無適當文字處理流程，公開資料的規模優勢未必能轉化為可解釋的研究結果。

二、法律文本之特徵表示

在文字探勘與文本分類任務中，第一個關鍵步驟是將非結構化文本轉換為模型可處理的數值特徵。BoW 將每篇文件視為詞彙集合，以詞項是否出現或出現次數作為特徵；TF 將詞彙次數轉換為相對頻率，以降低裁判書長度差異的影響；TF-IDF 則同時考量詞彙於個別文件中的出現頻率及其在整體語料中的稀有程度。雖然這些方法不直接處理深層語意，但在法律、金融等高度制度化文本中，詞彙本身的出現與分布仍可能包含重要分類訊號。

法律文本與一般新聞或社群文本不同，其文字具有高度制度化特徵。判決書經常重複使用固定法律語彙，例如構成要件、程序判斷、證據評價、請求權基礎與裁判結論。這使傳統稀疏特徵仍具研究價值，因為特定詞彙或詞彙組合可能直接對應到法律爭點與程序狀態。以智慧財產權案件為例，專利範圍、均等論、商標近似、混淆誤認、著作利用或營業秘密等詞彙，皆可能與案件類型及裁判結果存在統計關聯。

不過，法律文本特徵表示仍須面對兩個限制。第一，BoW、TF 與 TF-IDF 多半忽略詞序與句法結構，難以直接呈現法院推論過程。第二，裁判結果相關詞彙可能造成資料洩漏，使模型學到結果附近的固定語句，而非案件事實或法律理由。本文因此將傳統文字特徵視為可解釋基準，而非完美語意表示；研究重點在於比較不同特徵表示於相同資料處理條件下的相對效果，並檢視其在少數類別上的限制。

三、判決預測、可解釋性與本研究定位

法律判決預測是法律人工智慧的重要任務，其核心目標是利用案件事實、法律文本、法院理由或其他案件資訊，預測法院可能作成之裁判結果。既有研究顯示，法律文本中確實存在可供模型辨識之訊號。不過，司法應用場域特別重視模型可解釋性；若模型僅能提供預測結果，卻無法說明其依據，則在研究與實務中的使用皆受限制。相較於複雜深度模型，傳統文字特徵與 SVM 雖然語意表示能力有限，但具備較清楚的基準價值與可比較性。

既有法律判決預測文獻常處理二元分類、多類別分類、多標籤分類或多任務學習等不同任務。深度學習模型雖可能取得較佳表現，但其黑箱性使研究者較難判斷模型是否依賴法律上有意義的資訊。對於仍在建立資料處理與基準模型的研究情境，較穩健的做法是先以可重複、可比較且相對可解釋的流程建立基準，再評估更複雜模型是否真正改善少數類別與跨案件類型表現。

本研究定位在於建立臺灣智慧財產權判決結果分類之基準流程，而非宣稱模型可直接預測個案勝敗。相較於僅檢驗單一模型是否有效，本文同時納入案件類型、文字特徵表示、MNIR 特徵轉換與少數類別評估。此一設計可回答更具方法意義的問題：在中文智慧財產權裁判文本中，分類訊號是否主要保留於稀疏詞彙特徵？監督式降維是否會帶來額外效益？不同法律程序的文本是否需要不同特徵表示？

四、MNIR 監督式特徵轉換

MNIR 由 Taddy (2013) 提出，主要用於高維文字資料之監督式降維。其核心想法是以類別或低維分數反向解釋詞彙分布，藉由 inverse regression 將高維文本表示轉換為較低維的充分縮減分數。本研究在中文智慧財產權判決文本脈絡中檢驗 MNIR 是否能夠於 Chi-square 特徵選擇後進一步提升分類表現，並以直接使用卡方篩選後稀疏特徵的 Chi-square + SVM 作為對照流程。

MNIR 對文字資料具有吸引力，因為法律文本通常具有高維、稀疏與共線性高等特性。若能將大量詞彙壓縮為少數具有監督訊號的分數，理論上可降低模型複雜度並改善分類器穩定性。然而，監督式降維也可能帶來資訊壓縮風險，尤其在類別分布不均衡或少數類別具有細緻詞彙訊號時，低維表示未必能完整保留少數類別差異。因此，MNIR 是否有助於智慧財產權裁判結果分類，仍須透過實證比較檢驗。

參、研究方法與資料

一、資料來源與樣本整理

本研究資料取自司法院資料開放平台，蒐集期間為 1996 年 1 月至 2024 年 12 月。原始資料為 JSON 格式，欄位包含案號、年度、字別、號碼、裁判日期、案由、全文與裁判書 PDF 下載連結。經案由關鍵字及案件字別初步篩選，共取得 90,027 篇智慧財產權相關裁判書；再排除案件類型或裁判結果無法明確歸類者，最終保留 45,344 篇，作為後續模型分析樣本。

智慧財產權案件係依案由中的商標、著作權、專利等關鍵字，以及案件字別進行初步篩選；其後僅保留可明確歸入行政、民事、刑事與刑事附帶民事，且裁判結果可整理為 Lose、Mixed 或 Win 的案件。此一篩選邏輯可降低非智慧財產權案件或結果不明案件混入樣本的可能性，並使後續模型比較建立在較一致的任務定義上。

本文將案件類型區分為行政、民事、刑事與刑事附帶民事案件。行政案件多涉及人民或法人與行政機關間之公法爭議；民事案件多涉及私人間權利義務與財產利益；刑事案件係國家對犯罪行為之追訴與處罰；刑事附帶民事案件則是在刑事程序中一併處理被害人賠償請求。此一分類有助於避免不同法律程序與文本結構混雜，使模型比較更能反映案件類型差異。

資料處理流程包括案件篩選、文本清理、停用詞移除、中文斷詞與裁判結果標籤整理。中文斷詞結合 CKIP Transformers 與司法裁判用語辭典進行，並搭配 Jieba stop words 等停用詞字典移除低資訊量詞彙。為降低模型直接依賴結果用語的疑慮，本文移除如「駁回」、「有理由」、「准許」、「撤銷」等明顯裁判結果詞彙，但仍承認裁判文本中可能保留間接結果線索，因此本文結論應被理解為判決文本分類效果，而非完全排除所有結果訊號後的事前預測效果。

表 1 案件類型與裁判結果分布

資料集	Lose	Mixed	Win	合計
行政	10106	502	911	11519
民事	3887	1408	435	5730
刑事	1636	80	24552	26268
刑事附帶民事	748	1047	32	1827
合計	16377	3037	25930	45344

由表 1 可知，本研究資料合計 45,344 筆，且四類案件皆呈現不同程度的類別不平衡。行政案件以 Lose 類別為主，刑事案件以 Win 類別為主；刑事附帶民事案件雖然 Mixed 樣本較多，但 Win 類別僅 32 筆。此一分布使 Macro F1 較 Accuracy 更適合作為主要評估指標，因其能平均反映各類別之辨識能力。

表 2 裁判結果標籤整理原則

標籤	意義	整理原則
Lose	敗訴	主要請求未獲法院支持，或上訴、抗告、聲明等程序結果對主張方不利。
Mixed	部分勝訴	部分請求成立、部分金額獲准、部分權利或爭點受支持，或同案不同當事人結果不完全一致。
Win	勝訴	主要請求或救濟方向獲法院支持，裁判結果整體上對主張方有利。

表 2 說明本文三類裁判結果標籤之整理邏輯。此一設計比二元勝敗分類更貼近智慧財產權案件實際情形，因為部分勝訴在專利、商標、著作權與營業秘密案件中並不少見。例如，法院可能僅支持部分請求項、部分商品類別、部分損害賠償金額，或對不同被告作出不同判斷。若將此類案件強行併入勝訴或敗訴，將降低標籤的法律意義，也可能使模型評估失真。

表 3 年度區間與案件類型分布

年度	行政	民事	刑事	刑事附帶民事	合計
80 ~ 85 年	0	0	12	0	12
86 ~ 89 年	1068	9	1041	30	2148
90 ~ 95 年	4684	828	5880	61	11453
96 ~ 101 年	2852	1753	7723	420	12748
102 ~ 107 年	1764	1724	6340	678	10506
108 ~ 113 年	1151	1416	5272	638	8477

表 3 顯示，樣本集中於 90 年以後，且不同年度區間的案件組成並不相同。行政案件於早期年度占比較高，民事與刑事附帶民事案件則在後期逐漸增加。此一時間分布表示，模型可能同時面對案件類型、法律制度演變、裁判書書寫方式與文本長度變化等多重因素。因此，本文採案件類型分別建模，以降低異質資料混合後造成的解釋困難。

二、文字特徵與模型流程

本文建立三種文字特徵表示。BoW 保留詞彙原始出現次數，適合檢視法律用語或程序用語是否出現；TF 將詞彙次數轉換為相對頻率，可降低長短裁判書差異；TF-IDF

則降低常見詞彙權重並強化相對具區辨力之詞彙。本文不預設單一表示方法必然最佳，而是分案件類型比較其分類效果。

特徵選擇方面，本文採用 Chi-square 篩選與 Lose、Mixed、Win 三類結果較相關的詞彙特徵。模型流程包括兩組：第一組為 Chi-square + MNIR + SVM，亦即先以卡方篩選詞彙，再透過 MNIR 將高維文字特徵轉換為充分縮減分數，最後以 SVM 分類；第二組為 Chi-square + SVM，直接使用卡方篩選後的稀疏文字特徵訓練 SVM。MNIR 模型以 Gamma-Lasso 進行正則化估計；分類器採用 scikit-learn 之 LinearSVC，適用於高維稀疏文字特徵。另以 Majority Class baseline 作為最低比較基準，以檢查模型是否僅學到多數類別。

表 4 本研究各方法之功能與流程比較

方法	流程角色	主要功能
BoW	文字特徵表示	建立文件 - 詞彙矩陣，保留詞彙原始出現次數
TF	文字特徵表示	將詞彙次數轉換為相對詞頻，降低裁判書長度差異影響
TF-IDF	文字特徵表示	降低常見詞權重，強化相對具區辨力詞彙
Chi-square	特徵選擇	選取與 Lose、Mixed、Win 較相關之詞彙特徵
MNIR	監督式特徵轉換	將高維文字特徵轉換為充分縮減分數
SVM	分類器	將裁判書分類為 Lose、Mixed、Win
Majority baseline	基準模型	全部預測為多數類別，用以檢查模型是否超越最低基準

在中文法律文本處理上，斷詞品質會直接影響後續特徵矩陣。智慧財產權判決常同時出現一般法律詞彙、專利或商標專門用語、技術名詞與程序性表述。若切詞過細，模型可能取得大量低資訊量詞項；若切詞過粗，則可能使具有法律意義的詞彙組合無法被辨識。本文因此將斷詞、停用詞移除與明顯結果詞彙排除視為前處理核心，並在三種特徵表示下保持相同資料切分，讓不同流程之比較盡可能集中於特徵表示與模型流程本身。

三、評估方式

本文同時使用 Accuracy、Macro F1、分類報告、混淆矩陣與 Majority Class baseline 評估模型。Accuracy 反映整體預測正確比例，但在類別不平衡資料中可能被多數類別主導。Macro F1 則先分別計算各類別 F1，再取平均，因此能更清楚呈現模型是否兼顧少數類別。分類報告與混淆矩陣則用於進一步檢視模型是否將 Mixed 或 Win 樣本誤判為 Lose。

各案件類型資料集依 70%、10% 與 20% 的比例，分別劃分為訓練集、驗證集與測試集。卡方特徵選擇、MNIR 估計與 SVM 訓練以訓練集為基礎，驗證集用於選擇特徵數 K 與懲罰參數 C，測試集僅用於最終模型評估。K 與 C 皆由預先設定的候選參數組合中，依驗證集 Macro F1 選定。本文之目標並非宣稱某一模型可直接取代法律判斷，而是檢驗不同文字表示、特徵轉換與案件類型在智慧財產權判決文本分類中的相對效果。

表 5 最佳 Chi-square + SVM 模型之參數選擇摘要

資料集	K	Selected Features	Best C	Validation Macro F1
行政	3000	3000	4.0	0.379
民事	5000	5000	4.0	0.463
刑事	5000	5000	4.0	0.515
刑事附帶民事	3000	3000	0.0625	0.745

表 5 彙整各資料集在驗證集上選出的主要參數。行政與刑事附帶民事案件選用 3,000 個特徵，民事與刑事案件則選用 5,000 個特徵。此結果顯示，不同案件類型所需的詞彙維度並不一致；案件文本較複雜或爭點較分散時，較高特徵數可能有助於保留分類訊號。

四、研究流程與資料處理補充

在裁判結果標籤整理上，本文採三類分類而非二元分類，原因在於智慧財產權案件常出現部分請求成立、部分損害賠償獲准、不同權利項目分別判斷，或同一案件中不同當事人與不同爭點結果不一致之情形。若僅以勝敗二分，可能掩蓋部分勝訴案件的法律意義。本文將 Mixed 作為獨立類別，雖然增加分類難度，卻較能呈現智慧財產權訴訟結果的實際樣態。

在案件類型分別建模上，本文避免將行政、民事、刑事與刑事附帶民事案件直接混合。這四類案件雖同屬智慧財產權領域，但法律程序、裁判書結構、當事人角色與主要爭點皆不同。行政案件常圍繞行政處分是否合法，民事案件重視侵權成立與損害賠償，刑事案件著重犯罪構成要件，刑事附帶民事案件則兼具刑事事實與民事賠償請求。若混合建模，模型可能主要學到案件類型差異，而非同一案件類型內的裁判結果差異。

在特徵表示設計上，BoW、TF 與 TF-IDF 代表三種不同的文字訊號假設。BoW 假設詞彙是否出現或出現次數本身具有分類價值；TF 假設不同長度裁判書之間需要以相

對詞頻進行校正；TF-IDF 假設相對稀有且集中於特定文本的詞彙更具區辨力。由於智慧財產權判決同時包含法律固定語彙與案件特定技術語彙，三種表示方法皆可能在不同案件類型下取得較佳效果，因此本文以實證結果而非事前偏好決定適用性。

最後，本文採用 Macro F1 作為主要指標，原因在於裁判結果分布高度不均衡。若模型將大多數樣本預測為各案件類型中的多數類別，可能仍取得不低的 Accuracy，但此結果對研究與實務皆缺乏充分意義。Macro F1 可使 Lose、Mixed 與 Win 三類結果在評估中具有相同權重，因此能更敏感地反映少數類別辨識不足的問題。本文同時保留 Accuracy、分類報告與混淆矩陣，以避免單一指標造成過度解讀。

肆、研究結果與分析

一、兩種模型流程之比較

表 6 Chi-square + MNIR + SVM 於各資料集之最佳表現

資料集	MNIR 最佳特徵	K	C	Accuracy	Macro F1
行政	BoW	5000	0.0625	0.875	0.318
民事	TF-IDF	1000	0.125	0.695	0.353
刑事	TF-IDF	5000	0.125	0.928	0.390
刑事附帶民事	TF	1000	0.125	0.823	0.545

表 7 Chi-square + SVM 於各資料集之最佳表現

資料集	Direct 最佳特徵	Accuracy	Macro F1	Majority Macro F1
行政	BoW	0.828	0.392	0.311
民事	TF-IDF	0.680	0.428	0.269
刑事	TF	0.951	0.577	0.322
刑事附帶民事	BoW	0.854	0.654	0.245

表 6 與表 7 顯示，在四類案件資料集中，Chi-square + SVM 的 Macro F1 均高於 Chi-square + MNIR + SVM。此結果表示，在本研究資料、標籤設定、文本前處理與超參數範圍下，MNIR 監督式特徵轉換未帶來額外分類增益。較合理的解讀並非 MNIR 方法本身無效，而是卡方篩選後的稀疏文字特徵已保留相當程度的裁判結果分類訊號；再將其壓縮為低維 MNIR 分數時，可能同時壓縮了部分細部詞彙或少數類別訊號。

表 8 Chi-square + SVM 與 Chi-square + MNIR + SVM 之 Macro F1 比較

資料集	SVM Macro F1	MNIR Macro F1	Direct - MNIR	95% bootstrap CI
行政	0.392	0.318	0.073	[0.044, 0.104]
民事	0.428	0.353	0.075	[0.036, 0.115]
刑事	0.577	0.390	0.187	[0.124, 0.260]
刑事附帶民事	0.654	0.545	0.109	[0.007, 0.246]

表 8 比較兩條流程各自最佳設定下的表現，因此反映的是完整模型流程差異，而非在完全相同特徵與參數設定下，單獨識別 MNIR 轉換的效果。由表 8 可知，Direct - MNIR 之差異皆為正值，且 bootstrap 信賴區間未跨越零。此結果支持本文主要發現：就本研究設定而言，直接使用卡方篩選後稀疏特徵之 SVM，較能保留裁判結果分類所需訊息。

進一步而言，MNIR 的理論優勢在於降低高維文本特徵並產生較緊湊的監督式表示。然而，在本研究流程中，Chi-square 已先依裁判結果與詞彙分布之關聯進行篩選，使輸入 SVM 的特徵空間已具有相當程度的監督訊號。當資料同時存在類別不平衡與少數類別樣本不足時，低維轉換可能使少數類別的細部詞彙差異被平均化，導致 Macro F1 未能提升。

二、不同文字特徵表示之影響

表 9 Chi-square + SVM 下 BoW、TF、TF-IDF 之 Macro F1

資料集	BoW	TF	TF-IDF
行政	0.392	0.341	0.375
民事	0.403	0.417	0.428
刑事	0.564	0.577	0.562
刑事附帶民事	0.654	0.580	0.572

表 9 顯示，BoW、TF 與 TF-IDF 並無單一方法在所有案件類型中皆為最佳。行政案件與刑事附帶民事案件中，BoW 表現相對較佳；民事案件中，TF-IDF 表現較佳；刑事案件中，TF 表現較佳。此結果說明，法律文本分類不宜預設單一文字特徵或模型流程可適用所有案件。若分類訊號主要來自特定法律用語或程序用語是否出現，BoW 可

能較能保留原始詞彙訊號；若裁判書長度差異較大，TF 可能較能降低長文本影響；若特定權利主張或技術爭點詞彙具有區辨力，TF-IDF 則可能較具優勢。

行政案件中 BoW 表現最佳，可能與行政裁判書常出現固定程序語彙有關。行政智慧財產案件多涉及行政處分、訴願、審定或撤銷等程序脈絡，特定詞彙是否出現本身即可能反映爭點與結果方向。此時，保留原始詞彙出現資訊的 BoW 比相對詞頻或稀有詞加權更能捕捉分類訊號。

民事案件中 TF-IDF 表現最佳，可能反映民事智慧財產案件爭點較分散，且特定權利主張、技術內容或損害賠償語彙具有較高區辨力。民事案件文本通常包含請求權基礎、侵權要件、權利範圍與損害計算等內容；相對稀有但與爭點高度相關的詞彙，可能比一般高頻法律用語更能區分裁判結果。

刑事案件中 TF 表現最佳，顯示單篇裁判書內部的相對詞頻可能較能反映犯罪構成要件、證據評價或程序狀態。刑事智慧財產案件數量較多，且 Win 類別占比高，若僅使用原始次數，長文本可能對模型造成影響；TF 將詞彙轉換為相對頻率後，可能較能降低篇幅差異帶來的偏誤。

刑事附帶民事案件中 BoW 表現最佳，但此資料集的 Win 類別樣本極少，故解讀上應更謹慎。此類案件同時包含刑事程序與民事賠償請求，其文本中可能出現較明確的責任與損害語彙。BoW 表現較佳表示原始詞彙訊號具有分類價值，但少數類別樣本不足仍限制模型泛化能力。

三、錯誤分析與少數類別限制

表 10 民事案件最佳 Chi-square + SVM 模型之測試集混淆矩陣

實際\預測	Predicted Lose	Predicted Mixed	Predicted Win
Actual Lose	683	77	6
Actual Mixed	192	80	9
Actual Win	62	17	7

表 11 各資料集最佳 Chi-square + SVM 模型之類別 F1 摘要

資料集	Lose F1	Mixed F1	Win F1	Macro F1
行政	0.907	0.135	0.133	0.392
民事	0.802	0.352	0.130	0.428
刑事	0.591	0.167	0.974	0.577
刑事附帶民事	0.834	0.878	0.250	0.654

表 12 民事案件最佳 Chi-square + SVM 模型之分類報告

類別	Precision	Recall	F1-score	Support
Lose	0.729	0.892	0.802	766
Mixed	0.460	0.285	0.352	281
Win	0.318	0.081	0.130	86
macro avg	0.502	0.419	0.428	1133
weighted avg	0.631	0.680	0.639	1133

表 10 顯示，民事案件中許多 Mixed 與 Win 樣本被誤判為 Lose。表 11 與表 12 進一步顯示，多數類別通常具有較高 F1，但不同案件類型中的少數類別，如行政與刑事的 Mixed、民事的 Win、刑事附帶民事的 Win，表現仍偏弱。此結果說明，模型主要限制並非整體分數不足，而是少數類別辨識能力有限。即使模型整體 Accuracy 與 Macro F1 高於基準模型，也不能解讀為模型已能完整預測所有裁判結果。

上述結果與智慧財產權案件的法律性質相符。部分勝訴類別本身可能包含多種型態，例如部分請求成立、部分損害賠償被支持、部分權利範圍被認定，或不同爭點間出現不同判斷。此類標籤內部異質性較高，模型較難以單一詞彙分布穩定辨識。因此，未來若要提升模型實用性，應優先處理少數類別樣本不足、標籤細緻化與錯誤案例解釋等問題。

從模型評估角度來看，民事案件的 weighted avg F1 高於 macro avg F1，顯示整體表現受到 Lose 類別支撐。若僅呈現 Accuracy 或 weighted avg，容易忽略 Win 類別 recall 僅 0.081 的問題。此結果正是本文採用 Macro F1 與類別層級報告的原因：法律文本分類若要具有研究與實務價值，不能只在多數類別上表現良好，也必須揭露模型對少數但重要結果類別的限制。

伍、結論與建議

一、研究結論

本研究以臺灣智慧財產權判決文本為資料，建立三類裁判結果分類流程，並比較不同案件類型、文字特徵表示與模型流程。主要結論有三。第一，在本研究資料與設定下，Chi-square + SVM 在四類案件資料集中的 Macro F1 均高於 Chi-square + MNIR + SVM，顯示卡方篩選後之稀疏文字特徵已能保留相當程度的裁判結果分類訊息。第二，不同案件類型下適合的文字特徵表示不同；行政與刑事附帶民事案件中 BoW 較佳，民事案件中 TF-IDF 較佳，刑事案件中 TF 較佳。第三，模型雖能在多數類別上形成一定分類能力，但對部分少數類別仍存在明顯限制。

因此，本文認為智慧財產權判決文本中確實存在可供機器學習模型辨識的文字訊號，但模型表現不應僅以整體 Accuracy 判斷。法律文本分類的核心挑戰不只是建立可預測裁判結果的模型，更在於模型是否能均衡辨識不同裁判結果類別，並避免因多數類別主導而高估表現。

二、研究貢獻

理論上，本研究補充法律文本分類與智慧財產權判決結果預測之相關研究，說明案件類型、文本結構與詞彙分布會影響模型表現。方法上，本文建立可重複比較的 baseline pipeline，包含資料清理、斷詞、三種文字特徵、Chi-square 特徵選擇、MNIR 轉換、SVM 分類與多指標評估。實務上，本文可作為大量智慧財產權裁判書初步整理與分類之參考，協助研究者或法律科技系統進行樣本篩選與案件分布掌握。

在理論貢獻方面，本文強調智慧財產權判決分類不能忽略案件類型差異。行政、民事、刑事與刑事附帶民事案件雖同屬智慧財產權領域，但法律程序、文本結構與結果分布皆不同。本文結果顯示，不同案件類型下較適合的文字特徵表示並不一致，說明法律文本模型的表現並非僅由演算法決定，也受到制度脈絡與文本生成方式影響。

在方法貢獻方面，本文提供一套可作為後續研究比較基準的流程。後續若欲導入深度學習、預訓練語言模型、段落級建模或其他監督式降維方法，皆可先與本文 Chi-square + SVM 基準比較，檢驗其是否真正改善 Macro F1 與少數類別辨識，而非僅提升整體 Accuracy。此一基準流程有助於避免方法複雜度被誤認為研究貢獻。

在實務貢獻方面，本文可協助法律科技應用釐清模型定位。模型適合用於大量裁判書初步分類、研究樣本整理、案件分布探索與後續人工審查輔助；但不宜直接用於個案法律意見或勝敗判斷。此一界定有助於在利用文字探勘提升研究效率的同時，避免對模型輸出作過度解讀。

不過，本研究建立的是裁判結果分類之研究流程與方法基礎，而非可直接取代法律專業判斷的自動化決策工具。智慧財產權案件涉及技術事實、權利範圍、法律要件與法院裁量判斷，因此模型分類結果仍應搭配人工審查與個案脈絡分析。

表 13 不同案件類型下可優先考慮之文字特徵與模型流程

使用情境	建議方法	理由
行政案件分類	BoW + Chi-square + SVM	行政案件中 BoW 的 Macro F1 表現最高，可能較能保留程序用語與裁判結果差異。
民事案件分類	TF-IDF + Chi-square + SVM	民事案件中 TF-IDF 表現最高，可能較能強化具區辨力之權利主張與法律爭點詞彙。
刑事案件分類	TF + Chi-square + SVM	刑事案件中 TF 表現最高，表示單篇裁判書中的相對詞頻可能較具分類效果。
刑事附帶民事案件分類	BoW + Chi-square + SVM	刑事附帶民事案件中 BoW 表現最高，原始詞彙出現資訊已包含較明確分類訊號。

三、研究限制與後續建議

本研究仍有若干限制。第一，雖已移除明顯裁判結果詞彙，但仍無法完全排除文本中的間接結果線索。第二，資料存在類別不平衡，部分案件類型中的少數類別樣本數相對較少，使模型容易偏向該案件類型中的多數類別。第三，Mixed 類別內部異質性高，可能包含多種法律與事實型態。第四，本文主要以裁判書全文作為模型輸入，尚未完整分離案件事實、當事人主張、法院理由與主文。第五，BoW、TF 與 TF-IDF 雖具可解釋性與計算效率，但較難捕捉長距離語意與法理推論結構。第六，MNIR 結果應限縮於本文資料、標籤設定與超參數範圍，不宜推論為所有法律文本分類任務皆不適用。

此外，本研究採單次固定訓練、驗證與測試集劃分；表 8 之 paired bootstrap 主要衡量固定測試集下兩模型差異的抽樣不確定性，不能取代重複隨機劃分或交叉驗證，因此模型表現仍可能受到特定資料切分影響。後續研究若要提高結論穩定性，應加入重複隨機劃分、交叉驗證、bootstrap 重抽樣或不同年度區間之外部測試。

後續研究可朝三個方向發展。第一，強化模型可解釋性，進一步檢視高卡方詞彙、SVM 權重、MNIR loading 與錯誤案例，以確認模型是否捕捉法律爭點、請求類型或裁判理由，而非僅學習表面詞彙關聯。第二，改善少數類別辨識，可導入類別權重、過度抽樣、欠抽樣或更細緻的標籤設計，並以 Macro F1、各類別 F1-score 與混淆矩陣檢驗是否真正改善 Mixed 與 Win 類別表現。第三，進一步區分裁判書段落，檢驗模型究竟依賴事實、理由或主文附近文字。

在資料建構方面，後續研究亦可進一步區分裁判書段落。若能將主文、事實及理由、當事人主張與法院判斷分開建模，即可更精確回答模型究竟依賴何種文本資訊。

舉例而言，僅使用事實段落可較接近事前風險評估情境；使用法院理由則可分析裁判理由中與結果相關的語彙結構；比較不同段落的模型表現，亦有助於判斷模型是否過度依賴結果附近文字。此一方向可降低資料洩漏疑慮，並提升法律解釋上的可讀性。

在模型應用方面，本文建議將分類結果定位為研究輔助，而非個案法律判斷。模型可協助研究者從大量裁判書中快速掌握案件分布、初步篩選可能具有特定結果特徵的案件，或作為後續人工編碼的前置工具。然而，智慧財產權案件的勝敗常取決於技術事實、權利範圍、證據品質與法院對具體爭點的判斷。文字分類模型即使能捕捉統計關聯，也不等同於理解個案法律理由。因此，任何實務使用皆應保留人工審查與專業判斷。

整體而言，本研究證實臺灣智慧財產權判決文本中存在可供機器學習模型辨識的文字訊號，也顯示傳統文字特徵結合 SVM 可作為具參考價值的基準流程。未來若能進一步強化少數類別辨識、模型可解釋性與結果穩定性，將有助於使文字探勘方法更穩健地應用於法律研究與法律科技場域。

陸、參考文獻

- 法務部全國法規資料庫。2023。智慧財產及商業法院組織法。
<https://law.moj.gov.tw/LawClass/LawAll.aspx?pcode=A0010090>。
- 司法院。2026。行政訴訟。司法院全球資訊網。<https://www.judicial.gov.tw/tw/np-85-1.html>。
- 林常青。2019。臺灣法律經濟學實證的判決資料 - 介紹與應用。經濟論文，47 (4) : 533-546。
- 張添榜、王立達與劉尚志。2013。我國專利法上均等論適用之實證研究：是變奏還是變調？科技法學評論，10 (2) : 1-71。
- 陳秉訓。2021。從共同侵權行為理論分析方法請求項之複數執行者問題。專利師，47 : 1-11。
- 郭建中、陳羿愷。2020。從數據一探智慧財產法院運作實況：專題三，民事訴訟。Winkler Partners。
- Aletras, N., Tsarapatsanis, D., Preotiuc-Pietro, D., & Lampos, V. 2016. Predicting judicial decisions of the European Court of Human Rights: A natural language processing perspective. *PeerJ Computer Science*, 2: e93.
- Alghazzawi, D., Bamasag, O., Albeshri, A., Sana, I., Ullah, H., & Asghar, M. Z. 2022. Efficient prediction of court judgments using an LSTM+CNN neural network model with an optimal feature set. *Mathematics*, 10(5): 683.
- Ariai, F., Mackenzie, J., & Demartini, G. 2025. Natural language processing for the legal domain: A survey of tasks, datasets, models, and challenges. *ACM Computing Surveys*, 58(6): 163.

- Chalkidis, I., Androutsopoulos, I., & Aletras, N. 2019. Neural legal judgment prediction in English. *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*: 4317-4323.
- Chen, K.-P., Huang, K.-C., & Lin, C.-C. 2015. Party capability versus court preference: Why do the haves come out ahead? *Journal of Law, Economics, and Organization*, 31(1): 93-126.
- Eren, O., & Mocan, N. 2018. Emotional judges and unlucky juveniles. *American Economic Journal: Applied Economics*, 10(3): 171-205.
- Feng, Y., Li, C., & Ng, V. 2022. Legal judgment prediction: A survey of the state of the art. *Proceedings of IJCAI*: 5461-5469.
- Heyes, A., & Saberian, S. 2019. Temperature and decisions: Evidence from 207,000 court cases. *American Economic Journal: Applied Economics*, 11(2): 238-265.
- Hsieh, D., Chen, L., & Sun, T. 2021. Legal judgment prediction based on machine learning: Predicting the discretionary damages of mental suffering in fatal car accident cases. *Applied Sciences*, 11(21): 10361.
- Mamakas, D., Tsotsi, P., Androutsopoulos, I., & Chalkidis, I. 2022. Processing long legal documents with pre-trained transformers: Modding LegalBERT and Longformer. *Proceedings of the Natural Legal Language Processing Workshop*: 130-142.
- Manning, C. D., Raghavan, P., & Schütze, H. 2009. *Introduction to information retrieval*. Cambridge University Press.
- Surdeanu, M., Nallapati, R., Gregory, G., Walker, J., & Manning, C. D. 2011. Risk analysis for intellectual property litigation. *Proceedings of ICAIL*: 116-120.
- Taddy, M. 2013. Multinomial inverse regression for text analysis. *Journal of the American Statistical Association*, 108(503): 755-770.
- Yang, S., Tong, S., Zhu, G., Cao, J., Wang, Y., Xue, Z., Sun, H., & Wen, Y. 2022. MVE-FLK: A multi-task legal judgment prediction via multi-view encoder fusing legal keywords. *Knowledge-Based Systems*, 239: 107960.