

國立東華大學財務金融學系
碩士論文

判決文本會說話嗎？
臺灣智慧財產權裁判結果之文字探勘與
分類研究

*Do Court Judgments Speak? Text Mining and Classification of
Intellectual Property Judgment Outcomes in Taiwan*



研究生：陳信全
指導教授：侯介澤 博士
共同指導教授：林金龍 博士

中華民國 115 年 6 月

摘要

隨著司法資料公開與法律科技 (Legal Technology, LegalTech) 發展, 判決文本分析已成為實證法律研究的重要議題。如何從大量裁判書中擷取有效資訊, 並分析裁判結果, 是法律文字探勘 (Text Mining) 的重要任務。智慧財產權判決具有法律術語密集、案件類型差異明顯、文本結構複雜與裁判結果分布不均衡等特性。因此, 智慧財產權判決適合作為文字探勘與機器學習 (Machine Learning) 分類任務之研究對象。

本研究以臺灣智慧財產權相關裁判書為資料來源。本文將裁判結果整理為敗訴 (Lose)、部分勝訴 (Mixed) 與勝訴 (Win) 三類。並依案件類型區分為行政、民事、刑事與刑事附帶民事案件。各案件類型分別建立模型, 以比較其分類表現。在研究方法上, 本文首先進行案件篩選、文本清理、停用詞移除與中文斷詞。接著建立三種文字特徵表示, 包括詞袋模型 (Bag-of-Words, BoW)、詞頻表示 (Term Frequency, TF) 與詞頻—逆文件頻率 (Term Frequency-Inverse Document Frequency, TF-IDF)。本文再透過卡方特徵選擇 (Chi-square feature selection, Chi-square), 篩選與裁判結果較具關聯的詞彙特徵。模型流程方面, 本文比較兩種方法。第一種為 Chi-square + 多項式逆迴歸 (Multinomial Inverse Regression, MNIR) + 支持向量機 (Support Vector Machine, SVM)。第二種為 Chi-square + Direct SVM。前者用以檢驗 MNIR 監督式特徵轉換是否能改善高維法律文本分類。後者則作為不經 MNIR 轉換的對照流程。

實證結果顯示, 在本研究資料、標籤設定與超參數範圍下, Chi-square + Direct SVM 在四類案件資料集中的宏平均 F1 分數 (Macro F1) 皆高於 Chi-square + MNIR + SVM。此結果表示, MNIR 監督式特徵轉換未取得額外分類增益。不過, 這並不代表 MNIR 方法本身無效。較合理的解讀是, 在本研究任務中, 卡方篩選後的稀疏文字特徵已保留相當程度的分類訊息。此外, 不同案件類型下較適合的文字特徵表示並不相同。行政案件與刑事附帶民事案件中, BoW 表現相對較佳。民事案件中, TF-IDF 表現相對較佳。刑事案件中, TF 表現相對較佳。此結果說明, 法律文本分類不宜預設單一文字特徵或模型流程必然最佳。模型選擇應依案件類型、文本結構與詞彙分布而定。

進一步錯誤分析顯示, 模型的主要限制並非整體分數不足, 而是少數類別辨識能力有限。以民事案件為例, 模型對 Lose 類別具有較佳辨識能力。然而, 對 Mixed 與 Win 類別的表現明顯較弱。許多 Mixed 與 Win 樣本被誤判為 Lose。此結果反映智慧財產權判決分類受到類別不平衡影響。若僅觀察準確率 (Accuracy), 可能高估模型實際分類能力。因此, 本文以 Macro F1、分類報告與混淆矩陣輔助分析, 以檢視模型對不同裁判結果類別的辨識能力。

綜合而言, 本研究建立臺灣智慧財產權判決文本之三類裁判結果分類流程。本文透過不同案件類型、文字特徵表示與模型流程之比較, 說明傳統稀疏文字模型在法律文本分類中的

基準價值。同時，本文也指出少數類別辨識仍是智慧財產權判決分類中的重要限制。研究結果可作為後續法律文本分類、法律科技應用與實證法律研究之方法參考。



Abstract

With the development of open judicial data and legal technology, court judgment text analysis has become an important issue in empirical legal studies. Extracting useful information from large-scale judgments and analyzing outcomes are central tasks in legal text mining. Intellectual property judgments contain dense legal terminology, involve different case types, have complex textual structures, and show imbalanced judgment outcomes. These characteristics make them suitable for text mining and machine learning classification.

This study uses Taiwanese intellectual property court judgments as research data. Judgment outcomes are classified into three categories: Lose, Mixed, and Win. The data are further divided into four case types: administrative, civil, criminal, and criminal cases with attached civil actions. In terms of methodology, this study conducts case filtering, text cleaning, stop-word removal, and Chinese word segmentation. Three text feature representations are constructed: Bag-of-Words, Term Frequency, and Term Frequency-Inverse Document Frequency. Chi-square feature selection is then applied to select features more strongly associated with judgment outcomes.

This study compares two model pipelines: Chi-square + Multinomial Inverse Regression + Support Vector Machine, and Chi-square + Direct SVM. The former examines whether supervised MNIR feature transformation can improve high-dimensional legal text classification. The latter serves as a comparison pipeline without MNIR transformation. The empirical results show that Chi-square + Direct SVM achieves higher Macro F1 scores than Chi-square + MNIR + SVM across all four case-type datasets. This indicates that MNIR feature transformation does not provide additional classification gains in this research setting. However, this does not imply that MNIR is ineffective in general. A more cautious interpretation is that sparse text features selected by Chi-square already preserve considerable classification information. The most suitable text feature representation also differs across case types. BoW performs relatively better in administrative cases and criminal cases with attached civil actions. TF-IDF performs better in civil cases, while TF performs better in criminal cases. These findings suggest that legal text classification should consider case type, textual structure, and word distribution, rather than assuming one universally optimal feature representation or model pipeline.

Further error analysis shows that the main limitation of the models is insufficient recognition of minority classes. Taking civil cases as an example, the model performs relatively well in identifying Lose cases, but poorly in identifying Mixed and Win cases. Many Mixed and Win samples are

misclassified as Lose. This result reflects the influence of class imbalance in intellectual property judgment classification. If only Accuracy is considered, model performance may be overestimated. Therefore, this study uses Macro F1, classification reports, and confusion matrices to examine the model's ability to distinguish different judgment outcome classes.

Overall, this study establishes a three-class classification framework for Taiwanese intellectual property judgments. By comparing case types, text feature representations, and model pipelines, it demonstrates the baseline value of traditional sparse text models and highlights the difficulty of recognizing minority judgment outcomes. The findings may serve as a methodological reference for future legal text classification, legal technology applications, and empirical legal studies.



目錄

摘要.....	2
Abstract.....	4
表目錄.....	9
圖目錄.....	10
第一章 緒論.....	11
1.1 研究背景與動機.....	11
1.2 研究目的.....	13
1.3 研究問題.....	14
1.4 研究流程與架構.....	14
第二章 文獻回顧.....	15
2.1 前言.....	15
2.2 實證法律研究與量化分析的發展.....	15
2.3 法律文本之特徵表示：BoW、TF 與 TF-IDF.....	16
2.4 預測模型建構與可解釋性之必要性.....	17
2.5 MNIR 監督式特徵轉換與本研究定位.....	18
2.6 總結與研究缺口.....	19
第三章 研究方法與資料.....	21
3.1 研究流程.....	21
3.2 資料獲取與前處理.....	22
3.3 智慧財產權案件篩選與文本前處理.....	22
3.4 樣本篩選、標籤整理與樣本分布.....	23
3.4.1 案件類型之法律性質.....	23
3.4.2 樣本篩選與標籤整理.....	25
3.4.3 樣本分布.....	25
3.5 文字特徵建構.....	28
3.5.1 詞袋模型.....	28
3.5.2 詞頻表示.....	29
3.5.3 詞頻－逆文件頻率.....	30

3.7 MNIR 監督式特徵轉換	33
3.7.1 MNIR 之模型設定與 inverse regression	33
3.7.2 Gamma-Lasso 估計法與正則化	35
3.7.3 充分縮減分數與降維邏輯.....	35
3.8 模型流程設計.....	37
3.8.1 SVM 分類器設定	37
3.8.2 Chi-square + MNIR + SVM 流程	38
3.8.3 Chi-square + Direct SVM 對照流程	39
3.8.4 Majority Class baseline.....	39
3.8.5 模型評估方式.....	40
3.8.6 本研究各方法之功能與流程比較.....	42
3.9 資料切分與參數選擇.....	44
3.10 小結.....	45
第四章 研究結果與分析.....	47
4.1 實驗設定與評估邏輯.....	47
4.2 MNIR + SVM 核心流程之模型表現	48
4.3 Direct SVM 對照流程之模型表現	48
4.4 MNIR + SVM 與 Direct SVM 之整體流程比較.....	49
4.5 不同文字特徵表示之影響.....	52
4.6 參數選擇與驗證集表現.....	53
4.7 錯誤分析與少數類別限制.....	55
4.8 小結.....	58
第五章 結論與建議.....	60
5.1 研究結論.....	60
5.2 研究貢獻.....	61
5.3 研究限制.....	62
5.4 研究結果之建議.....	64
5.4.1 對模型與特徵表示選擇之建議.....	65
5.4.2 對不同資料情境之模型選擇建議.....	65
5.4.3 對後續研究與實務應用之建議.....	66

5.5 總結.....	68
參考文獻.....	69



表目錄

表 3-1 原始資料欄位說明	22
表 3-2 案件類型之法律性質與例示	25
表 3-3 案件類型與裁判結果分布	26
表 3-4 年度區間與案件類型分布	27
表 3-5 年度區間與裁判結果比例	28
表 3-6 TP、FP、FN、TN 判斷示意表	41
表 3-7 本研究各方法之功能與流程比較	43
表 4-1 Chi-square + MNIR + SVM 於各資料集之最佳表現	48
表 4-2 Chi-square + Direct SVM 於各資料集之最佳表現	49
表 4-3 Direct SVM 與 MNIR + SVM 之 Macro F1 比較	50
表 4-4 Direct SVM 下 BoW、TF、TF-IDF 之 Macro F1	52
表 4-5 各資料集最佳 Direct SVM 模型之參數選擇摘要	54
表 4-6 民事案件最佳 Direct SVM 模型之測試集混淆矩陣	55
表 4-7 民事案件最佳 Direct SVM 模型之分類報告	56
表 4-8 各資料集最佳 Direct SVM 模型之類別 F1 摘要	57
表 5-1 不同案件類型下可優先考慮之文字特徵與模型流程	66

圖目錄

圖 4-1 Direct SVM 與 MNIR + SVM 之 Macro F1 比較.....	50
圖 4-2 不同文字特徵表示之 Macro F1 比較.....	52
圖 4-3 Direct SVM 之 $K \times C$ 驗證集 Macro F1 熱力圖	54



第一章 緒論

1.1 研究背景與動機

近年來，大數據（Big Data）與人工智慧（Artificial Intelligence）的發展，使法律研究逐漸從傳統法規範解釋與個案分析，延伸至以資料為基礎的實證研究。傳統法學研究多側重於法規範的內在邏輯與解釋，亦即所謂「書本上的法律」（Law in Books）；然而，隨著法律經濟學、社會科學方法與資料科學工具的導入，研究者也開始關注法律在實際案件中的運作方式，亦即「行動中的法律」（Law in Action）。在此脈絡下，實證法律研究（Empirical Legal Studies, ELS）逐漸成為觀察法院裁判、司法行為與訴訟結果的重要方法。

臺灣司法體系在資料透明與開放方面具備制度性優勢。林常青（2019）指出，司法院公開之裁判書查詢系統提供大量完整判決全文資料，屬於高度資訊密集之非結構化文本資料。該資料庫涵蓋案件事實、當事人主張、法律適用與裁判理由等核心內容，且可供研究者取得與分析，為法律實證研究與法律文本分析奠定重要基礎。然而，裁判書文本具有篇幅長、術語密度高、格式複雜與法律推論脈絡明顯等特徵，如何將此類非結構化文本轉換為可供模型辨識之特徵，仍是法律科技（Legal Technology, LegalTech）與法律文本分析中的重要問題。

智慧財產權案件尤其具有高度專業性與技術性。張添榜等人（2013）指出，在智慧財產權案件中，判決預測的挑戰往往來自法律解釋與事實認定兩個層面。以專利侵權判斷為例，法院常需處理文義侵害與均等論（Doctrine of Equivalents）等問題。均等論雖可作為專利權保護的重要機制，但因其涉及專利權範圍是否擴張至請求項文字之外，容易與專利制度所重視之公示作用產生緊張關係，使法院判斷具有高度解釋空間。此類案件中，單純依靠少數關鍵字往往難以完整呈現法院判斷的依據。

此外，在新興技術領域中，事實認定的複雜度亦進一步提高。以智慧財產法院 108 年民專訴字第 59 號民事判決為例，該案涉及行動支付方法與複數執行者問題。當專利方法步驟分別由商店端、消費者端與銀行伺服器端共同完成時，法院須進一步判斷不同行為主體之行為與損害結果之間是否具有相當因果關係（陳秉訓，2021）。此類案件顯示，智慧財產權判決文本不僅包含法律規範，也包含技術事實、權利範圍、行為主體與因果關係等多層次資訊，因此適合作為法律文本探勘與裁判結果分類之研究對象。

另一方面，智慧財產權案件亦存在明顯的裁判結果不均衡問題。郭建中、陳羿愷（2020）整理智慧財產法院相關實務數據後指出，專利權人於部分年度之勝訴率偏低，顯示智慧財產權民事訴訟中不同裁判結果之分布並非均衡。此一現象對機器學習（Machine Learning）模型具有重要影響：若模型僅追求整體準確率（Accuracy），便可能因大量預測多數類別而取得表

面上較高的分數，卻無法有效辨識勝訴或部分勝訴等少數類別。因此，在智慧財產權判決分類任務中，研究者不僅需要建立模型，也必須檢視模型是否受到類別不平衡影響，並進一步分析其對不同裁判結果類別之辨識能力。

基於上述背景，本研究以臺灣智慧財產權相關判決為研究對象，運用文字探勘（Text Mining）與機器學習方法建立裁判結果分類流程。本研究並不將重點放在單純追求最高準確率，而是進一步比較不同案件類型、不同文字特徵表示與不同模型流程之分類表現。具體而言，本研究將裁判結果整理為敗訴、部分勝訴與勝訴三類，並依案件類型區分為行政、民事、刑事與刑事附帶民事案件；在方法上，則比較 卡方特徵選擇（Chi-square feature selection, Chi-square） + 多項式逆迴歸（Multinomial Inverse Regression, MNIR） + 支持向量機（Support Vector Machine, SVM）與 卡方特徵選擇 + 支持向量機 兩種流程，以檢驗 MNIR 監督式特徵轉換是否能在高維法律文本分類任務中帶來額外增益，並同時評估傳統稀疏文字特徵模型之基準價值。



1.2 研究目的

隨著司法資料公開與法律科技發展，如何從大量判決文本中擷取有用資訊，並據以分析裁判結果，已成為法律文本分析的重要議題。既有法律判決預測研究顯示，案件事實、法律文本與法院理由中，可能包含可供模型辨識的文字訊號。

然而，智慧財產權判決具有若干特性。第一，法律術語密集。第二，案件類型差異明顯。第三，裁判結果分布不均衡。第四，文本中可能存在明顯裁判結果詞彙。上述特性使模型在分類裁判結果時，容易受到高維文字特徵、類別不平衡與資料洩漏問題影響。

基於此，本研究以臺灣智慧財產權相關判決為研究對象，運用文字探勘與機器學習方法建立裁判結果分類流程。本文將裁判結果整理為敗訴、部分勝訴與勝訴三類，並依案件類型區分為行政、民事、刑事與刑事附帶民事案件，以檢驗不同案件類型下模型對裁判結果的辨識能力。

在文字特徵表示方面，本文比較 BoW、TF、TF-IDF 三種方法

在模型流程方面，本文比較兩種方法：

1. Chi-square + MNIR + SVM
2. Chi-square + Direct SVM

前者用以檢驗 MNIR 監督式特徵轉換是否能改善高維法律文本分類。後者則作為不經 MNIR 轉換之對照流程。

本研究之具體目的如下：

第一、建立臺灣智慧財產權判決文本分類流程。本文整理資料篩選、裁判結果標籤、文字特徵建構與模型訓練程序，作為法律文本分類分析之基礎。

第二、比較不同文字特徵表示之分類效果。本文透過 Chi-square 特徵選擇，篩選與裁判結果較具關聯之文字特徵，並比較 BoW、TF 與 TF-IDF 在不同案件類型下的表現。

第三、檢驗 MNIR 監督式特徵轉換之適用性。本文比較 Chi-square + MNIR + SVM 與 Chi-square + Direct SVM，以觀察 MNIR 是否能在智慧財產權判決分類中帶來額外分類增益。

第四、分析模型對不同裁判結果類別的辨識能力。本文針對敗訴、部分勝訴與勝訴三類結果，檢視模型是否能有效辨識少數類別，並分析類別不平衡對分類表現的影響。

第五、建立較完整的模型評估方式。本文採用 Macro F1、Accuracy、Majority Class baseline、分類報告與混淆矩陣，評估模型整體表現與錯誤分類型態，避免僅以準確率判斷

模型是否有效。

綜上所述，本研究不僅希望檢驗文字探勘方法應用於智慧財產權判決分類之可行性，也希望釐清不同案件類型、文字特徵表示與模型流程對分類結果之影響。

透過上述設計，本文可比較 BoW、TF 與 TF-IDF 之分類效果，檢驗 MNIR 在卡方特徵選擇後是否帶來額外增益，並分析模型在敗訴、部分勝訴與勝訴三類結果上的辨識能力與限制。基於上述研究目的，本文於下一節提出具體研究問題。

1.3 研究問題

本研究檢驗不同文字特徵表示、模型流程與案件類型對分類表現之影響。基於上述研究目的，本文提出以下研究問題：

RQ1：不同文字特徵表示方式（BoW、TF、TF-IDF）在智慧財產權判決結果分類中的表現是否存在差異？

RQ2：在卡方特徵選擇後，MNIR 監督式特徵轉換是否能相較於 Direct SVM 提升分類表現？

RQ3：不同案件類型下，較適合的文字特徵表示與模型流程是否有所不同？

RQ4：在裁判結果類別不平衡的情況下，模型是否能有效辨識敗訴、部分勝訴與勝訴三類結果？

1.4 研究流程與架構

本研究共分為五章。第一章說明研究背景、動機與研究目的；第二章回顧實證法律研究（Empirical Legal Studies, ELS）、法律文本特徵表示、判決預測模型與 MNIR 相關文獻；第三章說明資料來源、資料處理、特徵建構、模型流程與評估指標；第四章呈現模型實驗結果，並比較 MNIR + SVM 與 Direct SVM 兩種流程之表現；第五章則整理研究結論、研究貢獻、研究限制與後續研究建議。

第二章 文獻回顧

2.1 前言

隨著司法判決資料逐漸公開，法律文本開始成為實證研究的重要資料來源。過去法律研究多以法規範解釋、個案分析與法理推演為主。近年來，研究者則逐漸嘗試運用自然語言處理（Natural Language Processing, NLP）、文字探勘（Text Mining）與機器學習方法，分析大量非結構化判決文本（Ariai et al., 2025）。

在此脈絡下，法律判決不再只是個案閱讀的對象，也可以被轉換為可量化的文字資料。透過文字特徵建構與分類模型，研究者得以檢驗判決文本中是否存在可供模型辨識的分類訊號。例如，特定法律爭點、案件事實、請求類型或裁判理由用語，可能與案件類型或裁判結果具有關聯。

然而，法律判決文本不同於一般新聞、社群媒體或消費評論。判決書通常包含案件事實、當事人主張、法院理由、法律構成要件與裁判結果等資訊。此類文本篇幅較長，術語密度較高，且同一法律概念可能以不同方式表述。因此，如何將法律文本轉換為適合模型處理的特徵，並同時維持一定的可解釋性，是法律文本分類與判決預測研究的重要問題。

本章將依序回顧實證法律研究與法律文本分析的發展，說明 BoW、TF 與 TF-IDF 等傳統文字特徵表示在法律文本分類中的角色，接著討論機器學習模型與模型可解釋性之必要性，最後說明本研究在臺灣智慧財產權判決文本脈絡下，採用三類裁判結果分類、MNIR 監督式特徵轉換與 Direct SVM 對照流程之研究定位。

2.2 實證法律研究與量化分析的發展

實證法律研究（Empirical Legal Studies, ELS）強調以資料觀察法律制度的實際運作，並透過統計分析或量化方法檢視法院判決、法官行為與訴訟結果之間的關係。相較於傳統法學研究多著重於法規範內部邏輯與法理推演，實證法律研究更關注法律如何在實際案件中被操作與適用。

在國外研究中，已有文獻運用大量法院資料分析司法決策。例如 Eren and Mocan (2018) 探討外部事件是否影響法官量刑，Heyes and Saberian (2019) 則研究環境溫度與法院判決之間的關聯。這類研究顯示，法院判決可被視為可觀察、可量化並可進一步分析的實證資料，而不僅是單純的法理文本。

在臺灣脈絡下，司法資料公開亦為法律實證研究提供重要基礎。林常青 (2019) 指出，

司法院裁判書查詢系統提供大量完整判決資料，使研究者能夠從判決全文、案件類型、裁判結果等面向進行實證分析。Chen et al. (2015) 透過最高法院民事案件資料分析訴訟資源與裁判結果之關係，Chang et al. (2018) 則檢驗法院賠償金額判斷中的定錨效果。這些文獻不僅證明臺灣司法資料庫具備量化研究價值，也確立了將非結構化判決文本轉化為可計算特徵的正當性。

然而，智慧財產權判決文本具有更高的專業性與技術性。智慧財產權案件常涉及專利範圍解釋、侵權認定、商標混淆、著作權利用、營業秘密與損害賠償等問題。此類案件中的裁判結果往往不只受到單一事實影響，而是涉及當事人主張、技術內容、權利範圍、法律要件與法院理由之綜合判斷。因此，若要以文字探勘方法預測智慧財產權判決結果，除了需要處理大量文本資料，也必須面對法律術語密集、文本結構複雜與裁判結果類別不平衡等問題。

2.3 法律文本之特徵表示：BoW、TF 與 TF-IDF

在文字探勘與文本分類任務中，第一個關鍵步驟是將非結構化文本轉換為模型可處理的數值特徵。傳統文本分類常用的方式包括詞袋模型 (Bag-of-Words, BoW)、詞頻表示 (Term Frequency, TF) 與詞頻—逆文件頻率 (Term Frequency–Inverse Document Frequency, TF-IDF)。這些方法雖然不直接處理詞序與深層語意，但在許多專業文本分類任務中仍具備良好的基準價值。

法律裁判書具備篇幅冗長且充滿專業術語之特性，傳統上常被認為需要較複雜的語意模型來處理。然而，近年實證研究指出，在特定專業領域，例如金融與法律等具備高度編碼化語意之文本中，傳統詞袋模型在部分語意任務上仍可能具有競爭力，甚至在特定條件下超越部分密集語意嵌入模型 (Mamakas et al., 2022; Tang & Yang, 2025)。此一發現表示，對高度制度化與專業化文本而言，詞彙本身的出現與分布仍可能包含重要分類訊號。

BoW 將每一篇文件視為詞彙集合，並以詞項是否出現或出現次數作為特徵。其優點是模型結構簡單、計算效率高，且容易觀察哪些詞彙對分類結果具有貢獻。對法律判決而言，許多詞彙本身即具有高度制度性與語境意義，例如「侵害」、「損害賠償」、「混淆誤認」、「專利範圍」、「權利範圍」、「商標近似」、「著作利用」等詞彙，可能與特定案件類型、法律爭點或裁判理由具有關聯。因此，即使 BoW 忽略詞序，其仍可能捕捉法律文本中具判別力的詞彙訊號。

TF 則進一步考量詞彙在單一文本中的出現頻率。由於裁判書篇幅差異可能很大，單純使用原始詞頻可能使長文本產生較高詞彙計數，因此透過詞頻正規化，可降低文本長度差異對模型的影響。對於長篇裁判書而言，TF 有助於比較不同文件中詞彙相對使用程度，而非僅觀

察詞彙出現次數。

TF-IDF 則同時考量詞彙在個別文件中的出現頻率，以及該詞彙在整體語料中的稀有程度。若某一詞彙在某篇判決中頻繁出現，但在整體語料中並不常見，TF-IDF 會給予較高權重。此方法可降低一般高頻詞彙的影響，並強化較具區辨力的專門詞彙。對智慧財產權判決而言，某些涉及特定權利主張、請求類型或技術爭點的詞彙，可能不一定在所有判決中頻繁出現，但對特定裁判結果具有判別意義，因此 TF-IDF 可能有助於強化此類訊號。

本研究因此不預設單一特徵表示必然最佳，而是比較 BoW、TF 與 TF-IDF 三種文字特徵表示在不同案件類型下的分類效果。此一設計可檢視不同智慧財產權案件中，裁判結果分類較依賴詞項是否出現、詞頻分布，或相對稀有詞彙之權重。

2.4 預測模型建構與可解釋性之必要性

法律判決預測 (Legal Judgment Prediction, LJP) 是法律人工智慧中的重要任務，其核心目標是利用案件事實、法律文本、法院理由或其他案件資訊，預測法院可能作成之裁判結果。既有研究顯示，法律文本中確實存在可供模型辨識之訊號。例如 Aletras et al. (2016) 以歐洲人權法院案件文本預測是否違反公約條文，Surdeanu et al. (2011) 則針對智慧財產權訴訟進行訴訟風險分析。這些研究說明，機器學習方法可被應用於法律裁判結果或訴訟風險之預測。

不過，法律判決預測並不限於二元分類。Feng et al. (2022) 指出，法律判決預測包含多種任務形式，例如法條預測、罪名預測、刑期預測、裁判結果預測、多標籤分類與多任務學習。Yang et al. (2022) 亦將法律判決預測視為多任務學習問題，嘗試整合法律關鍵詞與多視角特徵進行預測。Chalkidis et al. (2019) 則在英文法律判決預測研究中，同時處理二元分類、多標籤分類與案件重要性預測。換言之，法律判決預測文獻中確有二元分類設定，但整體研究範圍並不限於二元分類。

在司法應用場域中，模型可解釋性具有高度重要性。若模型僅能提供預測結果，卻無法說明其依據，則其在法律實務中的使用將受到限制。法律判決牽涉當事人權益、法院理由與制度正當性，因此模型不應只是追求較高 Accuracy，而應進一步說明模型是否真正捕捉到與法律爭點、請求類型或裁判理由相關的訊號。

在法律人工智慧的實務應用中，大型語言模型與深層神經網路雖然在部分任務上具有良好表現，但其黑箱特性與可能產生幻覺的風險，使其在嚴謹司法場域仍面臨信任與解釋問題。相對地，傳統機器學習與整合學習方法在維持一定準確率的同時，較容易透過特徵重要性或詞彙權重提供解釋。Hsieh et al. (2021) 即運用隨機森林結合排列特徵重要性，預測車禍案件精神慰撫金，並分析法官審酌因素。Alghazzawi et al. (2022) 則指出，基礎深度學習模型在

司法資料上可取得較高準確率與 F1 分數，但黑箱性仍限制其在判決理由透明化上的應用。

相較於大型語言模型或深度神經網路，傳統機器學習模型與稀疏文字特徵雖然在語意理解能力上可能較有限，但其具有計算效率高、模型結構清楚、特徵權重較容易分析等優點。支持向量機（Support Vector Machine, SVM）即為常見的文本分類方法之一，尤其在高維稀疏文字特徵中具有良好表現。若搭配卡方特徵選擇，SVM 可先保留與裁判結果關聯較高的詞彙，再進行分類，形成可作為基準模型的傳統文字分類流程。

基於上述考量，本研究以 SVM 作為主要下游分類器，並比較 Direct SVM 與 MNIR + SVM 兩種流程。前者直接使用卡方篩選後的稀疏文字特徵進行分類，後者則先透過 MNIR 將高維文本轉換為低維監督式特徵，再進行分類。此一設計可同時檢驗傳統稀疏文字模型之基準表現，以及 MNIR 監督式特徵轉換是否能帶來額外增益。

2.5 MNIR 監督式特徵轉換與本研究定位

高維文本資料常面臨維度過高、詞彙稀疏與雜訊過多等問題。若直接將所有詞彙特徵輸入模型，可能造成運算成本增加、模型過度擬合，或使真正具有分類訊號的詞彙被大量無關詞彙稀釋。因此，特徵選擇與特徵轉換是法律文本分類中重要的方法問題。

卡方特徵選擇（Chi-square feature selection）是一種常見的監督式特徵篩選方法，其核心概念是檢驗詞彙出現與類別標籤之間是否具有統計關聯。若某一詞彙在不同類別中的出現分布差異越明顯，代表該詞彙越可能對分類具有判別力。透過卡方統計量，本研究可從高維詞彙矩陣中篩選出與裁判結果較相關的詞彙，降低模型輸入維度並減少雜訊。

MNIR 則是一種監督式特徵轉換方法，其主要目的在於將高維文字資料轉換為與目標變數相關的低維表徵。Taddy（2013）提出的 MNIR 架構，透過反向建模思維，分析給定目標變數條件下的文本生成分布，進而將高維文字資料轉換為充分縮減分數（Sufficient Reduction Scores, SR Scores）。與一般無監督式降維方法不同，MNIR 的重點不只是壓縮文本，而是透過標籤資訊萃取與分類目標相關的文本方向。理論上，若 MNIR 能有效捕捉裁判結果與詞彙分布之間的關係，則其產生的低維特徵可作為下游分類模型的有效輸入。

更直觀地說，MNIR 可理解為「用裁判結果反推詞彙方向，再將原本高維的文字特徵壓縮成較低維的分類訊號」。一般文字分類模型多是以詞彙特徵預測裁判結果，也就是由文字走向結果；MNIR 則反過來觀察在不同裁判結果下，哪些詞彙分布方向較具有差異，再利用這些方向形成低維的充分縮減分數。因此，MNIR 的重點不只是減少特徵數量，而是利用裁判結果標籤資訊，萃取與分類任務較相關的文本方向。

然而，MNIR 是否能提升模型表現，仍須透過實證比較檢驗。特別是在本研究已先透過

卡方統計量進行特徵選擇的情況下，高關聯詞彙可能已被保留於稀疏文字特徵中。此時，進一步進行 MNIR 轉換是否能帶來額外增益，或反而壓縮掉少數類別與細部法律爭點的訊號，便成為本研究的重要問題。

因此，本研究以 Chi-square + MNIR + SVM 作為核心技術流程，並以 Chi-square + Direct SVM 作為對照流程。透過比較兩者在行政、民事、刑事與刑事附帶民事案件中的 Macro F1、Accuracy 與類別層級表現，本研究可檢驗 MNIR 監督式特徵轉換在中文智慧財產權判決分類任務中的適用性，同時評估傳統稀疏文字模型在此任務中的基準價值。

2.6 總結與研究缺口

綜合上述文獻，法律文本探勘與判決預測研究已逐漸從傳統法條釋義與個案分析，轉向以資料與模型為基礎的實證分析。既有研究中，部分判決預測任務確實採用二元結果設定，例如預測歐洲人權法院案件是否違反公約條文，或預測智慧財產權訴訟中專利權人勝訴或被被告勝訴 (Aletras et al., 2016; Surdeanu et al., 2011)。然而，法律判決預測並不限於二元分類，也包含法條預測、罪名預測、刑期預測、多標籤分類與多任務學習等形式 (Chalkidis et al., 2019; Feng et al., 2022; Yang et al., 2022)。因此，本研究並不主張過去文獻皆以二元分類為主，而是聚焦於臺灣智慧財產權判決文本脈絡下，將裁判結果整理為敗訴、部分勝訴與勝訴三類，進一步檢視模型在不同裁判結果類別上的辨識能力。

在智慧財產權判決文本中，部分勝訴與勝訴等類別通常樣本數較少，且其文字特徵可能與敗訴類別高度重疊。若僅觀察整體 Accuracy，模型可能因偏向預測多數類別而取得較高分數，卻無法充分反映少數類別之辨識困難。因此，本研究以 Macro F1 作為主要評估指標，並輔以分類報告與混淆矩陣，檢視模型是否真正能辨識不同裁判結果，而非僅依賴多數類別分布取得表面上的分類效果。

在方法設計上，本研究不以單一複雜模型為唯一依據，而是比較兩條具代表性的文字分類流程。第一條為 Chi-square + MNIR + SVM，亦即先以卡方統計量進行特徵選擇，再透過 MNIR 進行監督式特徵轉換，最後以 SVM 進行分類；第二條為 Chi-square + Direct SVM，亦即不經 MNIR 轉換，直接以卡方篩選後之稀疏文字特徵訓練 SVM。透過此一設計，本研究可檢驗 MNIR 特徵轉換是否能在卡方特徵選擇後進一步提升分類表現，同時也能評估傳統稀疏文字特徵模型在中文智慧財產權判決分類任務中的基準價值。

因此，本研究之研究缺口不在於主張既有文獻完全未處理多類別問題，而是在臺灣智慧財產權判決文本脈絡下，建立敗訴、部分勝訴與勝訴三類裁判結果之分類流程，並比較不同案件類型、不同文字特徵表示與不同模型流程下的分類表現。此一設計有助於說明智慧財產

權判決資料中的案件異質性、類別不平衡與少數類別辨識限制，並作為後續法律文本分類與法律科技應用之方法參考。



第三章 研究方法與資料

3.1 研究流程


本研究旨在運用文字探勘 (Text Mining) 與機器學習 (Machine Learning) 方法，對臺灣智慧財產權相關判決文本進行裁判結果分類。整體研究流程包含資料蒐集、智慧財產權案件篩選、文本清理與斷詞、樣本標籤整理、文字特徵建構、卡方特徵選擇、模型訓練與模型評估。

本研究將裁判結果整理為敗訴、部分勝訴與勝訴三類，並依案件類型區分為行政、民事、刑事與刑事附帶民事四類資料集。由於不同案件類型在樣本規模、法律用語、裁判邏輯與裁判結果分布上可能存在差異，本研究不將所有案件直接合併為單一資料集，而是分別建立模型並比較其分類表現。

在文字特徵表示方面，本研究比較 BoW、TF 與 TF-IDF 三種方法。在模型流程方面，本研究比較兩條主要流程：第一，Chi-square + MNIR + SVM，亦即先以卡方統計量進行特徵選擇，再透過 MNIR 進行監督式特徵轉換，最後以 SVM 進行分類；第二，Chi-square + Direct SVM，亦即不經 MNIR 轉換，直接以卡方篩選後之稀疏文字特徵訓練 SVM。透過兩者比較，本研究檢驗 MNIR 監督式特徵轉換是否能在智慧財產權判決分類任務中帶來額外增益。

本研究流程可概括如下：

資料蒐集 → 智慧財產權案件篩選 → 文本清理與斷詞 → 樣本與標籤整理 → BoW / TF / TF-IDF 特徵建構 → Chi-square 降維 → MNIR + SVM 與 Direct SVM 模型訓練 → 驗證集參數選擇 → 測試集模型評估。



3.2 資料獲取與前處理

本研究資料來自司法院資料開放平台，蒐集期間為 1996 年 1 月至 2024 年 12 月。本研究使用 Python 執行自動化資料下載，取得裁判書壓縮檔後，再呼叫 7-Zip 進行解壓縮，取得 JSON（JavaScript Object Notation）格式之裁判書檔案。原始資料共包含 90,027 筆裁判書檔案。

原始資料主要欄位如下表所示。

表 3-1 原始資料欄位說明

原始欄位	欄位說明
JID	案號
JYEAR	年度
JCASE	字別
JNO	號碼
JDATE	裁判日期
JTITLE	案由
JFULL	全文
JPDF	裁判書 PDF 下載連結

其中，JTITLE 可用於判斷案件案由與智慧財產權相關性，JFULL 則為本研究文字探勘與模型建構之主要文本來源。由於本研究目標為裁判結果分類，因此後續處理係以判決全文、案件類型與裁判結果標籤作為主要分析資料。

3.3 智慧財產權案件篩選與文本前處理

本研究首先透過正則表達式（regular expression）篩選智慧財產權相關案件。篩選條件包含兩類：第一，若 JTITLE 中出現智慧財產權相關字詞，則歸類為智慧財產權相關案件；第二，若 JCASE 中含有「智」字，亦納入智慧財產權相關案件之初步篩選範圍。

本研究採用之智慧財產權相關關鍵字包含：「違反商標法」、「違反著作權法」、「商標異議」

「新型專利舉發」、「商標評定」、「新型專利異議」、「侵害專利權有關財產權爭議」等。經關鍵字與案由篩選後，本研究進一步進行文本清理、停止詞移除與斷詞處理，作為後續模型輸入資料。

在文本清理方面，本研究主要針對裁判書全文進行以下處理：第一，移除文本中的換行符號，例如 \r\n；第二，移除多餘空白與格式符號；第三，保留與判決內容相關之文字資訊；第四，使用 Jieba stop words 字典移除停用詞，以降低常見但缺乏分類意義之詞彙對模型造成干擾。

在斷詞方面，本研究結合司法院裁判書用語辭典資料庫與中研院中文詞知識庫小組（Chinese Knowledge and Information Processing, CKIP）開發之 CKIP Transformers 進行中文斷詞（CKIP Lab, n.d.）。由於法律文本具有大量專業詞彙與固定法律用語，若僅依一般中文斷詞工具處理，可能產生法律詞彙切分不完整的問題。因此，本研究透過法律用語辭典與 CKIP Transformers 輔助斷詞，使後續文字特徵能更貼近法律文本語境。

此外，為降低模型直接依賴裁判結果詞彙進行分類的疑慮，本研究於主要實證結果中採用「移除明顯裁判結果詞彙後」之文本版本。亦即，將「駁回」、「有理由」、「准許」、「撤銷」等可能直接揭露裁判結果之詞彙移除，再進行模型訓練與測試。此處理可降低明顯結果詞彙造成資料洩漏的可能，但仍不能保證完全排除所有間接裁判結果線索，因此後續結果解讀仍須限縮於此一文本處理條件下。

3.4 樣本篩選、標籤整理與樣本分布

3.4.1 案件類型之法律性質

本研究將智慧財產權相關判決依案件性質區分為行政案件、民事案件、刑事案件與刑事附帶民事案件。此一分類並非僅為資料整理上的便利，而是因為不同案件類型在當事人結構、爭點性質、裁判目的與判決用語上皆有所差異。根據《智慧財產及商業法院組織法》，智慧財產及商業法院依法掌理智慧財產之民事、刑事及行政訴訟；同法亦明定其管轄案件包括智慧財產權益所生之民事事件、涉及商標法、著作權法、營業秘密法等之刑事案件，以及因專利法、商標法、著作權法等涉及智慧財產權所生之行政事件（全國法規資料庫，2023）。因此，本研究將不同案件類型分開建模與比較，有其法律制度與資料性質上的基礎。

行政案件主要涉及人民、法人或其他當事人與行政機關之間的公法爭議。在智慧財產權脈絡下，行政案件常見於當事人不服主管機關就專利、商標或其他智慧財產權事項所作成之行政處分，進而提起行政訴訟。司法院行政訴訟須知中亦指出，提起行政訴訟時，起訴狀須記載訴訟標的、原因事實、證據及相關法律規定；若案件曾經訴願程序，亦應附具訴願決定

書。因此，行政案件的文本通常較常出現「原處分」、「訴願決定」、「撤銷」、「行政機關」、「審定」等語彙。以智慧財產權案件為例，若商標申請人不服商標註冊遭駁回，或專利權人不服專利舉發成立之處分，即可能形成行政訴訟（司法院，2026）。

民事案件主要處理私人間權利義務或財產利益之爭議。司法院民事訴訟須知說明，人民財產權若遭侵害而無法自行和平解決，法院即提供解決紛爭的機制；在小額訴訟的說明中，司法院亦舉例包含請求返還借款、票款、各類賠償、租金與工資等給付請求事件。在智慧財產權脈絡下，民事案件通常是權利人主張其專利權、商標權、著作權或營業秘密受到侵害，進而請求排除侵害、損害賠償或其他民事救濟。例如，專利權人主張他人產品落入專利權範圍而請求損害賠償，或商標權人主張他人使用近似商標造成混淆而請求停止使用與賠償，皆屬民事案件的典型型態（司法院，2025）。

刑事案件則涉及國家對犯罪行為之追訴與處罰。與民事案件主要處理私人間權利義務不同，刑事案件的核心在於判斷被告是否構成犯罪，以及是否應受刑罰或其他刑事法律效果。司法院刑事訴訟須知中說明，刑事案件經檢察官向法院起訴或聲請簡易判決處刑後，於一定條件下得進行協商程序，且協商內容可能包括被告願意接受之刑度、沒收範圍、是否緩刑、向被害人道歉或支付賠償金等事項。在智慧財產權脈絡下，刑事案件可能包括違反商標法、著作權法、營業秘密法等犯罪案件。例如，行為人販賣仿冒商標商品、非法重製或散布著作，或以不法方式取得、使用營業秘密，即可能形成智慧財產權刑事案件（司法院，2025）。

刑事附帶民事案件則是刑事程序中一併處理被害人損害賠償請求的案件類型。司法院書狀範例明確說明，刑事附帶民事訴訟係指因犯罪受損害的人，在刑事第二審辯論終結前，起訴請求賠償。因此，刑事附帶民事案件同時具有刑事案件與民事損害賠償的雙重性質：刑事部分處理犯罪成立與刑罰問題，附帶民事部分則處理被害人因犯罪所受損害是否得請求賠償。例如，在販賣仿冒商標商品或侵害著作權的刑事案件中，若權利人主張因犯罪行為受到財產損害，即可能於刑事程序中一併提起附帶民事訴訟，請求被告賠償（司法院，2025）。

綜合而言，行政、民事、刑事與刑事附帶民事案件雖皆可能與智慧財產權有關，但其訴訟目的並不相同。行政案件重點在於行政處分或公法上權利義務爭議，民事案件重點在於私人間權利侵害與損害賠償，刑事案件重點在於犯罪追訴與刑罰判斷，刑事附帶民事案件則是在刑事程序中一併處理被害人之民事賠償請求。由於四類案件在爭點、文本用語與裁判邏輯上皆可能不同，本研究將其分開建模，以避免不同法律程序的語言特徵相互混雜，並使後續模型表現比較更具可解釋性。

表 3-2 案件類型之法律性質與例示

案件類型	核心性質	常見爭點	智慧財產權案件例示
行政案件	人民或法人與行政機關間之公法爭議	是否應撤銷或維持行政處分、訴願決定是否適法	不服商標註冊駁回、專利舉發審定或其他智慧財產行政處分
民事案件	私人間權利義務或財產利益爭議	是否構成侵權、是否應排除侵害或賠償損害	專利侵權損害賠償、商標侵權排除侵害、著作權侵權賠償
刑事案件	國家對犯罪行為之追訴與處罰	被告是否成立犯罪、是否應受刑罰或沒收	違反商標法、著作權法、營業秘密法等刑事案件
刑事附帶民事案件	刑事程序中一併處理被害人賠償請求	犯罪被害人是否因犯罪受損害、被告是否應負賠償責任	仿冒商標或侵害著作權刑事案件中，權利人附帶請求損害賠償

3.4.2 樣本篩選與標籤整理

本研究並非將所有原始智慧財產權相關裁判書皆納入模型分析，而是保留最終實際進入模型流程之有效樣本。篩選原則主要包含兩項：第一，案件類型必須能明確歸入本研究設定之四類案件類型，亦即行政案件、民事案件、刑事案件與刑事附帶民事案件；第二，裁判結果必須能整理為本研究設定之三類結果標籤，亦即敗訴、部分勝訴與勝訴。

在案件類型方面，本研究納入行政案件、民事案件、刑事案件與刑事附帶民事案件。其對應至程式資料中的 JTYPE 欄位，分別為 ADMINISTRATIVE、CIVIL、CRIMINAL 與 CWC。其他未被歸入上述四類之案件，例如 RULING、不重要案件，以及其他無法明確分類之案件，皆未納入後續模型分析。此一篩選方式可使分類任務聚焦於案件類型較為明確，且具備足夠樣本數可供模型訓練與比較之資料。

在裁判結果方面，本研究將模型預測標籤整理為三類，分別為敗訴、部分勝訴與勝訴。其對應至程式資料中的 VERDICT 欄位，分別為 Lose、Mixed 與 Win。其他裁判結果類型，例如 Other、Remand、Settlement_Partial、未知結果與不重要案件，並未納入本研究之分類模型。換言之，本研究所稱之裁判結果分類，並非涵蓋所有可能的裁判結果，而是聚焦於可明確整理為敗訴、部分勝訴與勝訴之案件。

3.4.3 樣本分布

表 3-3 顯示不同案件類型下之裁判結果分布。整體而言，本研究資料存在明顯類別不平衡現象。行政、民事與刑事案件中，敗訴類別皆占較高比例，尤其刑事案件之敗訴樣本數明顯高於勝訴與部分勝訴類別。相較之下，刑事附帶民事案件呈現不同分布，其部分勝訴案件數相對較多，而勝訴案件數極少。此結果顯示，不同案件類型不僅樣本規模不同，裁判結果之分布型態亦具有明顯差異。





表 3-3 案件類型與裁判結果分布

資料集	Lose	Mixed	Win	合計
行政	10106	502	911	11519
民事	3887	1408	435	5730
刑事	24552	80	1636	26268
刑事附帶民事	748	1047	32	1827
合計	39293	3037	3014	45344

表 3-4 進一步呈現不同年度區間之案件類型分布。由表可見，本研究資料並非平均分散於各年度與案件類型，而是集中於特定期間與特定案件類型。刑事案件在多數年度區間中皆為主要樣本來源，並於部分年度區間達到相對高峰；行政案件主要集中於中期年度區間，之後樣本數逐漸下降；民事案件則在後期年度區間維持一定樣本規模。刑事附帶民事案件整



體樣本數相對較少。此結果說明，不同案件類型在時間分布上具有差異，後續若直接混合所有案件建模，可能使模型主要受到樣本數較多之案件類型影響。

表 3-4 年度區間與案件類型分布

年度	行政	民事	刑事	刑事附帶民事	合計
80～85 年	0	0	12	0	12
86～89 年	1023	8	1030	30	2091
90～95 年	4588	827	5838	59	11312
96～101 年	2852	1741	7663	418	12674
102～107 年	1700	1690	6322	668	10380
108～113 年	1147	1394	5266	632	8439

表 3-5 則從年度角度觀察裁判結果比例，呈現各年度區間中敗訴、部分勝訴與勝訴之相對占比。由表可見，各年度區間仍呈現高度不平衡的裁判結果分布，多數年度區間皆由敗訴類別占主要比例，而勝訴與部分勝訴類別占比較低。此外，早期年度區間的樣本數相對較少，因此不宜單獨作為模型推論之基礎。相較之下，後期年度區間樣本數明顯較多，表示本研究模型主要學習訊息多來自較後期之判決資料。

表 3-5 年度區間與裁判結果比例

年度區間	敗訴	部分勝訴	勝訴
80-85	33.3%	0.0%	66.7%
86-89	87.5%	1.2%	11.3%
90-95	89.2%	4.0%	6.8%
96-101	87.2%	6.3%	6.5%
102-107	84.3%	9.0%	6.8%
108-113	84.8%	9.8%	5.4%

綜合上述樣本分布，本研究資料具有兩項重要特徵。第一，不同案件類型在樣本數、年度分布與裁判結果比例上皆具有差異，表示各案件類型可能存在不同法律用語、裁判邏輯與分類難度。因此，本研究後續將行政、民事、刑事與刑事附帶民事案件分開建模與比較，而非將所有案件直接合併為單一資料集。第二，裁判結果存在明顯類別不平衡，若僅使用 Accuracy 作為模型評估指標，模型可能因偏向預測多數類別而取得較高準確率，卻無法反映少數類別之辨識能力。因此，本研究後續以 Macro F1 作為主要評估指標，並輔以 準確率、精確率、召回率、F1 分數與混淆矩陣進行分析。

3.5 文字特徵建構

本研究將前處理與斷詞後之判決文本轉換為模型可處理之數值矩陣，並比較 BoW、TF 與 TF-IDF 三種文字特徵表示。由於法院裁判書屬於非結構化長文本，若未先轉換為數值特徵，機器學習模型無法直接進行分類。因此，文字特徵建構是本研究模型流程中的重要步驟。

3.5.1 詞袋模型

第一，詞袋模型將每篇裁判書視為詞彙集合，並依詞項出現次數建立文件—詞彙矩陣。此方法忽略詞彙順序、語法結構與上下文關係，但能保留詞彙在不同裁判文本中的分布情形。對法律裁判書而言，許多詞彙本身即可能具有分類訊號，例如特定請求類型、程序用語、侵權判斷用語或裁判理由用語，因此 BoW 可作為本研究的基礎文字特徵表示。

設本研究共有 N 篇裁判書，經斷詞後形成 V 個不同詞彙。第 i 篇裁判書記為 d_i ，第

j 個詞彙記為 w_j ，則 BoW 中的元素可表示為：

$$x_{ij} = \text{count}(w_j, d_i)$$

其中， x_{ij} 代表詞彙 w_j 在裁判書 d_i 中出現的次數。因此，第 i 篇裁判書可表示為一個 V 維向量：

$$\mathbf{x}_i = [x_{i1} \quad x_{i2} \quad \cdots \quad x_{iV}]$$

所有裁判書則可形成 BoW 文件－詞彙矩陣：

$$\mathbf{X}_{BoW} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1V} \\ x_{21} & x_{22} & \cdots & x_{2V} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{NV} \end{bmatrix}$$

其中：

$$\mathbf{X}_{BoW} \in \mathbb{R}^{N \times V}$$

N 代表裁判書數量， V 代表詞彙表大小。若某一詞彙未出現在該篇裁判書中，則其對應數值為 0；若出現多次，則以其出現次數表示。本研究建立 BoW 矩陣後，進一步於訓練集上進行卡方特徵選擇，篩選與 Lose、Mixed、Win 三類裁判結果較具關聯之詞彙特徵，再分別輸入 MNIR + SVM 與 Direct SVM 流程。

3.5.2 詞頻表示

第二，詞頻表示是在 BoW 的基礎上，進一步將詞彙出現次數轉換為該詞彙在單篇文件中的相對出現頻率。BoW 使用原始詞彙次數，容易受到裁判書長度影響；若某篇裁判書篇幅較長，其所有詞彙的出現次數通常也較高。TF 則透過詞頻標準化，使不同長度的裁判書具有較高可比性。因此，TF 可用來衡量某一詞彙在特定裁判書內部的重要程度，而非僅觀察其原始出現次數。

設 x_{ij} 代表詞彙 w_j 在裁判書 d_i 中出現的次數，則 TF 可表示為：

$$\text{tf}_{ij} = \frac{x_{ij}}{\sum_{k=1}^V x_{ik}}$$

其中：

$$\sum_{k=1}^V x_{ik}$$

代表第 i 篇裁判書中所有詞彙的總出現次數。因此， tf_{ij} 表示詞彙 w_j 在第 i 篇裁判書

中的相對出現頻率。透過此方式，所有裁判書可形成：

$$\mathbf{X}_{TF} \in \mathbb{R}^{N \times V}$$

之 TF 特徵矩陣。

在本研究中，TF 用於降低裁判書篇幅差異對詞彙計數造成的影響。建立 TF 矩陣後，本研究同樣於訓練集上進行卡方特徵選擇，篩選與 Lose、Mixed、Win 三類裁判結果較具關聯的前 K 個詞彙，再分別輸入 MNIR + SVM 與 Direct SVM 流程。

3.5.3 詞頻－逆文件頻率

第三，詞頻－逆文件頻率是在 TF 的基礎上，進一步加入詞彙於整體語料中普遍程度的調整。TF 僅衡量某詞彙在單篇裁判書中的相對出現頻率，但若某些詞彙在大量裁判書中皆頻繁出現，則其區分不同裁判結果的能力可能有限。TF-IDF 因此透過逆文件頻率降低常見詞彙的權重，並提高相對少見但可能具有區辨力詞彙的權重。

本研究實作上採用 scikit-learn 之 TfidfVectorizer，並使用 IDF 平滑化與 L2 正規化處理 (scikit-learn developers, n.d.-b)。在 scikit-learn 的預設設定中，smooth_idf=True 會在 IDF 計算時加入平滑化處理，norm='l2' 則會將每篇文件的 TF-IDF 向量正規化為單位向量。

設 N 為裁判書總數， df_j 代表包含詞彙 w_j 的裁判書數量。在使用 smooth_idf=True 的情況下，逆文件頻率可表示為：

$$\text{idf}_j = \log \left(\frac{1 + N}{1 + df_j} \right) + 1$$

其中，分子與分母同時加 1，表示進行平滑化處理，以避免極端權重或零除問題。在未啟用 sublinear_tf 的情況下，scikit-learn 使用原始詞彙次數作為詞頻，因此未正規化前的 TF-IDF 權重可表示為：

$$z_{ij} = x_{ij} \times \text{idf}_j$$

在本研究使用 L2 正規化後，每一篇裁判書的 TF-IDF 向量會被縮放為單位長度。令第 i 篇裁判書未正規化前的 TF-IDF 向量為：

$$\mathbf{z}_i = [z_{i1} \quad z_{i2} \quad \cdots \quad z_{iV}]$$

則 L2 正規化後的 TF-IDF 特徵向量可表示為：

$$\mathbf{x}_i^{TF-IDF} = \frac{\mathbf{z}_i}{\|\mathbf{z}_i\|_2}$$

其中：

$$\| \mathbf{z}_i \|_2 = \sqrt{\sum_{j=1}^V z_{ij}^2}$$

因此，所有裁判書可形成：

$$\mathbf{X}_{TF-IDF} \in \mathbb{R}^{N \times V}$$

之 TF-IDF 特徵矩陣。

在本研究中，TF-IDF 用於強化在特定裁判書中較具代表性、但不普遍出現在所有裁判書中的詞彙。建立 TF-IDF 矩陣後，本研究同樣於訓練集上進行卡方特徵選擇，篩選與 Lose、Mixed、Win 三類裁判結果較具關聯之詞彙，再分別輸入 MNIR+SVM 與 Direct SVM 流程。

綜上所述，BoW、TF 與 TF-IDF 的矩陣形狀皆為 $N \times V$ ，差異在於矩陣元素的計算方式不同。BoW 保留詞彙原始出現次數，TF 將詞彙次數轉換為單篇裁判書內的相對詞頻，TF-IDF 則進一步結合詞彙在整體語料中的稀有程度。本研究不預設單一特徵表示必然最佳，而是在後續模型中分別檢驗 BoW、TF 與 TF-IDF 於不同案件類型下之分類效果。

3.6 卡方特徵選擇

判決文本經 BoW、TF 或 TF-IDF 向量化後，通常會形成高維稀疏矩陣。若直接將所有詞彙納入模型，可能造成三項問題：第一，計算負擔增加；第二，大量無關詞彙可能稀釋有效分類訊號；第三，模型可能因高維特徵而產生過度擬合。因此，本研究採用卡方特徵選擇進行降維，目的在於從大量詞彙中篩選出與裁判結果較具統計關聯之特徵。

在概念上，卡方特徵選擇可理解為檢驗「詞彙特徵」與「裁判結果類別」之間是否具有關聯。若某一詞彙特徵在 Lose、Mixed、Win 三類裁判結果中的分布差異越大，表示該特徵越可能與裁判結果相關，因此具有較高的分類判別力；相反地，若某一詞彙特徵在各類別中的分布相近，則該特徵對區分裁判結果的幫助可能較低。

需要說明的是，卡方特徵選擇常可用「詞彙出現情形」與「類別標籤」之間的列聯表（contingency table）進行直觀理解；然而，本研究實作上同時使用 BoW、TF 與 TF-IDF 三種文字特徵表示，因此並非僅限於二元的詞彙出現與否。本研究依 scikit-learn 之 chi2 方法，對 BoW、TF 與 TF-IDF 等非負文字特徵計算其與裁判結果標籤之關聯程度，並依卡方統計量由高至低排序，選取前 K 個詞彙特徵（scikit-learn developers, n.d.-a）。

在計算方式上，卡方統計量可用觀察值與期望值之差異加以表示。其概念為：若某一詞彙特徵與裁判結果類別彼此獨立，則不同類別中的特徵分布應接近期望分布；若實際觀察到

的分布與期望分布差距越大，則卡方統計量越高，表示該特徵與裁判結果類別之間的關聯越強。卡方統計量可表示為：

$$\chi^2 = \sum_{r=1}^R \sum_{c=1}^C \frac{(O_{rc} - E_{rc})^2}{E_{rc}}$$

其中， O_{rc} 代表第 r 列、第 c 欄的觀察次數， E_{rc} 則代表在詞彙與裁判結果彼此獨立的假設下，理論上應出現的期望次數。期望次數可表示為：

$$E_{rc} = \frac{(\text{第 } r \text{ 列總數}) \times (\text{第 } c \text{ 欄總數})}{\text{總樣本數}}$$

因此，若觀察值 O_{rc} 與期望值 E_{rc} 差距越大，則卡方統計量越高，表示該詞彙特徵與裁判結果類別之間的關聯越強。

以本研究為例，若某一詞彙特徵在敗訴案件中具有較高特徵值，但在部分勝訴與勝訴案件中較低，則該特徵的分布會明顯偏離「與裁判結果無關」時的期望分布，因此其卡方統計量會較高。相反地，若某一詞彙特徵在 Lose、Mixed、Win 三類案件中皆呈現相近分布，則其卡方統計量會較低，代表該特徵較不具分類判別力。

在本研究實作流程中，卡方特徵選擇僅於訓練集上進行。首先，本研究將每一案件類型之裁判文本轉換為 BoW、TF 或 TF-IDF 特徵矩陣。其次，以裁判結果標籤 Lose、Mixed、Win 作為類別變數，計算每一個詞彙特徵與裁判結果之間的卡方統計量。接著，依照卡方統計量由高至低排序，選取前 K 個詞彙特徵。最後，將訓練集所得到的特徵篩選規則套用至驗證集與測試集。

本研究之卡方特徵選擇流程可概括如下：

$$\mathbf{X} \rightarrow \chi^2(\mathbf{X}, y) \rightarrow \text{Select Top } K \rightarrow \mathbf{X}_{\text{selected}}$$

其中， $\mathbf{X}$ 代表 BoW、TF 或 TF-IDF 所形成的原始文字特徵矩陣， y 代表裁判結果標籤， $\chi^2(\mathbf{X}, y)$ 代表計算各詞彙特徵與裁判結果之間的卡方統計量， $\mathbf{X}_{\text{selected}}$ 則代表篩選後的特徵矩陣。

需要注意的是，本研究不在完整資料集上進行卡方特徵選擇，而是僅使用訓練集估計特徵篩選規則。此設計可避免驗證集與測試集資訊提前進入模型訓練流程，降低資料洩漏風險。 K 值則透過驗證集表現進行選擇，測試集僅用於最終模型評估。

卡方特徵選擇在本研究中具有兩項功能。第一，它可降低文字特徵維度，減少後續 MNIR 與 SVM 模型的計算負擔。第二，它可保留與裁判結果較具統計關聯的詞彙特徵，使模型更聚焦於具有分類訊號的法律用語。換言之，Chi-square 並非最終分類器，而是位於文字特徵建

構與模型訓練之間的特徵篩選步驟。本研究後續兩條模型流程，亦即 Chi-square + MNIR + SVM 與 Chi-square + Direct SVM，皆以卡方篩選後的特徵矩陣作為輸入。

卡方特徵選擇為文字分類與資訊檢索中常見的監督式特徵選擇方法，其目的在於衡量詞彙特徵與類別標籤之間的統計關聯，並據以篩選較具判別力的特徵 (Manning, Raghavan, & Schütze, 2009)。本研究亦依此邏輯，將卡方統計量作為高維裁判文本特徵降維的前置步驟。

3.7 MNIR 監督式特徵轉換

MNIR 是一種用於高維文本資料的監督式特徵轉換方法。直觀而言，MNIR 可理解為「用裁判結果反推詞彙方向，再做降維」。一般文字分類模型多採前向預測邏輯，也就是以文字特徵預測裁判結果；相對地，MNIR 採取 inverse regression 的思維，反過來觀察在不同裁判結果條件下，文字詞彙分布如何變化。

因此，MNIR 並非直接以文字特徵預測裁判結果，而是先估計裁判結果與詞彙分布之間的關係，找出哪些詞彙方向較能區分敗訴、部分勝訴與勝訴，再將高維文字特徵轉換為低維的充分縮減分數。換言之，MNIR 的功能不是直接分類，而是先把大量詞彙壓縮成較少數、且與裁判結果較相關的特徵，作為後續 SVM 分類器的輸入。在本研究脈絡中，裁判文本經 BoW、TF 或 TF-IDF 表示後，通常會形成高維且稀疏的文字特徵矩陣。雖然本研究已先透過卡方特徵選擇篩選與裁判結果較相關的詞彙，但篩選後的特徵仍可能包含大量詞彙維度。MNIR 的目的即是在卡方特徵選擇後，進一步利用裁判結果標籤資訊，將文字特徵轉換為較低維且與分類目標相關的表徵，作為後續 SVM 分類器的輸入。

因此，MNIR 在本研究中扮演「監督式特徵轉換」與「降維」的角色。其核心不只是減少特徵數量，而是透過裁判結果標籤，萃取與敗訴、部分勝訴與勝訴三類結果相關的詞彙分布方向。後續小節將進一步說明 MNIR 的模型設定與 inverse regression 邏輯、Gamma-Lasso 估計法，以及充分縮減分數如何作為 SVM 分類模型之輸入。

3.7.1 MNIR 之模型設定與 inverse regression

在高維度文本資料的統計建模中，研究者常面臨「維度災難」問題。當詞彙表規模達數千至數萬維度時，若直接以前向模型將裁判結果 y 對高維詞頻向量 x 建模，容易因參數空間過大而造成估計不穩定，亦可能使真正與裁判結果相關的詞彙訊號被大量無關詞彙稀釋。

本研究採用的 MNIR 架構，其核心策略在於反轉一般預測邏輯。也就是說，本文不是一開始就問「哪些詞彙可以預測裁判結果」，而是先問「在不同裁判結果下，詞彙分布呈現哪些系統性差異」。若某些詞彙在 Lose、Mixed 與 Win 三類結果中的出現模式明顯不同，MNIR

便會將這些差異整理為後續可供分類器使用的低維特徵。傳統前向模型通常關注 $\mathbf{x}$ 如何預測 y ；MNIR 則改以給定目標變數 y 的條件下，觀察文本詞彙分布 $\mathbf{x} | y$ 如何變化。換言之，MNIR 並非單純描述文本本身的隨機變異，而是試圖萃取與裁判結果 y 相關的詞彙分布方向。

在數學定義上，MNIR 將每一份裁判書視為由詞彙所組成的多項式抽樣結果。依據 Taddy (2013) 的架構，設第 i 篇裁判書之詞頻計數向量為 $\mathbf{x}_i$ ，該裁判書之總詞數為 m_i ，詞彙出現機率向量為 $\mathbf{q}_i$ ，而 $\mathbf{v}_i$ 為由裁判結果 y_i 所對應之目標變數因子，則 MNIR 的基本形式可表示為：

$$\mathbf{x}_i | \mathbf{v}_i \sim \text{Multinomial}(m_i, \mathbf{q}_i)$$

其中， $\mathbf{x}_i$ 為詞頻計數向量， m_i 為第 i 篇裁判書的總詞數， $\mathbf{q}_i$ 則為該裁判書中各詞彙出現機率所構成的向量。此設定表示，MNIR 關注的是在給定裁判結果相關因子 $\mathbf{v}_i$ 的條件下，裁判文本中的詞彙如何分布。

進一步而言，詞彙出現機率 $\mathbf{q}_i$ 可透過邏輯連結函數與目標變數因子 $\mathbf{v}_i$ 建立關係。第 j 個詞彙的出現機率可表示為：

其中：

$$q_{ij} = \frac{\exp(\eta_{ij})}{\sum_{l=1}^p \exp(\eta_{il})}$$

$$\eta_{ij} = \alpha_j + \mathbf{v}_i^\top \boldsymbol{\varphi}_j$$

在此公式中， α_j 為詞彙 j 的基礎攔截項，代表該詞彙在整體語料中的基準出現傾向； $\boldsymbol{\varphi}_j$ 則為詞彙 j 對應於目標變數因子 $\mathbf{v}_i$ 的負載參數，用以描述該詞彙與裁判結果相關變異之間的關係。若某些詞彙在 Lose、Mixed 與 Win 三類裁判結果中的分布差異明顯，其對應的 $\boldsymbol{\varphi}_j$ 便可能具有較高的判別意義。

此處的 inverse regression 意義在於，MNIR 不是直接估計「文字特徵如何預測裁判結果」，而是反過來估計「不同裁判結果下的文字詞彙分布」。因此，MNIR 的重點不只是分類，而是透過裁判結果標籤資訊，找出與裁判結果相關的詞彙分布方向，並將其轉換為後續分類模型可使用的低維特徵。

MNIR 的另一項優勢在於，當多份文件具有相同或相近的目標變數特徵時，可透過合併詞彙計數將資料壓縮為列聯表形式進行估計。此一可折疊性 (collapsibility) 可降低高維文本資料的計算負擔，使模型在處理大規模語料時具備較佳效率。對本研究而言，MNIR 的目的即是透過此一逆向建模方式，萃取法律文本中與裁判結果相關的低維表徵。

3.7.2 Gamma-Lasso 估計法與正則化

在前述 MNIR 模型設定下，模型需要估計大量詞彙負載參數。由於法律文本經斷詞後通常會形成高維詞彙空間，若所有詞彙參數皆無限制地進入模型，容易造成估計不穩定、計算負擔提高，並增加過度擬合的風險。因此，MNIR 在實際估計時需要搭配正則化方法，以控制高維詞彙參數並降低雜訊詞彙的影響。

Taddy (2013) 提出 Gamma-Lasso 估計法，用以處理高維文本模型中的參數收縮問題。其核心概念是對詞彙負載參數加入懲罰機制，使與目標變數關聯較弱的詞彙參數被壓縮，而與裁判結果較相關的詞彙訊號得以保留。相較於標準 Lasso 對所有係數進行一致性的收縮，Gamma-Lasso 透過較具彈性的非凹性懲罰機制，能降低重要詞彙係數被過度壓縮的問題。

設 $\ell(\alpha, \Phi)$ 為 MNIR 模型的對數概似函數，其中 α 代表詞彙基礎攔截項， Φ 代表所有詞彙負載參數所形成的矩陣。Gamma-Lasso 可概念性表示為以下懲罰化估計問題：

$$(\hat{\alpha}, \hat{\Phi}) = \arg \max_{\alpha, \Phi} \left\{ \ell(\alpha, \Phi) - \lambda \sum_{j=1}^p P_{\gamma}(\varphi_j) \right\}$$

其中， $\hat{\alpha}$ 與 $\hat{\Phi}$ 分別為估計後的攔截項與詞彙負載矩陣， φ_j 代表第 j 個詞彙對應的負載參數， p 為詞彙數量， λ 控制整體懲罰強度， $P_{\gamma}(\varphi_j)$ 則代表 Gamma-Lasso 所對應的非凹性懲罰函數。此懲罰項的作用在於壓縮不具明顯判別力的詞彙參數，同時盡可能保留與裁判結果具有較強關聯的詞彙方向。

在本研究中，Gamma-Lasso 的功能不是直接進行分類，而是作為 MNIR 模型估計中的正則化步驟。具體而言，Gamma-Lasso 協助 MNIR 從大量法律詞彙中估計出較穩定的詞彙負載矩陣 $\hat{\Phi}$ ，再由此計算後續的充分縮減分數。換言之，Gamma-Lasso 位於 MNIR 模型內部，其目的在於提升高維文本特徵轉換的穩定性，而非取代後續的 SVM 分類器。

對本研究而言，Gamma-Lasso 具有兩項方法意義。第一，它可降低無關詞彙對 MNIR 估計的干擾，使模型更聚焦於與 Lose、Mixed 與 Win 三類裁判結果相關的詞彙訊號。第二，它可在高維法律文本資料中減少過度擬合風險，使 MNIR 轉換後的低維特徵較適合輸入後續 SVM 分類器。因此，Gamma-Lasso 可視為 MNIR 進行監督式特徵轉換時的重要估計機制。

3.7.3 充分縮減分數與降維邏輯

在 MNIR 完成模型估計後，核心輸出並不是直接的裁判結果預測，而是每一篇裁判書對應的充分縮減分數。此分數可視為原始高維文本特徵的低維監督式表徵，其目的並非保留裁

判書中的所有文字資訊，而是保留與裁判結果分類較相關的詞彙訊號。

設第 i 篇裁判書之詞頻計數向量為 $\mathbf{x}_i$ ，該裁判書總詞數為 m_i ，則其相對詞頻向量可表示為：

$$\mathbf{f}_i = \frac{\mathbf{x}_i}{m_i}$$

其中， $\mathbf{f}_i$ 代表第 i 篇裁判書中各詞彙的相對出現頻率。若 $\hat{\Phi}$ 為 MNIR 經 Gamma-Lasso 估計後得到的詞彙負載矩陣，則第 i 篇裁判書的充分縮減分數可表示為：

$$\mathbf{s}_i = \hat{\Phi}^T \mathbf{f}_i$$

其中， $\mathbf{s}_i$ 即為第 i 篇裁判書之充分縮減分數， $\hat{\Phi}$ 則代表 MNIR 所估計出的詞彙負載方向。此公式表示，MNIR 會將原始高維詞彙頻率向量 $\mathbf{f}_i$ 投影到由 $\hat{\Phi}$ 所形成的低維空間中，進而得到較低維的文本表徵。

換言之，原始文字特徵矩陣可能包含數千至數萬個詞彙維度，但並非所有詞彙皆與裁判結果有關。MNIR 透過前述 inverse regression 模型，先估計不同裁判結果下詞彙分布的變化方向，再利用這些估計出的詞彙負載方向，將每篇裁判書轉換為低維的充分縮減分數。因此，MNIR 的降維並非一般無監督式壓縮，而是利用裁判結果標籤資訊進行監督式特徵轉換。

在模型假設成立下，充分縮減分數可被視為原始高維文本中與裁判結果相關資訊的低維摘要。也就是說，給定充分縮減分數後，原始高維詞彙向量對裁判結果所能提供的額外資訊理論上會降低。此一關係可概念性表示為：

$$y_i \perp \mathbf{x}_i \mid \mathbf{s}_i$$

其中， y_i 為第 i 篇裁判書的裁判結果標籤， $\mathbf{x}_i$ 為原始高維詞彙向量， $\mathbf{s}_i$ 則為 MNIR 轉換後的充分縮減分數。此條件獨立關係並非本研究直接檢定之經驗命題，而是在 MNIR 模型設定成立下的理論性質。因此，本文對此採取保守解讀：MNIR 理論上可將高維文本轉換為與裁判結果相關的低維表徵，但其實際分類效果仍需透過後續與 Direct SVM 的比較加以檢驗。

在本研究流程中，MNIR 位於卡方特徵選擇與 SVM 分類器之間。具體而言，本研究先以卡方統計量篩選與 Lose、Mixed、Win 三類裁判結果較相關的前 K 個詞彙特徵，再以訓練集估計 MNIR 模型與詞彙負載矩陣 $\hat{\Phi}$ 。接著，將訓練集、驗證集與測試集分別轉換為充分縮減分數，最後再將這些低維特徵輸入 SVM 分類器進行裁判結果分類。

因此，充分縮減分數在本研究中具有兩項功能。第一，它將高維稀疏文字特徵轉換為低維表徵，降低後續分類器的輸入維度。第二，它透過裁判結果標籤資訊保留與分類目標較相

關的詞彙方向，使後續 SVM 分類器能以較低維的特徵進行判斷。不過，MNIR 轉換是否能實際提升分類表現，仍需以第四章 MNIR + SVM 與 Direct SVM 的實證結果作為判斷依據。

3.8 模型流程設計

本研究比較兩條主要模型流程，分別為 **Chi-square + MNIR + SVM** 與 **Chi-square + Direct SVM**。兩條流程皆以前述文字特徵建構與卡方特徵選擇作為共同前置步驟，差異在於是否進一步透過 MNIR 進行監督式特徵轉換。前者用以檢驗 MNIR 是否能將高維法律文本特徵轉換為較具判別力之低維表徵；後者則作為不經 MNIR 轉換之直接對照流程。

具體而言，本研究先將裁判文本轉換為 BoW、TF 或 TF-IDF 特徵矩陣，再以卡方統計量篩選與 Lose、Mixed、Win 三類裁判結果較相關的前 K 個詞彙特徵。完成特徵篩選後，第一條流程會進一步將卡方篩選後的文字特徵輸入 MNIR，轉換為充分縮減分數，再以 SVM 進行分類；第二條流程則不經 MNIR，直接將卡方篩選後的文字特徵輸入 SVM。透過此一設計，本研究得以檢驗 MNIR 特徵轉換是否能在既有卡方特徵選擇基礎上帶來額外分類增益。

3.8.1 SVM 分類器設定

SVM 是一種常見的監督式分類模型，其核心概念是在特徵空間中尋找能區分不同類別的分類邊界。對本研究而言，SVM 的輸入可以是卡方篩選後之 BoW、TF 或 TF-IDF 稀疏文字特徵，也可以是 MNIR 轉換後之充分縮減分數；其輸出則為 Lose、Mixed 與 Win 三類裁判結果預測。

由於裁判文本經文字向量化後通常具有高維且稀疏的特性，SVM 適合作為本研究之下游分類器。SVM 的目的並非重新進行文字特徵篩選，而是根據前一階段產生的特徵向量，建立可區分不同裁判結果的分類規則。

在多類別分類情境下，SVM 可對不同裁判結果類別建立分類函數。概念上，對於第 i 篇裁判書，其分類函數可表示為：

$$f_c(\mathbf{v}_i) = \mathbf{w}_c^T \mathbf{v}_i + b_c$$

其中， $\mathbf{v}_i$ 代表第 i 篇裁判書輸入 SVM 的特徵向量，可能是卡方篩選後的文字特徵，也可能是 MNIR 轉換後的充分縮減分數； c 代表裁判結果類別，包含 Lose、Mixed 與 Win； $\mathbf{w}_c$ 與 b_c 則分別代表分類函數的權重與截距。

模型最後會將樣本分配至分類分數最高的類別：

$$\hat{y}_i = \arg \max_c f_c(\mathbf{v}_i)$$

其中， $\hat{y}_i$ 代表模型對第 i 篇裁判書所預測的裁判結果。換言之，SVM 在本研究中的功能，是根據輸入特徵判斷每篇裁判書最可能屬於敗訴、部分勝訴或勝訴。

在本研究中，SVM 同時用於兩條模型流程。第一，在 Chi-square + MNIR + SVM 流程中，SVM 使用 MNIR 轉換後的充分縮減分數進行分類。第二，在 Chi-square + Direct SVM 流程中，SVM 直接使用卡方篩選後的稀疏文字特徵進行分類。透過這兩種設定，本研究得以比較 MNIR 特徵轉換後的低維特徵與原始稀疏文字特徵在裁判結果分類上的表現差異。

3.8.2 Chi-square + MNIR + SVM 流程

第一條模型流程為 **Chi-square + MNIR + SVM**。此流程的目的，是檢驗 MNIR 監督式特徵轉換是否能在卡方特徵選擇之後，進一步將高維法律文本特徵轉換為較具判別力的低維表徵，並提升 SVM 對裁判結果的分類能力。此流程與 Direct SVM 的主要差異在於：本流程不直接將卡方篩選後的詞彙特徵輸入 SVM，而是先透過 MNIR 轉換為充分縮減分數，再進行分類。

本研究首先將裁判文本轉換為 BoW、TF 或 TF-IDF 特徵矩陣，接著於訓練集上進行卡方特徵選擇，選出與 Lose、Mixed、Win 三類裁判結果較具統計關聯的前 K 個詞彙特徵。完成卡方篩選後，本研究使用訓練集之文字特徵矩陣與裁判結果標籤估計 MNIR 模型，並取得訓練資料之充分縮減分數。

MNIR 模型訓練完成後，本研究固定已估計完成的 MNIR 轉換規則，將驗證集與測試集分別轉換至相同的低維特徵空間。此步驟的重點在於，驗證集與測試集只套用訓練集所學得的轉換規則，而不重新估計 MNIR 模型，以避免驗證集或測試集資訊提前進入模型訓練流程。

此流程可概括如下：

$$\mathbf{X} \rightarrow \chi^2 \text{ feature selection} \rightarrow \mathbf{X}_{\text{selected}} \rightarrow \text{MNIR} \rightarrow \mathbf{S} \rightarrow \text{SVM} \rightarrow \hat{y}$$

其中， $\mathbf{X}$ 代表 BoW、TF 或 TF-IDF 所形成的原始文字特徵矩陣， $\mathbf{X}_{\text{selected}}$ 代表經卡方特徵選擇後的文字特徵矩陣， $\mathbf{S}$ 代表 MNIR 轉換後的充分縮減分數矩陣， $\hat{y}$ 則代表 SVM 預測之裁判結果。

在下游分類階段，本研究以 MNIR 轉換後之充分縮減分數訓練 SVM 分類器，並以驗證集 Macro F1 選擇 SVM 懲罰參數 C 。確定最佳參數後，再將訓練集與驗證集合併，依最佳設定重新訓練最終模型，最後使用測試集評估模型表現。測試集僅作為最終模型評估資料，不參與特徵選擇、MNIR 估計或參數選擇。

因此，Chi-square + MNIR + SVM 流程在本研究中具有兩層意義。第一，Chi-square 用於初步降低詞彙維度，保留與裁判結果較相關的詞彙特徵。第二，MNIR 進一步將卡方篩選後

的高維文字特徵轉換為低維充分縮減分數，使 SVM 不必直接處理完整的高維稀疏矩陣。後續第四章將透過此流程與 Direct SVM 流程之比較，檢驗 MNIR 轉換是否能在本研究資料中帶來額外分類增益。

3.8.3 Chi-square + Direct SVM 對照流程

第二條模型流程為 **Chi-square + Direct SVM**。此流程的目的，是作為 Chi-square + MNIR + SVM 的對照組，用以檢驗在不經 MNIR 監督式特徵轉換的情況下，卡方篩選後的稀疏文字特徵本身是否已具有足夠的分類能力。

與 MNIR + SVM 流程不同，Direct SVM 不會將文字特徵轉換為充分縮減分數，而是直接使用卡方特徵選擇後的 BoW、TF 或 TF-IDF 特徵矩陣訓練 SVM 分類器。換言之，此流程保留卡方篩選後的高維稀疏文字特徵，讓 SVM 直接根據這些詞彙特徵判斷裁判結果。

此流程可概括如下：

$$\mathbf{X} \rightarrow \chi^2 \text{ feature selection} \rightarrow \mathbf{X}_{\text{selected}} \rightarrow \text{SVM} \rightarrow \hat{y}$$

其中， $\mathbf{X}$ 代表 BoW、TF 或 TF-IDF 所形成的原始文字特徵矩陣， $\mathbf{X}_{\text{selected}}$ 代表經卡方特徵選擇後的文字特徵矩陣， $\hat{y}$ 則代表 SVM 預測之裁判結果。

在實作流程上，本研究同樣僅於訓練集上進行卡方特徵選擇，並將訓練集所得到的特徵篩選規則套用至驗證集與測試集。接著以訓練集之 $\mathbf{X}_{\text{selected}}$ 訓練 SVM 分類器，並以驗證集 Macro F1 選擇最佳 SVM 懲罰參數 C 。確定最佳參數後，再將訓練集與驗證集合併，依最佳設定重新訓練最終模型，最後使用測試集進行模型評估。此流程與 MNIR + SVM 一樣，測試集僅用於最終評估，不參與特徵選擇或參數調整。

Direct SVM 在本研究中具有重要的基準意義。若 MNIR + SVM 的表現優於 Direct SVM，則表示 MNIR 監督式特徵轉換可能在卡方篩選後提供額外的降維與分類增益；反之，若 Direct SVM 的表現優於 MNIR + SVM，則表示在本研究資料與設定下，卡方篩選後的稀疏文字特徵可能已保留足夠的裁判結果分類訊號，進一步進行 MNIR 低維轉換未必能改善模型表現。

因此，本研究不單獨觀察 MNIR + SVM 的模型分數，而是透過 MNIR + SVM 與 Direct SVM 的直接比較，判斷 MNIR 監督式特徵轉換在中文智慧財產權裁判結果分類任務中的實際效果。此設計也可避免直接假設較複雜的特徵轉換方法必然優於傳統稀疏文字模型。

3.8.4 Majority Class baseline

除 MNIR + SVM 與 Direct SVM 外，本研究亦設置 **Majority Class baseline** 作為最低基準模型。Majority Class baseline 是指模型不根據裁判文本內容進行判斷，而是一律將所有

樣本預測為訓練資料中樣本數最多的裁判結果類別。由於本研究資料存在明顯類別不平衡，若只觀察 Accuracy，模型可能因大量預測多數類別而取得表面上較高的分數，因此需要設置此一基準模型作為比較標準。

在本研究中，Majority Class baseline 的計算邏輯如下。首先，於訓練集中確認 Lose、Mixed 與 Win 三類裁判結果的樣本數，找出樣本數最多的類別。接著，無論驗證集或測試集中的裁判文本內容為何，模型皆預測為該多數類別。其預測規則可表示為：

$$\hat{y}_i = \arg \max_{c \in \{Lose, Mixed, Win\}} n_c$$

其中， n_c 代表訓練集中類別 c 的樣本數， $\hat{y}_i$ 代表第 i 筆樣本的預測結果。換言之，Majority Class baseline 不使用任何文字特徵，也不進行模型訓練，而是完全依據訓練集的類別分布進行預測。

此基準模型的目的是在於檢查分類模型是否真的學習到裁判文本中的分類訊號。若 MNIR + SVM 或 Direct SVM 的表現僅略高於 Majority Class baseline，表示模型相較於單純預測多數類別的最低基準，所增加的分類效益有限，模型表現可能仍高度受到類別分布影響。反之，若模型表現明顯高於 Majority Class baseline，則表示模型至少具有超越多數類別預測規則的分類能力，可能已從裁判文本中捕捉到部分與裁判結果相關的特徵。不過，模型是否能有效辨識各裁判結果類別，仍須進一步搭配 Macro F1、各類別 Precision、Recall、F1-score 與混淆矩陣進行判斷。

因此，Majority Class baseline 在本研究中作為判斷模型是否具有實質分類能力的最低比較標準。後續第四章將以此基準輔助解讀 Direct SVM 與 MNIR + SVM 的分類結果，避免僅因 Accuracy 較高而誤判模型具有良好分類能力。

3.8.5 模型評估方式

本研究之模型表現主要以 Macro F1 作為判斷依據，並輔以 Accuracy、Precision、Recall、F1-score 與混淆矩陣進行分析。需要說明的是，即使在類別分布較均衡的情況下，Accuracy 仍無法完整呈現模型在各類別上的錯誤型態；而在本研究 Lose、Mixed 與 Win 三類裁判結果明顯不均衡的情況下，Accuracy 更可能受到多數類別影響而高估模型表現。因此，本研究不僅觀察整體 Accuracy，也以 Macro F1、各類別指標與混淆矩陣檢視模型是否能有效辨識不同裁判結果。

為說明 Precision、Recall 與 F1-score 的計算方式，本文先以任一類別 c 為目標類別，採 one-vs-rest 方式表示 TP、FP、FN 與 TN 之判斷邏輯。其概念如下表所示。

表 3-6 TP、FP、FN、TN 判斷示意表

	預測為類別 c	預測為非類別 c
實際為類別 c	TP	FN
實際為非類別 c	FP	TN

其中，TP (True Positive) 代表實際為類別 c ，且模型也正確預測為類別 c ；FP (False Positive) 代表實際並非類別 c ，但模型錯誤預測為類別 c ；FN (False Negative) 代表實際為類別 c ，但模型錯誤預測為非類別 c ；TN (True Negative) 則代表實際並非類別 c ，且模型也未預測為類別 c 。

以本研究三類裁判結果為例，若以 Win 作為目標類別，則 TP 代表實際為 Win 且模型也預測為 Win；FN 代表實際為 Win 但模型預測為 Lose 或 Mixed；FP 代表實際並非 Win 但模型預測為 Win；TN 則代表實際並非 Win 且模型也未預測為 Win。Lose 與 Mixed 類別亦可依相同 one-vs-rest 邏輯計算。

準確率表示模型正確分類樣本數占總樣本數之比例。在二元分類或 one-vs-rest 架構下，Accuracy 可表示為：

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + FN + TN}$$

在多類別分類情境下，Accuracy 亦可理解為混淆矩陣中所有正確分類數除以總樣本數，也就是對角線正確分類總和占全部樣本的比例。以本研究 Lose、Mixed 與 Win 三類分類為例，可表示為：

$$\text{Accuracy} = \frac{n_{\text{Lose,Lose}} + n_{\text{Mixed,Mixed}} + n_{\text{Win,Win}}}{N}$$

其中， $n_{\text{Lose,Lose}}$ 、 $n_{\text{Mixed,Mixed}}$ 與 $n_{\text{Win,Win}}$ 分別代表 Lose、Mixed 與 Win 被正確分類的樣本數， N 則代表總樣本數。Accuracy 的優點是直觀易懂，但其限制在於無法呈現模型是否只對多數類別表現良好。因此，在本研究中，Accuracy 僅作為輔助指標，而非主要判斷標準。

精確率衡量模型預測為某一類別的樣本中，有多少比例實際屬於該類別，可表示為：

$$\text{Precision} = \frac{TP}{TP + FP}$$

召回率衡量某一實際類別中，有多少比例被模型正確辨識，可表示為：

$$\text{Recall} = \frac{TP}{TP + FN}$$

Precision 關注的是「模型預測為某類時有多準」，Recall 關注的是「某一實際類別有多少被模型抓出來」。在本研究中，Recall 對少數類別特別重要，因為若勝訴或部分勝訴案件大多被誤判為敗訴，即使整體 Accuracy 較高，模型仍無法有效辨識少數裁判結果。

F1-score 為 Precision 與 Recall 的調和平均，可表示為：

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

F1-score 同時考量 Precision 與 Recall。當其中任一指標偏低時，F1-score 也會受到影響。因此，相較於單獨觀察 Precision 或 Recall，F1-score 較適合用來評估模型對單一類別的整體辨識能力。

由於本研究為 Lose、Mixed、Win 三類裁判結果分類，若僅觀察整體 Accuracy，容易忽略模型對少數類別的辨識困難。因此，本研究採用 Macro F1 作為主要評估指標。Macro F1 係先分別計算各類別之 F1-score，再取平均，可表示為：

$$\text{Macro F1} = \frac{1}{C} \sum_{c=1}^C F1_c$$

其中， C 代表類別數。本研究共有 Lose、Mixed 與 Win 三類，因此 $C = 3$ 。Macro F1 對每一個類別給予相同權重，不會因 Lose 類別樣本數較多而使整體評估結果過度偏向多數類別。因此，相較於 Accuracy，Macro F1 較能反映模型在三類裁判結果上的平均辨識能力。

除上述數值指標外，本研究亦透過混淆矩陣觀察模型錯誤分類型態。混淆矩陣可顯示實際類別與預測類別之間的對應關係，使研究者能進一步判斷模型是否傾向將 Mixed 或 Win 誤判為 Lose，或是否在特定類別之間產生系統性混淆。透過 Accuracy、Macro F1、各類別 Precision、Recall、F1-score 與混淆矩陣的搭配，本研究得以更完整評估模型表現，而非僅依單一指標判斷模型是否有效。

3.8.6 本研究各方法之功能與流程比較

為整理本研究之模型設計，表 3-7 彙整本文所使用之主要方法，包含文字特徵表示、特徵選擇、監督式特徵轉換、分類器、對照流程與基準模型。此表之目的在於說明各方法在研究流程中的位置，並釐清各方法之輸入、輸出與主要功能。

表 3-7 本研究各方法之功能與流程比較

方法	流程角色	輸入資料	輸出與主要功能
BoW	文字特徵表示	斷詞後裁判文本	建立文件—詞彙矩陣，保留詞彙原始出現次數
TF	文字特徵表示	詞彙出現次數	將詞彙次數轉換為相對詞頻，降低裁判書長度差異影響
TF-IDF	文字特徵表示	詞頻與文件頻率	形成加權詞彙矩陣，降低常見詞權重並強化相對具區辨力詞彙
Chi-square	特徵選擇	文字特徵矩陣與裁判結果標籤	選取前 K 個與 Lose、Mixed、Win 較相關之詞彙特徵
MNIR	監督式特徵轉換	卡方篩選後文字特徵與裁判結果標籤	透過 inverse regression 將高維文字特徵轉換為充分縮減分數
Gamma-Lasso	MNIR 估計機制	MNIR 詞彙負載參數	正則化詞彙負載矩陣，壓縮雜訊詞彙並穩定高維參數估計
SVM	分類器	稀疏文字特徵或 MNIR 充分縮減分數	將裁判書分類為 Lose、Mixed、Win
Direct SVM	對照流程	卡方篩選後稀疏文字特徵	不經 MNIR 轉換，直接以 SVM 進行裁判結果分類
Majority Class baseline	最低基準模型	訓練集類別分布	全部預測為多數類別，用以檢查模型是否超越單純多數類別預測

由表 3-7 可知，本研究方法流程可分為三個層次。第一層為 BoW、TF 與 TF-IDF 之文字特徵表示，其功能是將非結構化裁判文本轉換為模型可處理之數值矩陣。第二層為 Chi-square 與 MNIR 之特徵選擇與特徵轉換，其中 Chi-square 用以篩選與裁判結果較相關之詞彙，MNIR 則進一步透過 inverse regression 將高維文字特徵轉換為低維充分縮減分數。第三層為 SVM 分類器、Direct SVM 對照流程與 Majority Class baseline，用以檢驗模型是否能有效區分 Lose、Mixed 與 Win 三類裁判結果。

整體而言，本研究並非單獨檢驗某一項方法，而是比較不同方法組合所形成的完整分類

流程。Chi-square + MNIR + SVM 流程用以檢驗 MNIR 監督式特徵轉換是否能帶來額外分類增益；Chi-square + Direct SVM 流程則作為不經 MNIR 轉換之對照基準；Majority Class baseline 則作為最低比較標準，用以判斷模型是否僅依賴多數類別分布。透過此一設計，本研究得以比較不同文字特徵表示、降維方法與分類流程對智慧財產權裁判結果分類表現之影響。

3.9 資料切分與參數選擇

本研究首先依案件類型將資料區分為行政、民事、刑事與刑事附帶民事四個資料集，並分別進行後續模型建構與評估。由於四類案件在樣本數、法律用語、裁判邏輯與裁判結果分布上皆可能存在差異，本文並未將所有案件合併為單一資料集後再進行切分，而是針對各案件類型分別建立模型，以便比較不同案件類型下之分類表現。

在資料切分前，本研究已先針對各案件類型資料集建立 BoW、TF 與 TF-IDF 之文件一詞項矩陣 (Document-Term Matrix, DTM)。亦即，文字特徵表示係先於各案件類型資料集中完成，將裁判文本轉換為模型可處理之數值矩陣。因此，本文不將 BoW、TF 與 TF-IDF 之詞彙表建立描述為完全僅由訓練集估計，而是明確區分「文件一詞項矩陣建立」與後續「模型訓練階段」之處理流程。

整體資料處理與切分流程可表示為：

Case Type Dataset → DTM Construction → 70: 10: 20 Split
→ (Training Set, Validation Set, Test Set)

其中，Case Type Dataset 代表行政、民事、刑事與刑事附帶民事四類案件資料集；DTM Construction 代表分別建立 BoW、TF 與 TF-IDF 文件一詞項矩陣；70: 10: 20 Split 則代表將各案件類型資料集切分為訓練集、驗證集與測試集。

進入模型訓練階段後，本研究僅使用訓練集估計卡方特徵選擇、MNIR 特徵轉換模型與 SVM 分類器。具體而言，卡方特徵選擇係以訓練集資料計算各詞彙特徵與裁判結果標籤之關聯，並選取前 K 個特徵；MNIR 模型亦以訓練集之卡方篩選後特徵與裁判結果標籤進行估計；SVM 分類器則使用訓練集特徵進行分類模型訓練。驗證集與測試集不參與上述卡方特徵選擇規則、MNIR 模型或初始 SVM 分類器之估計，而是套用由訓練集得到的特徵選擇與模型轉換規則。

本研究之模型訓練與參數選擇流程可表示為：

Training Set → Chi-square Select K → Model Training → Validation Macro F1
→ Select Best (K, C)

其中，Chi-square Select K 代表依卡方統計量選取前 K 個詞彙特徵；Model Training 代表依不同流程進行 MNIR + SVM 或 Direct SVM 模型訓練；Validation Macro F1 代表以驗證集之 Macro F1 作為模型選擇依據；Select Best (K, C) 則代表選出最佳卡方特徵數 K 與 SVM 懲罰參數 C 。

在選出最佳 K 與 C 後，本研究再使用訓練集與驗證集合併後的資料重新訓練最終 SVM 模型，並以測試集進行最終評估。此流程可表示為：

Training Set + Validation Set → Final Model Training → Test Set → Final Evaluation

其中，Final Evaluation 包含 Accuracy、Macro F1、Precision、Recall、F1-score 與混淆矩陣。

測試集不參與特徵選擇、MNIR 模型估計、SVM 訓練，也不參與 K 或 C 的選擇。換言之，測試集僅作為最終模型評估資料，用以檢驗模型在未參與模型選擇過程之資料上的分類表現。因此，本文在資料洩漏議題上採取較保守之表述：由於文件一詞項矩陣已於資料切分前依案件類型建立，本文不主張所有文字特徵建構步驟皆完全由訓練集估計；但在模型訓練與模型選擇階段，卡方特徵選擇、MNIR 特徵轉換、SVM 估計與超參數選擇皆未使用測試集進行估計或調整。

透過上述流程，本文得以在各案件類型中比較不同文字特徵表示、MNIR + SVM 與 Direct SVM 兩種模型流程之分類表現，並以測試集結果作為最終模型效能評估依據。

3.10 小結

本章說明本研究之資料來源、樣本篩選、文字特徵建構、特徵選擇、模型流程與評估方式。首先，本研究以司法院資料開放平台之裁判書資料為基礎，透過智慧財產權相關關鍵字與案件字別篩選研究樣本，並將案件類型區分為行政、民事、刑事與刑事附帶民事四類。由於不同案件類型在法律性質、訴訟目的、裁判用語與裁判結果分布上皆具有差異，本文分別建立模型進行比較，而非將所有案件合併為單一資料集。

其次，本研究將裁判結果整理為 Lose、Mixed 與 Win 三類，並排除無法明確歸類之案件，以建立適合模型訓練之有效樣本。在文字處理方面，本文先進行文本清理、停用詞移除與中文斷詞，再分別建立 BoW、TF 與 TF-IDF 三種文件一詞項矩陣。三種特徵表示皆用於將非結構化裁判文本轉換為可供機器學習模型處理的數值資料，但其特徵權重邏輯有所不同：BoW 保留詞彙原始出現次數，TF 調整詞彙在單篇裁判書中的相對頻率，TF-IDF 則進一步降低常見詞彙權重並強化較具區辨力之詞彙。

再者，本文採用卡方特徵選擇作為文字特徵篩選方法，目的在於從高維詞彙矩陣中選出與裁判結果標籤較具關聯之詞彙特徵。完成卡方篩選後，本研究進一步比較兩條模型流程：第一條為 Chi-square+MNIR+SVM，亦即透過 MNIR 將卡方篩選後的高維文字特徵轉換為充分縮減分數，再輸入 SVM 進行分類；第二條為 Chi-square+Direct SVM，亦即不經 MNIR 轉換，直接將卡方篩選後之稀疏文字特徵輸入 SVM。透過此一設計，本文可檢驗 MNIR 監督式特徵轉換是否能在本研究資料中帶來額外分類增益。

最後，本研究依案件類型分別進行資料切分與參數選擇。文件一詞項矩陣係於資料切分前依各案件類型建立；進入模型訓練階段後，卡方特徵選擇、MNIR 模型估計與 SVM 分類器訓練則以 Training Set 為基礎進行，Validation Set 用於選擇卡方特徵數 K 與 SVM 懲罰參數 C ，Test Set 則僅用於最終模型評估。在評估指標方面，由於本研究資料具有明顯類別不平衡，本文不僅觀察 Accuracy，也以 Macro F1、各類別 Precision、Recall、F1-score 與混淆矩陣分析模型表現，以避免僅依整體準確率高低判斷模型是否有效。

綜合而言，本章建立了後續實證分析的完整方法基礎。第四章將依據本章所述流程，分別呈現 MNIR + SVM 與 Direct SVM 在四類智慧財產權案件中的分類結果，並進一步比較不同文字特徵表示與不同模型流程對裁判結果分類表現之影響。



第四章 研究結果與分析

4.1 實驗設定與評估邏輯

依據第三章之模型流程，針對行政、民事、刑事與刑事附帶民事四類智慧財產權判決資料集進行裁判結果三分類實驗。本文比較兩條模型流程：其一為 Chi-square + MNIR + SVM，亦即先以卡方統計量進行特徵選擇，再透過 MNIR 進行監督式特徵轉換，最後以 SVM 分類；其二為 Chi-square + Direct SVM，亦即不經 MNIR 轉換，直接以卡方篩選後之稀疏文字特徵訓練 SVM。前者用以檢驗 MNIR 監督式特徵轉換是否能改善高維法律文本分類，後者則作為直接對照流程。

本章統一採用「移除明顯裁判結果詞彙後」之文本版本作為主要實證結果。換言之，本章結果代表在排除「駁回」、「有理由」、「准許」、「撤銷」等可能直接揭露裁判結果之詞彙後，模型流程與文字特徵表示之相對表現。此設定有助於降低模型直接依賴結果詞彙進行分類的疑慮，並在相同文本處理條件下比較 MNIR + SVM、Direct SVM 以及 BoW、TF、TF-IDF 之差異。不過，此版本仍不能保證完全排除所有資料洩漏可能，因為法律文本中仍可能存在間接反映裁判結果的語境、請求類型或裁判理由線索。

模型訓練與評估採固定資料切分：訓練集用於模型估計與特徵選擇，驗證集用於選擇卡方特徵數 K 與 SVM 參數 C，測試集則僅用於最後模型表現評估。換言之，第四章各表所列 Accuracy 與 Macro F1，均為模型在測試集上的結果；參數選擇則依驗證集 Macro F1 進行。

第三章之樣本分布已顯示，Lose、Mixed 與 Win 三類裁判結果並非均衡分布，因此本章以 Macro F1 作為主要判斷依據。若僅使用 Accuracy，模型可能因偏向預測多數類別而取得較高準確率，卻無法有效辨識少數類別。因此，本章除報告 Accuracy 與 Macro F1 外，也納入類別層級 F1-score 與混淆矩陣，以揭露模型在少數類別上的限制；最低基準模型則於 4.3 Direct SVM 對照流程中一併說明。

本章並非僅呈現模型分數，而是以 Macro F1 為主要依據，依序檢驗六項問題：第一，MNIR + SVM 核心流程之分類表現；第二，Direct SVM 對照流程是否具備競爭力；第三，MNIR 特徵轉換是否帶來額外增益；第四，不同文字特徵表示是否影響分類表現；第五，在移除明顯裁判結果詞彙後，模型結果應如何界定；第六，模型錯誤是否集中於特定裁判結果類別。

4.2 MNIR + SVM 核心流程之模型表現

表 4-1 呈現 Chi-square + MNIR + SVM 於四類資料集之最佳測試結果。根據表 4-1，MNIR + SVM 在不同案件類型下之 Macro F1 介於 0.318 至 0.545，其中刑事附帶民事資料集表現最高，Macro F1 為 0.545；行政資料集最低，Macro F1 為 0.318。此結果應與第三章所呈現之類別不平衡現象一併解讀，因為高 Accuracy 不必然代表模型能均衡辨識三類裁判結果。

表 4-1 Chi-square + MNIR + SVM 於各資料集之最佳表現

資料集	MNIR 最佳特徵	K	C	Accuracy	MNIR + SVM Macro F1
行政	BoW	5000	0.0625	0.875	0.318
民事	TF-IDF	1000	0.125	0.695	0.353
刑事	TF-IDF	5000	0.125	0.928	0.390
刑事附帶民事	TF	1000	0.125	0.823	0.545

從表 4-1 的 Accuracy 與 Macro F1 落差可看出，MNIR + SVM 在部分資料集雖取得較高 Accuracy，但 Macro F1 並未同步提升。例如行政與刑事資料集之 Accuracy 分別為 0.875 與 0.928，但 Macro F1 僅為 0.318 與 0.390。結合第三章之標籤分布可知，這類落差主要反映類別不平衡下 Accuracy 容易受多數類別影響，因此上述結果不宜解讀為模型已能均衡辨識敗訴、部分勝訴與勝訴三類裁判結果。

相較之下，刑事附帶民事資料集之 Macro F1 達 0.545，表示 MNIR + SVM 在該資料集上的三類平均表現相對較高。不過，此處僅為整體 Macro F1 比較，尚不能代表三個裁判結果類別皆被穩定辨識，仍需於後續錯誤分析中進一步檢視各類別表現。

整體而言，MNIR + SVM 可形成可執行的分類流程，但其 Macro F1 表現仍受到資料類別不平衡與案件類型差異影響。因此，MNIR + SVM 的結果尚未能單獨支持 MNIR 特徵轉換具有穩定增益；若要判斷 MNIR 是否改善分類效果，仍需與不經 MNIR 轉換之 Direct SVM 對照流程進行比較。

4.3 Direct SVM 對照流程之模型表現

本節進一步呈現 Chi-square + Direct SVM 對照流程之表現。Direct SVM 不經 MNIR 特徵轉換，而是直接使用卡方篩選後的稀疏文字特徵訓練 SVM，因此可作為檢驗 MNIR 轉換

是否帶來額外增益的對照基準。

本研究另設置 Majority Class baseline 作為最低基準模型。Majority Class baseline 是指模型不根據文本內容進行判斷，而是一律預測訓練資料中樣本數最多的裁判結果類別。若 Direct SVM 僅略高於或接近此基準，代表模型可能只是受到多數類別分布影響；若明顯高於此基準，則表示模型至少學習到部分文本分類訊息。

表 4-2 呈現 Chi-square + Direct SVM 於各資料集之最佳表現。Direct SVM 在四類資料集中的 Macro F1 介於 0.380 至 0.654，且皆高於 Majority Class baseline。其中，刑事附帶民事資料集之 Macro F1 最高，為 0.654；刑事資料集次之，為 0.577；民事與行政資料集分別為 0.428 與 0.380。

表 4-2 Chi-square + Direct SVM 於各資料集之最佳表現

資料集	Direct 最佳特徵	Accuracy	Macro F1	Majority Macro F1
行政	BoW	0.831	0.380	0.311
民事	TF-IDF	0.680	0.428	0.269
刑事	TF	0.951	0.577	0.322
刑事附帶民事	BoW	0.854	0.654	0.245

與 Majority Class baseline 相比，四類資料集的 Direct SVM 皆有明顯提升。其中刑事附帶民事資料集由 0.245 提升至 0.654，刑事資料集由 0.322 提升至 0.577，顯示 Direct SVM 並非僅透過預測多數類別取得表面上的表現，而是能從文本詞彙中學習到與裁判結果相關的分類訊息。不過，此處仍僅代表 Direct SVM 作為對照流程之表現，是否優於 MNIR + SVM 仍需於下一節進行直接比較。

4.4 MNIR + SVM 與 Direct SVM 之整體流程比較

表 4-3 比較 Direct SVM 與 MNIR + SVM 在各資料集最佳設定下的 Macro F1。此比較的目的，是檢視在本研究目前的實驗設定下，加入 MNIR 監督式特徵轉換後，是否能相較於 Direct SVM 取得較佳表現。

需注意的是，表 4-3 比較的是兩個流程各自最佳設定下的整體表現。此處並非在完全控制相同特徵表示與參數後，單獨檢定 MNIR 的效果。因此，後續結果應解讀為兩種模型流程的整體比較。

表 4-3 Direct SVM 與 MNIR + SVM 之 Macro F1 比較

資料集	Direct 最佳特徵	Direct SVM Macro F1	MNIR 最佳特徵	MNIR + SVM Macro F1	Direct - MNIR
行政	BoW	0.380	BoW	0.318	0.062
民事	TF-IDF	0.428	TF-IDF	0.353	0.075
刑事	TF	0.577	TF-IDF	0.390	0.187
刑事附帶民事	BoW	0.654	TF	0.545	0.109




圖 4-1 Direct SVM 與 MNIR + SVM 之 Macro F1 比較

根據表 4-3，Direct SVM 在四類資料集的 Macro F1 均高於 MNIR + SVM。行政資料集差距為 0.062，民事資料集差距為 0.075，刑事資料集差距為 0.187，刑事附帶民事資料集差距為 0.109。

整體而言，四類資料集結果方向一致，顯示在本研究資料與超參數設定下，Direct SVM 對照流程較 MNIR + SVM 核心流程取得較佳分類表現。

此結果表示，在本研究目前的資料、標籤設定與超參數範圍下，MNIR 特徵轉換未呈現相較 Direct SVM 的額外分類增益。此一結果可從法律文本特性、特徵壓縮效果與高維稀疏表示三個面向加以理解。

第一，法律判決文本具有高度制度化與專業化的語言特性，許多詞彙本身即帶有明確的

法律程序、請求類型或裁判理由訊號。例如智慧財產權判決中常見的侵權、損害賠償、商標、著作權、專利範圍、行政處分、訴願決定等詞彙，可能已能反映不同案件類型與裁判結果之差異。

因此，在經過 Chi-square 特徵選擇後，Direct SVM 可直接利用這些具有判別力的稀疏詞彙特徵進行分類，不一定需要再透過 MNIR 將其轉換為低維表徵。此點也可與表 4-4 相互呼應：行政案件與刑事附帶民事案件中 BoW 表現相對較佳，顯示在部分法律文本情境下，詞彙是否出現或出現次數本身即具有重要分類訊號。

第二，MNIR 的優點在於將高維文字特徵轉換為較低維、與裁判結果相關的充分縮減分數；然而，降維本身也可能造成資訊壓縮的代價。

特別是在本研究的三類裁判結果分類任務中，Mixed 與 Win 類別樣本數相對較少，且其文字特徵可能較分散或與 Lose 類別重疊。若 MNIR 在轉換過程中主要保留能解釋整體類別差異的主要方向，部分屬於少數類別的細部詞彙訊號可能被壓縮或平滑，導致模型對少數類別的辨識能力未能提升，甚至使 Macro F1 下降。

換言之，MNIR 並非無效，而是在本研究資料結構下，其低維化過程可能未能完整保留少數類別所需的判別訊息。

第三，本研究結果也反映高維稀疏特徵與低維密集特徵在法律文本分類中的差異。一般而言，低維特徵有助於降低模型複雜度與雜訊，但法律文本中的分類訊號往往分散於大量專門詞彙、程序用語與請求語彙之中。

Direct SVM 保留卡方篩選後的高維稀疏結構，使模型仍能利用較多具體詞彙進行分類；相對地，MNIR 將這些詞彙訊號轉換為較少數的低維分數，雖然降低維度，但也可能犧牲部分細緻的法律語言差異。

因此，在本研究資料中，高維稀疏文字特徵反而較能保留裁判結果分類所需的資訊。

綜合而言，Direct SVM 優於 MNIR + SVM 的結果，不宜解讀為 MNIR 方法本身缺乏價值，而應限縮理解為：在本研究已先透過 Chi-square 篩選高關聯詞彙，且法律文本本身具有高度制度化關鍵詞訊號的情況下，直接使用稀疏文字特徵進行分類，較能保留與裁判結果相關的細部資訊。

此結果亦說明，在法律文本分類任務中，模型設計不應預設降維或特徵轉換必然優於傳統稀疏特徵，而應透過對照模型與類別層級結果進行檢驗。

4.5 不同文字特徵表示之影響

表 4-4 比較 Direct SVM 使用 BoW、TF 與 TF-IDF 三種文字特徵表示之 Macro F1。本文以同一文本版本與同一模型流程進行比較，目的在於降低文本版本與模型流程差異造成的干擾，並觀察文字特徵表示本身是否會影響分類表現。

表 4-4 Direct SVM 下 BoW、TF、TF-IDF 之 Macro F1

資料集	BoW	TF	TF-IDF
行政	0.380	0.341	0.375
民事	0.403	0.417	0.428
刑事	0.564	0.577	0.562
刑事附帶民事	0.654	0.580	0.572




圖 4-2 不同文字特徵表示之 Macro F1 比較

根據表 4-4，三種文字特徵表示並不存在單一方法在所有資料集皆最佳。行政資料集以 BoW 表現最佳，Macro F1 為 0.380，但與 TF-IDF 的 0.375 差距很小。民事資料集以 TF-IDF 表現較佳，Macro F1 為 0.428。刑事資料集以 TF 表現較佳，Macro F1 為 0.577。刑事附帶民事資料集則以 BoW 表現最佳，Macro F1 為 0.654。

此結果顯示，不同案件類型下，較適合的文字特徵表示並不完全一致。因此，法律文本分類不宜預設某一種文字表示必然優於其他方法。文字特徵表示的效果，仍須依案件類型與

資料特性加以檢驗。

不過，部分資料集中不同特徵表示之差距有限。因此，本文不宜過度解讀單一特徵表示的優劣。例如行政資料集中，BoW 與 TF-IDF 表現接近。刑事資料集中，TF、BoW 與 TF-IDF 的差距也不大。相較之下，刑事附帶民事資料集中，BoW 明顯高於 TF 與 TF-IDF。這表示在該資料集中，原始詞頻或詞項出現資訊，可能更能保留與裁判結果相關的分類訊號。

就可能解釋而言，三種文字特徵表示的差異可從以下三點理解。

第一，BoW 保留詞彙是否出現或出現次數的資訊。若某些案件類型的分類訊號主要來自程序用語、請求類型、案件事實描述或法律爭點詞彙，則 BoW 可能已足以捕捉重要分類訊號。行政案件與刑事附帶民事案件中 BoW 表現較佳，可能即與此有關。

第二，TF 可反映詞彙在單一文本中的相對出現比例。相較於 BoW，TF 較能降低文本長度差異對原始詞頻的影響。因此，若刑事案件中的分類訊號與特定犯罪事實、行為描述或法律用語的相對出現比例有關，TF 便可能取得較佳表現。

第三，TF-IDF 會提高相對稀有詞彙的權重。民事智慧財產權案件常涉及特定權利主張、損害賠償、技術爭點或法律概念。這些詞彙未必在所有文件中頻繁出現，但可能具有較高判別力。因此，TF-IDF 可能有助於強化民事案件中較具專屬性的分類訊號。


綜合而言，BoW、TF 與 TF-IDF 的差異並非單純技術選擇，而是反映不同案件類型中，裁判結果訊號的來源不同。若分類訊號主要來自詞彙是否出現，BoW 可能較適合。若分類訊號來自詞彙出現比例，TF 可能較有優勢。若分類訊號來自相對稀有但具判別力的詞彙，TF-IDF 則可能較具效果。

不過，本文尚未進一步檢視各模型之高權重詞彙。因此，上述解釋仍屬可能推論。後續研究可透過高卡方詞彙、SVM 權重或特徵重要性分析，進一步驗證不同文字特徵表示所捕捉到的法律詞彙訊號。

4.6 參數選擇與驗證集表現

表 4-5 呈現各資料集最佳 Direct SVM 模型之參數選擇摘要。四類資料集之最佳 K 與 C 並不相同，顯示不同案件類型所需的特徵數與 SVM 懲罰參數有所差異。行政資料集最佳 K 為 3000，民事與刑事資料集最佳 K 均為 5000，刑事附帶民事資料集最佳 K 則為 3000。

表 4-5 各資料集最佳 Direct SVM 模型之參數選擇摘要



資料集	K	Selected Features	Best C	Validation Macro F1
行政	3000	3000	4.0	0.385
民事	5000	5000	4.0	0.463
刑事	5000	5000	4.0	0.515
刑事附帶民事	3000	3000	0.0625	0.745

圖 4-3 Direct SVM 之 K x C 驗證集 Macro F1 熱力圖

根據表 4-5，模型參數並非以單一固定值套用於所有資料集，而是依各資料集之 validation Macro F1 選擇。刑事附帶民事資料集在驗證集上取得最高 Validation Macro F1 (0.745)，並於測試集取得最高 Macro F1 (0.654)，顯示其在此次資料切分下，驗證集與測試集表現皆相對較高。相對而言，行政資料集最佳 Validation Macro F1 僅為 0.385，測試集 Macro F1 為 0.380，顯示其分類任務相對較困難，且少數類別辨識可能受到更大限制。

不過，此表僅能說明各資料集最佳模型之參數選擇結果，不能直接推論所有資料集皆具有相同最佳 K 與 C。圖 4-3 進一步呈現各資料集在不同 K 與 C 組合下之 validation Macro F1，紅框標示各資料集之最佳組合；若要更完整檢驗參數結果是否穩定，仍需搭配重複隨機切分或交叉驗證進行確認。

4.7 錯誤分析與少數類別限制

本節以民事案件作為詳細錯誤分析對象，主要原因有二。

第一，民事案件測試集中，Lose、Mixed 與 Win 三類皆具有一定樣本數。因此，較適合觀察模型是否偏向多數類別，也較能分析 Mixed 與 Win 被誤判的情形。

第二，民事智慧財產權案件常涉及侵權責任、損害賠償、權利歸屬與商業利益衝突。其裁判結果較容易連結當事人之經濟利益，因此具有實務與經濟解讀意義。

民事案件中，最佳 Direct SVM 模型雖高於 Majority Class baseline，但 Macro F1 僅為 0.428。這表示模型雖具一定分類能力，但仍存在明顯類別辨識限制。該模型採用移除明顯裁判結果詞彙後之文本版本，並使用 TF-IDF 特徵。其測試集 Accuracy 為 0.680，Macro F1 為 0.428。表 4-6 為測試集混淆矩陣，表 4-7 為分類報告。

表 4-6 民事案件最佳 Direct SVM 模型之測試集混淆矩陣

實際\預測	Predicted Lose	Predicted Mixed	Predicted Win
Actual Lose	683	77	6
Actual Mixed	192	80	9
Actual Win	62	17	7

表 4-7 民事案件最佳 Direct SVM 模型之分類報告

類別	Precision	Recall	F1-score	Support
Lose	0.729	0.892	0.802	766
Mixed	0.460	0.285	0.352	281
Win	0.318	0.081	0.130	86
macro avg	0.502	0.419	0.428	1133
weighted avg	0.631	0.680	0.639	1133

根據表 4-6，民事案件模型主要能正確辨識 Lose 類別。Actual Lose 共有 766 件，其中 683 件被正確預測為 Lose，Recall 達 0.892。

相較之下，Mixed 與 Win 類別表現明顯較弱。Actual Mixed 共有 281 件，僅 80 件被正確預測為 Mixed，另有 192 件被誤判為 Lose。Actual Win 共有 86 件，僅 7 件被正確預測為 Win，另有 62 件被誤判為 Lose。

此結果顯示，模型在民事案件中明顯傾向預測 Lose 類別。換言之，Mixed 與 Win 類別容易被歸入敗訴。

表 4-7 亦呈現相同現象。Lose 類別 F1-score 為 0.802，明顯高於 Mixed 類別的 0.352 與 Win 類別的 0.130。尤其 Win 類別 Recall 僅為 0.081，表示實際勝訴案件中，只有極少比例能被模型成功辨識。

因此，民事案件模型雖然整體 Accuracy 達 0.680，且高於 Majority Class baseline，但其分類能力主要來自 Lose 類別。對於 Mixed 與 Win 這兩類較少數且語意界線較模糊的裁判結果，模型仍存在明顯辨識限制。

進一步而言，Mixed 與 Win 類別辨識困難，可能來自以下三個原因。

一、 Mixed 類別本身具有高度異質性。

Mixed 代表部分勝訴，但部分勝訴可能包含多種情形。例如，法院可能僅就部分請求、部分損害賠償金額、部分權利範圍，或部分當事人與部分爭點作成不同判斷。

這些案件雖然同樣被整理為 Mixed，但其法律意義與文本特徵未必一致。因此，模型較難學習到穩定的 Mixed 類別訊號。

二、 不同裁判結果之間可能共享相似法律詞彙。

本研究已移除「駁回」、「有理由」、「准許」、「撤銷」等明顯裁判結果詞彙，以降低模型直接依賴結果詞彙進行分類的可能。然而，移除這些詞彙後，判決文本中仍保留大量案件事實、雙方主張、證據攻防、法律要件與法院理由。

由於不同裁判結果的案件可能涉及相同法律爭點與相似權利主張，例如侵權認定、損害賠償、權利範圍、商標近似或著作利用等問題，因此即使最終裁判結果不同，文本中仍可能出現高度相似的法律詞彙。若模型主要依賴詞彙分布進行分類，便可能難以區分 Lose、Mixed 與 Win。

三、法院判決書的寫作方式會增加分類難度。

裁判書通常不是單純呈現最終勝敗，而是依序記載當事人主張、爭點整理、證據資料、法院認定與法律適用。當明顯裁判結果詞彙被移除後，模型可依賴的訊號更偏向間接的爭點描述與理由結構。

然而，這些間接訊號未必能穩定對應至特定裁判結果。尤其 Mixed 類別可能同時包含多個爭點與多種判斷方向，使文本特徵呈現混合狀態。因此，模型更容易將其歸入樣本數較多且語言模式較穩定的 Lose 類別。

綜合而言，本研究之少數類別辨識限制，不能僅解讀為模型分數不足。此一結果也反映法律標籤、文本語意與法院寫作方式共同造成的分類困難。

尤其 Mixed 類別並非單一明確結果，而是由多種部分成立與部分不成立的裁判型態組成。Win 類別則因樣本數較少，且與其他類別共享大量法律詞彙，使模型難以形成穩定判別邊界。

因此，後續研究若欲提升少數類別表現，除處理類別不平衡外，也可進一步細分部分勝訴型態。亦可結合判決理由段落、請求項目與裁判主文等更細緻的文本結構資訊。

表 4-8 各資料集最佳 Direct SVM 模型之類別 F1 摘要

資料集	Lose F1	Mixed F1	Win F1	Macro F1
行政	0.908	0.114	0.119	0.380
民事	0.802	0.352	0.130	0.428
刑事	0.974	0.167	0.591	0.577
刑事附帶民事	0.834	0.878	0.250	0.654

表 4-8 進一步摘要各資料集最佳 Direct SVM 模型之類別 F1。結果顯示，少數類別辨識不足並非僅出現在民事案件，而是存在於多數資料集。

行政、民事與刑事附帶民事資料集的 Win 類別 F1 分別僅為 0.119、0.130 與 0.250。刑事資料集雖然 Win 類別 F1 較高，達 0.591，但 Mixed 類別 F1 僅為 0.167。

這表示不同案件類型的困難類別並不完全相同。不過整體而言，模型對樣本數較少或語意特徵較不明顯的裁判結果類別，仍較難辨識。

因此，本研究不能將模型過度解讀為已能完整預測所有裁判結果。較精確地說，模型在主要類別上具有一定分類能力，但對少數類別仍存在明顯限制。尤其在部分資料集中，Win 或 Mixed 類別仍是模型最難辨識的結果類別。

未來若要提升模型對少數裁判結果的辨識能力，可從三個方向著手。第一，可加入類別權重以降低模型偏向多數類別的問題。第二，可使用重抽樣方法改善少數類別資料不足。第三，可針對少數類別進行更細緻的錯誤案例分析，以釐清模型誤判的主要文本來源。

4.8 小結

本章結果顯示，在移除明顯裁判結果詞彙後之文本版本下，Chi-square + MNIR + SVM 可形成一套可執行的智慧財產權判決文本分類流程；然而，在本研究資料與超參數設定下，MNIR + SVM 未相較 Direct SVM 帶來額外增益。

四類資料集中，Direct SVM 皆取得高於 MNIR + SVM 的 Macro F1，顯示卡方特徵選擇後之稀疏文字特徵已保留相當程度的分類訊息。此結果可能與法律文本的制度化語言特性有關：許多法律程序用語、請求類型與裁判理由詞彙本身即具有分類訊號，使 Direct SVM 能直接利用高維稀疏詞彙特徵進行分類。

相對地，MNIR 雖能將高維文本轉換為低維充分縮減分數，但在類別不平衡與少數類別訊號較弱的情況下，降維過程可能壓縮部分 Mixed 或 Win 類別的細部詞彙訊息，因而未能提升 Macro F1。

此一限制不僅來自少數類別樣本數不足，也與部分勝訴標籤本身的異質性、Win 與 Mixed 類別和 Lose 類別共享相似法律詞彙，以及法院判決書同時呈現雙方主張與多重裁判理由的寫作方式有關。因此，少數類別辨識困難可視為法律文本分類任務中的結構性問題，而非單純的模型調參問題。

不同文字特徵表示方面，BoW、TF 與 TF-IDF 並無單一方法在所有資料集皆最佳。行政與刑事附帶民事資料集以 BoW 表現相對較佳，民事資料集以 TF-IDF 表現相對較佳，刑事資料集則以 TF 表現相對較佳。此結果說明，法律文本分類需依案件類型與資料特性選擇文字表示方式，而不宜預設單一特徵表示必然最佳。

由於本章統一採用移除明顯裁判結果詞彙後之文本版本，結果解讀應限縮於此一文本處理條件下，不應進一步宣稱模型已完全排除所有資料洩漏可能。

最後，民事案件錯誤分析顯示，模型主要能辨識 Lose 類別，但對 Mixed 與 Win 類別仍存在明顯限制。民事案件最佳 Direct SVM 模型雖高於 Majority Class baseline，但 Mixed 類別 F1-score 僅為 0.352，Win 類別 F1-score 僅為 0.130，且 Win recall 僅為 0.081。

整體而言，本研究模型可被理解為在主要類別上具有一定分類能力，但尚不能被解讀為已能完整預測所有裁判結果。關於本研究結果與既有法律文本分類文獻之異同比較，將於第五章進一步討論。



第五章 結論與建議

5.1 研究結論

本研究以臺灣智慧財產權相關裁判書為研究對象，透過文字探勘與機器學習方法，建立裁判結果分類模型，並將裁判結果整理為敗訴、部分勝訴與勝訴三類。本研究進一步依案件類型將資料區分為行政、民事、刑事與刑事附帶民事案件，分別檢驗不同案件類型下模型之分類表現。此一設計使本研究不僅能觀察整體模型表現，也能進一步檢視模型在不同裁判結果類別上的辨識能力，尤其是部分勝訴與勝訴等樣本數較少、語意界線可能較不明確之類別。

既有法律判決預測文獻中，確有研究採用二元結果設定，例如歐洲人權法院案件中是否違反公約條文之預測，或智慧財產權訴訟中專利權人勝訴與被告勝訴之預測。惟法律判決預測任務本身並不限於二元分類，亦包含法條預測、罪名預測、刑期預測、多標籤分類與多任務學習等形式。因此，本研究並不主張過去文獻皆以二元分類為主，而是聚焦於臺灣智慧財產權判決文本脈絡下，建立敗訴、部分勝訴與勝訴三類裁判結果之分類流程，並分析模型在不同案件類型與不同結果類別上的辨識差異。

本研究首先以 Chi-square + MNIR + SVM 作為核心技術流程，目的在於檢驗 MNIR 監督式特徵轉換是否能將高維法律文本特徵轉換為較具判別力的低維表示，進而改善裁判結果分類。然而，實證結果顯示，在本研究資料、標籤設定與超參數範圍下，MNIR + SVM 雖可形成一套可執行的分類流程，但未相較於 Chi-square + Direct SVM 取得更佳表現。

四類案件資料集中，Direct SVM 的 Macro F1 皆高於 MNIR + SVM，顯示卡方特徵選擇後的稀疏文字特徵已保留相當程度與裁判結果相關的分類訊息。因此，本研究並不將此結果解讀為 MNIR 方法本身無效，而是指出在本研究任務中，直接使用篩選後之高維稀疏詞彙特徵，反而較能保留分類所需訊息。

其次，不同文字特徵表示在不同案件類型下呈現不同效果。BoW、TF 與 TF-IDF 並無單一方法在所有案件類型中皆為最佳。行政與刑事附帶民事案件中，BoW 表現相對較佳；民事案件中，TF-IDF 表現相對較佳；刑事案件中，TF 表現相對較佳。此結果說明，法律文本分類不宜預設某一種文字表示必然優於其他方法，而應依案件類型、文本結構與詞彙分布進行比較。

最後，錯誤分析顯示，模型主要限制並非整體分數不足，而是少數類別辨識能力有限。以民事案件為例，模型對敗訴類別具有較佳辨識能力，但對部分勝訴與勝訴類別表現明顯較弱。

混淆矩陣顯示，許多 Mixed 與 Win 樣本被誤判為 Lose，表示模型仍有偏向多數類別的傾向。此結果說明，即使模型整體 Accuracy 與 Macro F1 高於基準模型，也不能直接解讀為模型已能完整預測所有裁判結果。較精確地說，本研究模型能在主要類別上形成一定分類能力，但對少數且語意界線較模糊的裁判結果仍存在明顯限制。

5.2 研究貢獻

本研究之貢獻可分為三個層面：理論貢獻、方法貢獻與實務貢獻。

第一，在理論貢獻方面，本研究補充法律文本分類與智慧財產權判決結果預測之相關研究。本文不僅檢驗模型能否分類裁判結果，也比較不同案件類型、文字特徵表示與模型流程之差異。研究結果顯示，BoW、TF 與 TF-IDF 並無單一方法在所有案件類型中皆為最佳。這表示法律文本分類效果會受到案件性質、文本結構與詞彙分布影響。因此，法律文本分類不宜預設單一特徵表示或模型流程必然適用於所有案件，而應依據案件類型與資料特性進行比較。此外，本研究亦檢驗 MNIR 監督式特徵轉換在中文智慧財產權判決文本分類中的適用性。MNIR 理論上可利用裁判結果反推詞彙分布方向，並將高維文字特徵轉換為低維表徵。然而，本研究結果顯示，在卡方特徵選擇已先保留高關聯詞彙的情況下，MNIR + SVM 未優於 Direct SVM。此結果表示，在本研究資料、標籤設定與超參數範圍下，MNIR 的降維優勢並未轉化為較佳分類效果。相對地，卡方篩選後的高維稀疏詞彙特徵仍具有重要分類價值。因此，本研究對 MNIR 在中文智慧財產權判決文本分類中的適用條件與限制，提供了具體經驗證據。

第二，在方法貢獻方面，本研究建立一套可重複執行的智慧財產權判決文本分類流程。

本文之 baseline pipeline 包含以下步驟：

- (一) 蒐集並篩選智慧財產權判決文本。
- (二) 進行文本清理、停用詞移除與中文斷詞。
- (三) 整理 Lose、Mixed 與 Win 三類裁判結果標籤。
- (四) 建構 BoW、TF 與 TF-IDF 文字特徵。
- (五) 使用 Chi-square 進行特徵選擇。
- (六) 比較 MNIR + SVM 與 Direct SVM 兩種模型流程。
- (七) 以 Majority Class baseline 作為最低比較基準。

此一流程的價值不僅在於建立分類模型，也在於提供後續研究清楚的比較基準。後續研究若加入新的模型、特徵轉換方法或文字表示方式，即可檢驗其是否真正帶來額外改善。同時，由於本研究資料存在類別不平衡，本文並未僅以整體準確率判斷模型表現。本文進一步

使用 Macro F1、分類報告與混淆矩陣，檢視模型在 Lose、Mixed 與 Win 三類結果上的辨識能力。此一評估方式有助於揭露 Mixed 與 Win 等少數類別的分類限制，避免模型因主要預測多數類別而被高估。

第三，在實務貢獻方面，本研究可作為智慧財產權判決文本整理與初步分類之參考。

公開裁判書數量龐大。若完全仰賴人工閱讀與標記，將耗費大量時間與人力。本研究建立之分類流程，可協助研究者或實務工作者對大量智慧財產權判決進行初步整理。此流程亦可用於掌握不同案件類型與裁判結果分布，並作為後續人工審查、實證法律研究或法律科技系統開發的基礎。此外，本研究亦提供模型選擇上的實務指引。在本研究資料條件下，不同案件類型可優先考慮以下模型流程：

一、行政案件：BoW + Chi-square + Direct SVM。

二、民事案件：TF-IDF + Chi-square + Direct SVM。

三、刑事案件：TF + Chi-square + Direct SVM。

四、刑事附帶民事案件：BoW + Chi-square + Direct SVM。

此結果顯示，法律文本分類不宜直接套用單一模型。較適當的作法，是依案件性質、文本結構與分類目的選擇合適方法。不過，本研究之實務貢獻仍應審慎界定。本文建立的是裁判結果分類之研究流程與方法基礎，而非可直接取代法律專業判斷的自動化決策工具。智慧財產權案件涉及技術事實、權利範圍、法律要件與法院裁量判斷。因此，模型分類結果仍應搭配人工審查與個案脈絡分析。本文較適合作為大量判決文本初步分類、研究樣本整理與法律科技系統開發之輔助基礎，而不宜直接作為個案勝敗預測或法律意見之依據。

綜合而言，本研究的貢獻不僅在於建立智慧財產權判決結果分類模型，更在於三個面向。理論上，本文說明不同文字特徵表示與 MNIR 監督式特徵轉換在法律文本分類中的適用差異。方法上，本文建立可重複比較的 baseline pipeline。實務上，本文提供大量判決文本初步分類與模型選擇之參考。

5.3 研究限制

本研究仍有以下限制。

第一，本文仍無法完全排除資料洩漏可能。

本研究雖已移除「駁回」、「有理由」、「准許」、「撤銷」等明顯裁判結果詞彙，以降低模型直接依賴結果詞彙的疑慮。然而，法律文本中仍可能存在間接線索。例如語境、請求類型、

程序狀態或裁判理由結構，皆可能反映裁判結果。因此，本研究結果應理解為「移除明顯結果詞彙後」的模型比較，而非完全排除所有結果線索後的預測效果。

第二，本研究資料存在類別不平衡問題。

部分案件類型中，Win 或 Mixed 樣本數相對較少。因此，模型較容易偏向預測 Lose 類別。即使本文以 Macro F1 作為主要評估指標，仍無法完全解決少數類別資料不足所造成的學習限制。尤其在民事案件錯誤分析中，Win 類別 recall 明顯偏低，顯示模型對少數類別仍有改善空間。

第三，裁判結果標籤可能存在邊界模糊。

本研究將裁判結果整理為 Lose、Mixed 與 Win 三類。然而，Mixed 類別代表部分勝訴，其內部可能包含多種情形。例如部分請求成立、部分損害賠償金額被支持、部分權利範圍被認定，或不同當事人、不同爭點之間出現不同判斷結果。

這些案件雖然皆被歸入 Mixed，但其法律意義與文本特徵未必一致。因此，模型對 Mixed 類別辨識較弱，除了受到樣本數影響外，也可能與標籤內部異質性有關。換言之，三類標籤設計有助於進行裁判結果分類，但仍無法完全呈現智慧財產權判決結果的細緻差異。

第四，本文尚未將裁判書不同段落完整分離。

本研究主要以裁判書全文作為模型輸入。雖然本文已移除明顯裁判結果詞彙，但尚未將案件事實、當事人主張、法院理由與裁判主文進行完整分離。因此，模型仍是在整體判決文本上學習分類訊號，而非僅依據案件事實或特定理由段落進行分析。

這表示文本中仍可能保留部分間接結果線索。例如程序狀態、爭點配置或理由結構。故本文結果較適合解讀為「判決文本分類」效果，而不宜直接解讀為模型僅依據案件事實即可預測裁判結果。後續研究若能分別使用案件事實、法院理由或主文前文本進行建模，將有助於更精確檢驗模型依賴哪些文本資訊。

第五，本文使用之稀疏文字特徵仍有語意限制。

本研究主要以 BoW、TF 與 TF-IDF 進行建模。此類方法具備可解釋性與計算效率，但較難捕捉長距離語意關係、事實脈絡與法理推論結構。智慧財產權判決常涉及技術事實、權利範圍解釋與法律要件判斷。若僅依靠詞彙分布，可能無法完整呈現法院裁判理由。

第六，MNIR 結果不宜過度推論。

本研究結果顯示，MNIR + SVM 未相較於 Direct SVM 取得較佳表現。然而，此結果應限縮於本文資料、標籤設定、文本處理方式與超參數範圍之下。本文不能據此推論 MNIR 在所有法律文本分類任務中皆不具效果。

若後續研究採用不同案件類型、不同標籤設計、不同特徵數設定、重複交叉驗證或其他下游分類器，MNIR 仍可能在特定資料情境下展現不同效果。

第七，本文採固定資料切分。

本研究使用固定訓練集、驗證集與測試集進行模型訓練與評估。此設計可建立清楚且可重複的實驗流程。然而，單次切分結果仍可能受到特定樣本分布影響。

若要進一步確認 Direct SVM 與 MNIR + SVM 之差異是否穩定，後續可加入重複隨機切分、交叉驗證或 bootstrap 重抽樣檢定。因此，本文目前之模型比較結果，應理解為固定資料切分下的實證結果，而非所有可能切分下皆必然成立的結論。

第八，本文資料限於公開裁判書。

本研究資料係以公開裁判書為主要來源。因此，本文僅能觀察最終進入裁判並形成裁判書之案件。實務上，部分智慧財產權紛爭可能透過和解、撤回或其他方式結束。此類案件通常不會完整呈現在裁判書資料中，也未必形成可供本文分類的明確裁判結果。

因此，本文模型分析的對象，主要是具有明確裁判結果的公開判決案件。本文尚未納入和解案件所反映的訴訟策略、風險評估與案件強弱訊息。此一限制表示，本研究結果不宜直接推論至所有智慧財產權紛爭，而應限縮於公開裁判書中具備明確裁判結果之案件。

5.4 研究結果之建議

根據第四章實證結果，本研究發現，在臺灣智慧財產權裁判結果分類任務中，模型表現不僅受到模型流程影響，也與案件類型、文字特徵表示方式、類別不平衡程度及少數類別辨識能力密切相關。尤其本研究結果顯示，在本研究資料、文本處理方式與超參數設定下，MNIR + SVM 流程並未相較於 Direct SVM 取得更佳表現；同時，不同案件類型下較適合的文字特徵表示亦不完全相同。此外，模型雖能在多數類別上取得一定分類能力，但對 Mixed 與 Win 等少數類別仍存在辨識不足的問題。

因此，本節將依據本研究結果提出方法選擇與應用建議。以下建議主要分為三個面向：第一，模型流程與基準模型之選擇；第二，不同案件類型下文字特徵表示方式之選擇；第三，後續研究與實務應用上應注意之問題，包括少數類別辨識、模型可解釋性、結果穩定性與模型應用範圍之限制。

5.4.1 對模型與特徵表示選擇之建議

根據本研究結果，後續進行智慧財產權判決文本分類時，建議先建立清楚且可重複的基準模型，再進一步檢驗其他特徵轉換方法是否能帶來額外改善。本研究比較 Chi-square + MNIR + SVM 與 Chi-square + Direct SVM 後發現，在四類案件資料集中，Direct SVM 的 Macro F1 皆高於 MNIR + SVM。此結果顯示，在本研究資料、標籤設定與超參數範圍下，MNIR 監督式特徵轉換並未相較於直接使用卡方篩選後之稀疏文字特徵取得更佳表現。然而，此結果不應被解讀為 MNIR 方法本身無效，而應限縮理解為：在本研究已先透過 Chi-square 特徵選擇篩選高關聯詞彙的情況下，卡方篩選後的稀疏文字特徵可能已保留相當程度的裁判結果分類訊號。此時，若再將特徵轉換為較低維的 MNIR 充分縮減分數，部分細部詞彙訊號或少數類別訊號可能被壓縮，因而未能進一步提升分類表現。因此，後續研究若欲使用 MNIR 或其他特徵轉換方法，仍應與 Direct SVM 等基準流程進行比較，而不宜預設特徵轉換必然改善模型表現。

因此，本文建議後續研究在選擇模型流程時，不宜僅依方法複雜度作為判斷依據，而應以明確的基準模型作為起點。就本研究資料而言，Chi-square + Direct SVM 可作為一個具可比較性的基準流程；若後續模型能在此基準之上進一步改善 Macro F1 與少數類別表現，才較能說明其確實具有額外方法價值。

5.4.2 對不同資料情境之模型選擇建議

除模型流程本身外，本研究結果亦顯示，不同案件類型適合的文字特徵表示並不完全相同。因此，後續進行智慧財產權判決文本分類時，不宜將同一種文字特徵表示直接套用於所有案件類型，而應依據案件性質、文本結構、詞彙分布與分類目的進行選擇。本文依據第四章 Direct SVM 之實證結果，整理在本研究資料條件下，不同案件類型可優先考慮之文字特徵與模型流程如下。

表 5-1 不同案件類型下可優先考慮之文字特徵與模型流程

使用情境	建議方法	理由
行政案件分類	BoW + Chi-square + Direct SVM	依表 4-4，行政案件中 BoW 的 Macro F1 表現最高，表示原始詞彙出現資訊可能較能反映行政案件之程序用語與裁判結果差異。
民事案件分類	TF-IDF + Chi-square + Direct SVM	依表 4-4，民事案件中 TF-IDF 的 Macro F1 表現最高，表示較具區辨力或相對稀有的權利主張、請求類型與法律爭點詞彙可能較重要。
刑事案件分類	TF + Chi-square + Direct SVM	依表 4-4，刑事案件中 TF 的 Macro F1 表現最高，表示詞彙在單篇裁判書中的相對出現頻率可能比原始詞頻或稀有詞加權更具分類效果。
刑事附帶民事案件分類	BoW + Chi-square + Direct SVM	依表 4-4，刑事附帶民事案件中 BoW 的 Macro F1 表現最高，表示原始詞彙出現或次數可能已包含較明確之分類訊號。

由上表可知，在本研究資料條件下，不同案件類型適合的文字特徵表示並不完全相同。行政案件與刑事附帶民事案件可優先考慮 BoW，民事案件可優先考慮 TF-IDF，刑事案件則可優先考慮 TF。此結果表示，法律文本分類不宜將同一種文字特徵表示直接套用於所有案件類型，而應依據案件性質、文本結構與詞彙分布進行選擇。

進一步而言，若分類訊號主要來自特定法律用語、程序用語或裁判理由詞彙本身是否出現，BoW 可能較能保留原始詞彙訊號；若裁判書長度差異較大，TF 可能較能降低長文本對詞彙次數的影響；若特定權利主張、技術爭點或專門法律用語較具區辨力，TF-IDF 則可能較能強化相對稀有但具有分類意義的詞彙。不過，上述建議應限縮於本研究資料、文本處理方式與模型設定之下，不宜直接推論為所有智慧財產權案件皆適用相同組合。

5.4.3 對後續研究與實務應用之建議

本研究結果顯示，智慧財產權判決文本分類模型雖能從裁判書文字中學習部分分類訊號，但其應用範圍仍須審慎界定。

本文模型較適合作為法律文本分類、案件初步篩選或研究輔助工具，而不宜直接作為個案勝敗預測或法律決策依據。尤其本研究模型對多數類別表現相對較佳，但對 Mixed 與 Win

等少數類別仍存在辨識不足的問題。若將模型直接用於實務判斷，可能低估部分勝訴或勝訴案件的可能性。因此，模型輸出仍應搭配人工審查與個案脈絡分析。

在後續研究方面，第一，建議進一步強化模型可解釋性。雖然本研究已透過 Chi-square、BoW、TF、TF-IDF 與 Direct SVM 建立相對清楚的分類流程，但目前仍主要呈現模型表現，尚未深入分析模型實際依賴哪些詞彙或語境進行判斷。因此，後續研究可進一步檢視高卡方詞彙、SVM 權重、MNIR loading 與錯誤案例，以確認模型是否真正捕捉到法律爭點、請求類型、程序用語或裁判理由，而非僅學習到表面詞彙關聯。

第二，後續研究應進一步檢驗模型結果的穩定性。本研究採固定訓練集、驗證集與測試集切分，能建立清楚且可重複的實驗流程。然而，單次切分結果仍可能受到特定樣本分布影響。若要提高結論穩健性，後續研究可加入重複隨機切分、交叉驗證、bootstrap 重抽樣檢定，或不同年度區間的外部測試資料。特別是本研究資料橫跨較長期間，不同年度的案件數量、裁判用語與案件類型分布可能有所變化，因此未來可進一步檢驗模型在不同時間區間下是否維持相似表現。

第三，本研究結果顯示，少數類別辨識能力是後續模型改進的重要方向。錯誤分析顯示，模型容易將 Mixed 或 Win 類別誤判為 Lose 類別，反映模型表現仍受到類別不平衡與少數類別樣本不足影響。因此，未來研究可導入類別權重、過度抽樣、欠抽樣或其他不平衡資料處理方法，以提升模型對少數裁判結果類別的辨識能力。同時，模型改進效果不應僅以整體 Accuracy 判斷，而應搭配 Macro F1、各類別 F1-score 與混淆矩陣進行檢驗，以確認模型是否真正改善 Mixed 與 Win 等少數類別之表現。

第四，在實務應用上，模型輸出應被定位為輔助性資訊。模型可用於大量裁判書的初步分類、案件類型比較、研究樣本整理，或協助研究者快速辨識可能具有特定裁判結果特徵的案件。然而，智慧財產權案件常涉及技術事實、權利範圍、法律要件與法院裁量判斷，單純依據裁判文本詞彙分布仍不足以完整判斷個案結果。因此，模型結果應搭配法律專業審查與個案脈絡分析，而不宜單獨作為訴訟策略或法律意見之依據。

綜合而言，後續智慧財產權法律文本分類可朝三個方向發展：第一，建立清楚可比較的基準模型；第二，強化少數類別辨識、模型可解釋性與結果穩定性；第三，在實務應用上明確界定模型僅能作為輔助工具。如此才能避免將模型分類結果過度解讀，也能使文字探勘方法更穩健地應用於法律研究與法律科技場域。

5.5 總結

整體而言，本研究證實，臺灣智慧財產權判決文本中確實存在可供機器學習模型辨識之文字訊號。透過文字特徵建構、卡方特徵選擇、MNIR 監督式特徵轉換與 SVM 分類模型之比較，本研究發現，在本研究資料與設定下，Chi-square + Direct SVM 相較於 Chi-square + MNIR + SVM 具有較佳分類表現，顯示卡方篩選後之稀疏文字特徵已能保留相當程度的裁判結果分類訊息。因此，傳統文字特徵結合 Direct SVM 可作為智慧財產權判決文本分類任務中具參考價值的基準流程。然而，本研究亦顯示，模型表現不應僅以整體準確率判斷。由於裁判結果存在明顯類別不平衡，模型雖能在多數類別上取得一定分類能力，但對 Mixed 與 Win 等少數類別仍存在辨識不足的問題。此結果說明，智慧財產權判決文本分類的核心挑戰，不只是建立能夠預測裁判結果的模型，更在於模型是否能均衡辨識不同裁判結果類別，並避免因多數類別主導而高估模型表現。此外，本研究結果也顯示，不同案件類型適合的文字特徵表示並不完全相同。行政與刑事附帶民事案件中，BoW 表現相對較佳；民事案件中，TF-IDF 表現相對較佳；刑事案件中，TF 表現相對較佳。此結果表示，法律文本分類不宜預設單一文字特徵表示或模型流程必然最佳，而應依案件類型、文本結構、詞彙分布與研究目的進行選擇。

綜合而言，本研究之主要貢獻在於建立臺灣智慧財產權判決文本之三類裁判結果分類流程，並透過不同案件類型、不同文字特徵表示與不同模型流程之比較，說明法律文本分類中的模型表現差異與少數類別限制。未來若欲進一步提升模型之研究價值與實務參考性，應優先強化少數類別辨識、模型可解釋性與結果穩定性，並審慎界定模型作為法律文本分析輔助工具之角色，而非將其直接視為個案裁判結果預測之依據。

參考文獻

- 法務部全國法規資料庫。(2023, 4月26日)。智慧財產及商業法院組織法。全國法規資料庫。<https://law.moj.gov.tw/LawClass/LawAll.aspx?pcode=A0010090>
- 司法院。(2026, 3月31日)。行政訴訟。司法院全球資訊網。
<https://www.judicial.gov.tw/tw/np-85-1.html>
- 司法院。(2025, 9月3日)。民事訴訟須知。司法院全球資訊網。
<https://www.judicial.gov.tw/tw/cp-165-27-430b8-1.html>
- 司法院。(2025, 5月29日)。刑事訴訟須知。司法院全球資訊網。
<https://www.judicial.gov.tw/tw/cp-165-28-683b6-1.html>
- 司法院。(2025, 10月9日)。刑事附帶民事訴訟起訴狀。司法院全球資訊網。
<https://www.judicial.gov.tw/tw/cp-1370-4310-e5078-1.html>
- 林常青。(2019)。臺灣法律經濟學實證的判決資料—介紹與應用。經濟論文, 47(4), 533–546。
<https://www.airitilibrary.com/Article/Detail/1018161x-201912-201912300022-201912300022-533-546>
- 張添榜、王立達、劉尚志。(2013)。我國專利法上均等論適用之實證研究：是變奏還是變調？科技法學評論, 10(2), 1-71。
<https://lawdata.com.tw/tw/doi/?doi=10.3966/181130952013121002001>
- 陳秉訓。(2021)。從共同侵權行為理論分析方法請求項之複數執行者問題：以一件行動支付類金融科技專利為例。專利師, 47, 1-11。
<https://lawdata.com.tw/tw/doi/?doi=10.3966/221845622021100047001>
- 郭建中、陳羿愷。(2020)。從數據一探智慧財產法院運作實況：專題三，民事訴訟。Winkler Partners。
<https://winklerpartners.com/zh/%E5%BE%9E%E6%95%B8%E6%93%9A%E4%B8%80%E6%8E%A2%E6%99%BA%E6%85%A7%E8%B2%A1%E7%94%A2%E6%B3%95%E9%99%A2%E9%81%8B%E4%BD%9C%E5%AF%A6%E6%B3%81-%E5%B0%88%E9%A1%8C%E4%B8%89-%E6%B0%91%E4%BA%8B/>
- Aletras, N., Tsarapatsanis, D., Preotiu-Pietro, D., & Lampos, V. (2016). Predicting judicial decisions of the European Court of Human Rights: A natural language processing perspective. *PeerJ Computer Science*, 2, Article e93. <https://doi.org/10.7717/peerj-cs.93>

- Alghazzawi, D., Bamasag, O., Albeshri, A., Sana, I., Ullah, H., & Asghar, M. Z. (2022). Efficient prediction of court judgments using an LSTM+CNN neural network model with an optimal feature set. *Mathematics*, 10(5), Article 683. <https://doi.org/10.3390/math10050683>
- Ariai, F., Mackenzie, J., & Demartini, G. (2026). Natural language processing for the legal domain: A survey of tasks, datasets, models, and challenges. *ACM Computing Surveys*, 58(6), Article 163, 1–37. <https://doi.org/10.1145/3777009>
- Chang, Y.-C., Chen, K.-P., & Lin, C.-C. (2018). *Anchoring effect in real litigation: An empirical study*. SSRN. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=2726903
- Chalkidis, I., Androutsopoulos, I., & Aletras, N. (2019). Neural legal judgment prediction in English. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics* (pp. 4317–4323). Association for Computational Linguistics. <https://aclanthology.org/P19-1424/>
- Chen, K.-P., Huang, K.-C., & Lin, C.-C. (2015). Party capability versus court preference: Why do the “haves” come out ahead? An empirical lesson from the Taiwan Supreme Court. *Journal of Law, Economics, and Organization*, 31(1), 93–126. <https://doi.org/10.1093/jleo/ewt022>
- CKIP Lab. (n.d.). *CKIP Transformers* [Computer software]. GitHub. Retrieved May 10, 2026, from <https://github.com/ckiplab/ckip-transformers>
- Eren, O., & Mocan, N. (2018). Emotional judges and unlucky juveniles. *American Economic Journal: Applied Economics*, 10(3), 171–205. <https://doi.org/10.1257/app.20160390>
- Feng, Y., Li, C., & Ng, V. (2022). Legal judgment prediction: A survey of the state of the art. In *Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence* (pp. 5461–5469). International Joint Conferences on Artificial Intelligence Organization. <https://doi.org/10.24963/ijcai.2022/765>
- Heyes, A., & Saberian, S. (2019). Temperature and decisions: Evidence from 207,000 court cases. *American Economic Journal: Applied Economics*, 11(2), 238–265. <https://doi.org/10.1257/app.20170223>
- Hsieh, D., Chen, L., & Sun, T. (2021). Legal judgment prediction based on machine learning: Predicting the discretionary damages of mental suffering in fatal car accident cases. *Applied Sciences*, 11(21), Article 10361. <https://doi.org/10.3390/app112110361>

- Mamakas, D., Tsotsi, P., Androutsopoulos, I., & Chalkidis, I. (2022). Processing long legal documents with pre-trained transformers: Modding LegalBERT and Longformer. In *Proceedings of the Natural Legal Language Processing Workshop 2022* (pp. 130–142). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2022.nllp-1.11>
- Manning, C. D., Raghavan, P., & Schütze, H. (2009). *Introduction to information retrieval*. Cambridge University Press.
- scikit-learn developers. (n.d.-a). sklearn.feature_selection.chi2. scikit-learn. Retrieved May 10, 2026, from https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.chi2.html
- scikit-learn developers. (n.d.-b). sklearn.feature_extraction.text.TfidfVectorizer. scikit-learn. Retrieved May 10, 2026, from https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html
- Surdeanu, M., Nallapati, R., Gregory, G., Walker, J., & Manning, C. D. (2011). Risk analysis for intellectual property litigation. In *Proceedings of the 13th International Conference on Artificial Intelligence and Law* (pp. 116–120). Association for Computing Machinery. <https://doi.org/10.1145/2018358.2018375>
- Taddy, M. (2013). Multinomial inverse regression for text analysis. *Journal of the American Statistical Association*, 108(503), 755–770. <https://doi.org/10.1080/01621459.2012.734168>
- Tang, Y., & Yang, Y. (2025). FinMTEB: Finance massive text embedding benchmark. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing* (pp. 3620–3638). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2025.emnlp-main.179>
- Yang, S., Tong, S., Zhu, G., Cao, J., Wang, Y., Xue, Z., Sun, H., & Wen, Y. (2022). MVE-FLK: A multi-task legal judgment prediction via multi-view encoder fusing legal keywords. *Knowledge-Based Systems*, 239, Article 107960. <https://doi.org/10.1016/j.knosys.2021.107960>