

判決文本會說話嗎？

臺灣智慧財產權裁判結果之文字探勘與分類研究

指導教授： 林金龍 教授
侯介澤 教授

研究核心

論文第 2 頁



研究發現

01

Direct SVM 表現較佳

在行政、民事、刑事及刑事附帶民事案件中，Chi-square + Direct SVM 的 Macro F1 均高於 MNIR + SVM。

02

不同案件適合不同文字特徵

行政案件：BoW

民事案件：TF-IDF


刑事案件：TF

刑事附帶民事案件：BoW

03

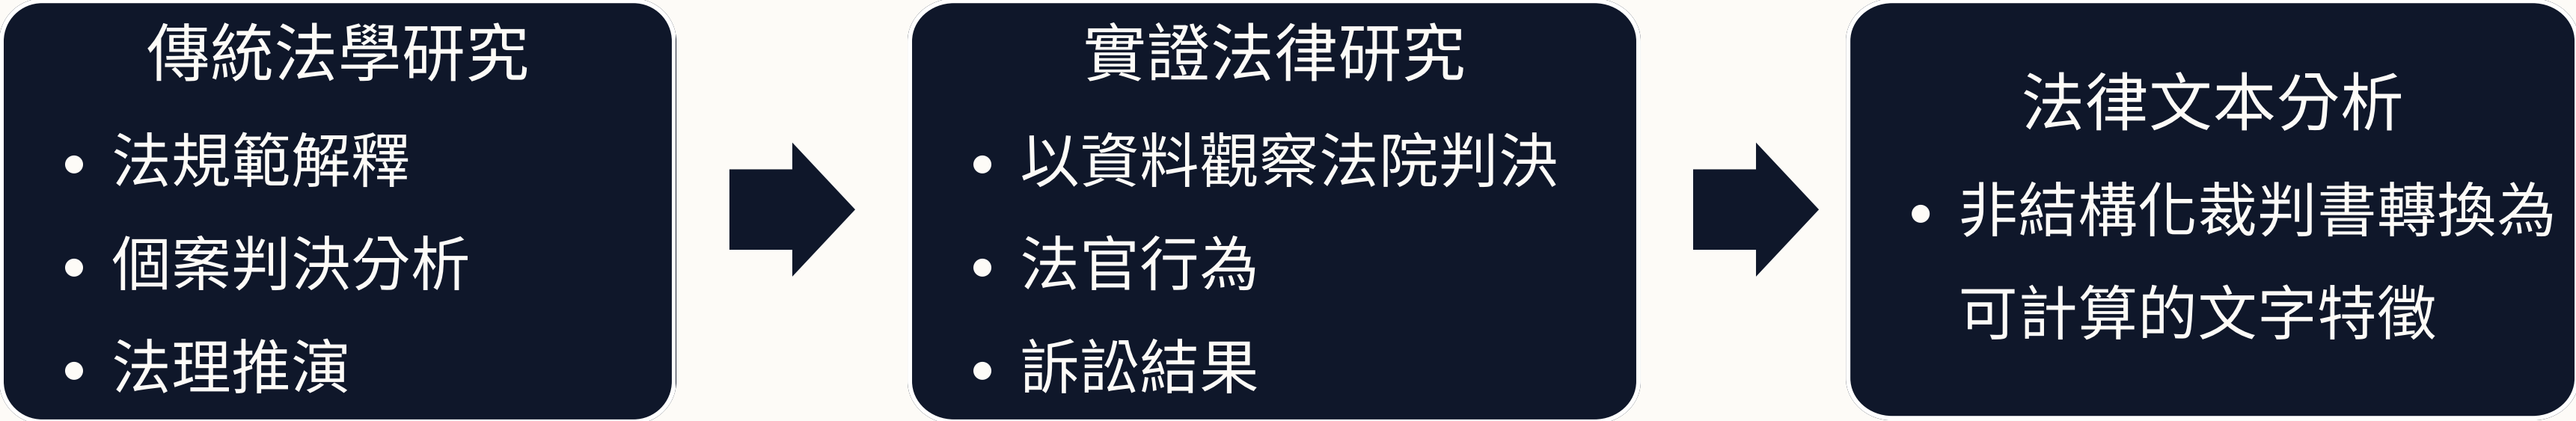
少數類別仍難以辨識

模型對「敗訴」案件辨識較佳，但容易將「部分勝訴」與「勝訴」誤判為「敗訴」。




研究問題成立：背景與動機

傳統法學研究	實證法學／資料導向研究
重視法條解釋、判決理由、規範論證	重視大量資料、可觀察模式、統計與模型
常以個案或少量判決深入分析	可處理大規模裁判文本
問「法律應如何解釋」	問「判決資料呈現什麼模式」



研究問題成立：背景與動機

論文第 13 頁



研究問題成立：智財案件特性

論文第 25 頁

專業術語密集

- 專利、商標、著作權、營業秘密等領域用語
- 技術事實與法律要件交織
- 詞彙本身可能具有分類訊號

案件類型差異明顯

- 行政案件
- 民事案件
- 刑事案件
- 刑事附帶民事案件

文本結構複雜


- 當事人主張
- 證據與技術事實
- 法律要件判斷
- 裁判理由

文本訊號具可檢驗性

- 請求類型
- 程序用語
- 侵權判斷用語
- 裁判理由用語

研究問題成立：類別不平衡


論文第 26 頁



裁判結果分布不均



模型傾向預測多數類別



Accuracy 看似不錯



少數類別辨識被掩蓋

研究問題成立：文獻回顧與缺口

論文第 15 頁

實證法律研究

- 法律研究逐漸從法規範解釋，延伸到以資料觀察「行動中的法律」。
- 判決書可作為法院行為與訴訟結果的量化資料。

法律文本特徵表示

- 判決書屬於非結構化文本，需轉換為模型可處理的數值特徵。
- 本研究比較 BoW、TF、TF-IDF。

判決預測與可解釋性

- 法律判決預測研究顯示，文本中可能存在可學習的裁判結果訊號。
- 但法律場域不能只追求 Accuracy，也需重視可解釋性與類別表現。

MNIR 監督式特徵轉換

- MNIR 可將高維文字特徵轉換為與結果相關的低維表示。
- 本研究檢驗 MNIR + SVM 是否優於 Direct SVM。

本研究要檢驗什麼？

論文第 14 頁

分類可行性

判決文本是否能提供足以區分 Lose / Mixed / Win 的文字訊號？

案件類型

行政、民事、刑事、刑事附帶民事是否呈現不同分類表現？

特徵與模型


BoW、TF、TF-IDF 以及 MNIR + SVM / Direct SVM 的表現是否不同？

少數類別


在類別不平衡下，Mixed / Win 是否容易被模型忽略或誤判？

研究設計驗證：分類建模


論文第 21 頁



研究設計驗證：資料與標籤



研究設計驗證：資料與標籤



資料集	Lose	Mixed	Win	合計
行政	10,106	502	911	11,519
民事	3,887	1,408	435	5,730
刑事	24,552	80	1,636	26,268
刑事附帶民事	748	1,047	32	1,827
合計	39,293	3,037	3,014	45,344

挑戰 1：
整體類別不平衡Lose 共 39,293 筆，遠高於 Mixed 和 Win

挑戰 2：
案件類型差異明顯不同案件類型的分布差很多



研究設計驗證：特徵與模型

論文第 28 頁



明顯裁判結果詞：

駁回、准許、撤銷、有理由、無理由、有罪、無罪

停用詞：

。、依據、為何、以為、只有



研究設計驗證：特徵與模型

同一份斷詞後文本，轉換為三種文字特徵表示，再分別進入模型比較。

特徵表示	計算概念	在法律文本中的意義
BoW	詞是否出現 / 出現次數	保留特定法律用語是否出現在判決中
TF	詞在單篇判決中的出現頻率	反映某些爭點或法律概念在個案中被反覆討論的程度
TF-IDF	同時考量單篇詞頻與整體稀有程度	強化較具區辨力的專門詞彙，降低一般高頻詞影響



研究設計驗證：特徵與模型

	專利 範圍	混淆 誤認	技術 特徵	重製	
判決 1	0	1	0	2	Lose
判決 2	0	3	0	1	Lose
判決 3	0	0	5	0	Win

詞 A：三類都常見 → 關聯低

Lose 

Mixed 

Win 

詞 B：某一類明顯較常見 → 關聯高

Lose 

Mixed 


Win 

依 Chi-square 分數排序

- 1. 詞 B 高
- 2. 詞 C 高
- 3. 詞 D 中高
- ...
- K. 詞 K


保留前 K 個詞彙特徵

Chi-square 不負責分類，而是先縮小詞彙空間，讓後續模型聚焦於較可能區分裁判結果的文字訊號。



研究設計驗證：特徵與模型

論文第 37 頁



研究設計驗證：特徵與模型

$$\hat{\Phi}^T \cdot \mathbf{f}_i = \mathbf{z}_i$$

$$(K \times P) \quad (P \times 1) \quad (K \times 1)$$

$$\begin{bmatrix} \hat{\phi}_{11} & \hat{\phi}_{21} & \cdots & \hat{\phi}_{P1} \\ \hat{\phi}_{12} & \hat{\phi}_{22} & \cdots & \hat{\phi}_{P2} \\ \vdots & \vdots & \ddots & \vdots \\ \hat{\phi}_{1K} & \hat{\phi}_{2K} & \cdots & \hat{\phi}_{PK} \end{bmatrix} \begin{bmatrix} f_{i1} \\ f_{i2} \\ \vdots \\ f_{iP} \end{bmatrix} = \begin{bmatrix} z_{i1} \\ z_{i2} \\ \vdots \\ z_{iK} \end{bmatrix}$$

$\mathbf{x}_i$: 第 i 篇判決的詞彙計數向量

m_i : 第 i 篇判決的總詞數

$\mathbf{f}_i$: 標準化後的詞頻向量

P : Chi-square 後保留的詞彙特徵數

K : MNIR 轉換後的低維分數數量

$\hat{\Phi}$: MNIR 估計出的詞彙投影參數矩陣

$\mathbf{z}_i$: 第 i 篇判決的 MNIR scores

MNIR sufficient reductions: 3 outcome classes $\Rightarrow$ 2 independent SR scores

MNIR projection

Three outcome labels imply two independent SR directions.

$$\mathbf{f}_i = \mathbf{x}_i / m_i$$

text-frequency vector

$$P \times 1$$

$$\hat{\Phi}^T$$

MNIR projection matrix

$$2 \times P$$

$$\mathbf{z}_i$$

sufficient reduction scores

$$2 \times 1$$

$$\mathbf{z}_i = \hat{\Phi}^T \mathbf{f}_i$$


$$(2 \times P)(P \times 1) = (2 \times 1)$$

$$\mathbf{z}_i = [z_{i1}, z_{i2}]^T$$

The SVM uses SR1 and SR2 to classify Lose, Mixed, and Win.

This is a dimension-reduction step, not the final classifier.

Two-dimensional MNIR SR space



Conceptual illustration: points and boundaries are schematic, not empirical sample coordinates.

研究設計驗證：特徵與模型

論文第 38 頁

MNIR + SVM

輸入特徵：

$$\mathbf{z}_i = \begin{bmatrix} z_{i1} \\ z_{i2} \end{bmatrix}$$

Direct SVM

輸入特徵：

$$\mathbf{X}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{iK} \end{bmatrix}$$



Majority Class baseline 不使用文本內容，而是一律預測訓練集中最多的類別。

案件類型	Majority baseline Macro F1	最佳 Direct SVM Macro F1	是否提升
行政	0.311	0.380	是
民事	0.269	0.428	是
刑事	0.322	0.577	是
刑事附帶民事	0.245	0.654	是



結果主張	證據	意義
Direct SVM 較佳	四類案件中，Direct SVM 的 Macro F1 皆高於 MNIR + SVM	在本研究資料與設定下，MNIR 未帶來額外增益
沒有單一最佳特徵	行政 BoW、民事 TF-IDF、刑事 TF、 刑事附帶民事 BoW	文字特徵選擇須依案件類型判斷
Mixed / Win 仍難辨識	民事案件 Win F1 僅 0.130，Mixed / Win 常被判為 Lose	類別不平衡與少數類別辨識仍是主要限制



實證結果支持：Direct SVM 較佳

資料集	MNIR 最佳特徵	K	C	Accuracy	MNIR + SVM Macro F1
行政	BoW	5000	0.0625	0.875	0.318
民事	TF-IDF	1000	0.125	0.695	0.353
刑事	TF-IDF	5000	0.125	0.928	0.390
刑事附帶民事	TF	1000	0.125	0.823	0.545

觀察一：四類案件的最佳特徵不同

行政為 BoW，民事與刑事為 TF-IDF，刑事附帶民事為 TF。

觀察二：Accuracy 與 Macro F1 呈現不同面向

Accuracy 反應整體預測比例，Macro F1 反應三類結果平均表現。

實證結果支持：Direct SVM 較佳

資料集	Direct 最佳特徵	Accuracy	Macro F1	Majority Macro F1
行政	BoW	0.831	0.380	0.311
民事	TF-IDF	0.680	0.428	0.269
刑事	TF	0.951	0.577	0.322
刑事附帶民事	BoW	0.854	0.654	0.245

觀察一：四類案件皆高於 baseline

Direct SVM 的 Macro F1 均高於 Majority Class baseline。

觀察二：最佳特徵因案件而異

行政 BoW、民事 TF-IDF、刑事 TF、刑事附帶民事 BoW。

實證結果支持：Direct SVM 較佳

資料集	Direct 最佳特徵	Direct SVM Macro F1	MNIR 最佳特徵	MNIR + SVM Macro F1	Direct - MNIR
行政	BoW	0.380	BoW	0.318	0.062
民事	TF-IDF	0.428	TF-IDF	0.353	0.075
刑事	TF	0.577	TF-IDF	0.390	0.187
刑事附帶民事	BoW	0.654	TF	0.545	0.109

最大差距：刑事案件


Direct SVM 高出 0.187。

最小差距：行政案件

Direct SVM 高出 0.062。

整體判斷

四類案件方向一致，Direct SVM 較佳。




實證結果支持：無單一最佳特徵


資料集	BoW	TF	TF-IDF	最佳特徵
行政	0.380	0.341	0.375	BoW
民事	0.403	0.417	0.428	TF-IDF
刑事	0.564	0.577	0.562	TF
刑事附帶民事	0.654	0.580	0.572	BoW

文字特徵的選擇不能一概而論，必須依案件類型與文本結構判斷。

- 行政案件 BoW 較佳，可能與固定程序用語或法規爭點有關。
- 民事案件 TF-IDF 較佳，可能與爭點較多元、需降低常見詞權重有關。
- 刑事案件 TF 較佳，可能與特定事實或構成要件用語頻率有關。
- 刑事附帶民事 BoW 較佳，但因樣本與類別分布特殊，需保守解讀。



實證結果支持：無單一最佳特徵



實證結果支持：Mixed / Win 較難辨識

論文第 55 頁

Win：樣本少、最容易被忽略

Lose：樣本多、辨識較穩定

Mixed：樣本少、容易流向
Lose

1. 模型是否偏向 Lose？

- Mixed / Win 是否大量被預測為 Lose？

2. 少數類別 F1 是否偏低？

- Win 與 Mixed 的 Precision / Recall / F1 是否明顯低於 Lose？

3. 問題是否只出現在單一案件類型？


- 四案件中，各類別 F1 是否都呈現差異？

實證結果支持：Mixed / Win 較難辨識

實際 \ 預測	Pred. Lose	Pred. Mixed	Pred. Win	Total
Actual Lose	683 89.2%	77 10.1%	6 0.8%	766 100%
Actual Mixed	192 68.3%	80 28.5%	9 3.2%	281 100%
Actual Win	62 72.1%	17 19.8%	7 8.1%	86 100%

類別	Precision	Recall	F1-score	Support
Lose	0.729	0.892	0.802	766
Mixed	0.460	0.285	0.352	281
Win	0.318	0.081	0.130	86
macro avg	0.502	0.419	0.428	1133
weighted avg	0.631	0.680	0.639	1133

實證結果支持：Mixed / Win 較難辨識



資料集	Lose F1	Mixed F1	Win F1	Macro F1
行政	0.908	0.114	0.119	0.380
民事	0.802	0.352	0.130	0.428
刑事	0.974	0.167	0.591	0.577
刑事附帶民事	0.834	0.878	0.250	0.654

研究問題	回答	對應證據
RQ1 判決文本能否分類 裁判結果？	可以，但不同結果類別難度不同	Direct SVM 高於 baseline ； Lose F1 普遍較高
RQ2 案件類型是否影響 模型表現？	會，四類案件表現與最佳設定不同	四類案件 Macro F1、最佳特徵 與參數不同
RQ3 哪種文字特徵較 佳？	沒有單一最佳特徵	行政 BoW、民事 TF-IDF、刑事 TF、刑事附帶民事 BoW
RQ4 MNIR 是否優於 Direct SVM ？	否，在本研究設定下 Direct SVM 較佳	四類案件 Direct SVM Macro F1 均高於 MNIR + SVM

建立臺灣智財判決分類任務

- 聚焦臺灣智慧財產權
- 判決區分四類案件
- 將裁判結果整理為 Lose / Mixed / Win

系統比較文字特徵與模型流程

- 比較 BoW、TF、TF-IDF
- 比較 MNIR + SVM 與 Direct SVM
- 提供傳統稀疏文本模型的基準結果

指出少數裁判結果辨識限制

- Mixed / Win 辨識不穩定
- 類別不平衡影響模型學習
- 裁判結果標籤本身具有語意複雜度

研究限制	未來研究方向
類別不平衡	加入類別權重、重抽樣或成本敏感學習
Mixed 標籤複雜	更細緻區分部分勝訴型態或請求項目
文本段落尚未分開建模	比較事實、理由、當事人主張等段落訊號
傳統特徵語意有限	比較深度語意模型，並保留可解釋性分析

判決文本會說話嗎？

論文第 68 頁

判決文本確實包含可供模型辨識的裁判結果訊號，但模型表現受到案件類型、文字特徵、模型流程與少數類別限制影響。